



SOGANG UNIVERSITY
AI.SW GRADUATE SCHOOL

ACADEMIC REPORT

중간고사 REPORT

통계기반 데이터 분석

대학원

AI.SW 대학원

학과

소프트웨어 및 시스템공학과

이름

이인범

담당 교수

정화민 교수님

제출 일자

2026.04.27

목차

TABLE OF CONTENTS

- 01 학습모듈 개요 MODULE OVERVIEW
- 02 가설의 개념과 검정 방법 HYPOTHESIS CONCEPTS & TESTING METHODS
- 03 가설 검정 오류 및 평가 기준 TESTING ERRORS & EVALUATION CRITERIA
- 04 통계 기반 분석모델 개요 STATISTICAL ANALYSIS MODELS OVERVIEW
- 05 회귀·분산·주성분·판별 분석 REGRESSION · ANOVA · PCA · DISCRIMINANT
- 06 데이터 마이닝 분석 기법 DATA MINING: CLASSIFICATION · PREDICTION · CLUSTERING
- 07 앙상블·파생변수·시각화 ENSEMBLE · DERIVED VARIABLE · VISUALIZATION
- 08 빅데이터 모델 평가 및 검증 MODEL EVALUATION & VALIDATION
- 09 빅데이터 모델 운영방안 BIG DATA MODEL OPERATIONS
- 10 핵심 개념 종합 정리 KEY CONCEPTS SUMMARY

SECTION 1

· HYPOTHESIS SETUP

가설 설정하기

가설의 개념·종류부터 귀무가설·대립가설 검정,
제1·2종 오류, 검정 통계량과 p-값까지

01



01. 학습모듈 개요

MODULE OVERVIEW

■ 학습 목표

수집된 정형·비정형 데이터를 활용하여 가설 설정 후 통계 기반 분석 모델을 수립하고 평가하는 역량을 함양한다.

■ 학습 구성 체계

학습 1 → 가설 설정하기 | 귀무·대립가설 수립, 가설 검정 방법 및 오류 이해

학습 2 → 빅데이터 모델 개발하기 | 통계·마이닝 기법 선택, 앙상블·시각화 활용

학습 3 → 빅데이터 모델 평가·검증하기 | 데이터셋 분할, 과적합, 성능 평가 지표

학습 4 → 빅데이터 모델 운영방안 마련하기 | 운영 프로세스, 성능 추적·개선

■ 핵심 분석 유형

예측(Prediction) | 분류(Classification) | 군집(Clustering) | 연관(Association Rule)

■ 선수학습

빅데이터 분석 기획 / 분석용 데이터 탐색 (LM2001010506_15v1)



02. 가설의 개념과 종류

HYPOTHESIS: CONCEPTS & TYPES

■ 빅데이터 분석과 가설의 관계

빅데이터 분석에서 통계적 모델의 유의성을 검증하기 위해서는 반드시 가설을 설정해야 한다. 가설이란 모집단의 모수(parameter)에 대해 세운 가정 혹은 잠정적 결론으로, 표본 데이터를 통해 그 진위 여부를 판단하는 것이 가설검정(Hypothesis Testing)의 목적이다.

■ 귀무가설 (H_0 , Null Hypothesis)

현재까지 주장되어 온 것, 또는 기존과 차이가 없음을 나타내는 가설이다. 가설검정의 출발점은 항상 '귀무가설이 참이다'라는 전제에서 시작한다. 예를 들어 신약의 효과를 검증하는 경우, 귀무가설은 '신약의 효과가 없다(기존 약과 차이 없다)'로 설정된다.

■ 대립가설 (H_1 , Alternative Hypothesis)

연구가설(Research Hypothesis)이라고도 하며, 연구자가 표본을 통해 확실히 입증하고자 하는 가설이다. 통계적으로 유의미한 증거가 확보되면 귀무가설을 기각하고 대립가설을 채택한다.

■ 핵심 원칙

귀무가설이 참이라는 전제 하에 표본으로부터 매우 극단적인 통계값이 나타날 경우(즉, 유의수준 이하의 확률로 발생하는 경우)에만 귀무가설을 기각한다. 이는 '무죄 추정의 원칙'과 유사한 논리 구조를 가진다.



■ 예시 1: 다이어트 프로그램 효과 검증

한 제약회사가 새로운 다이어트 프로그램의 체중 감소 효과를 광고한다. 이를 검증하기 위해 지원자 10명을 모집하고, 프로그램 참여 전·후 체중을 각각 측정하였다.

(1) 양측검정으로 설정하는 경우

H_0 : 참여 전후 체중 차이의 모평균 = 0 (효과 없음)

H_1 : 참여 전후 체중 차이의 모평균 $\neq 0$ (어떤 변화가 있음, 방향 미지정)

(2) 단측검정으로 설정하는 경우 (더 강력한 주장)

H_0 : 참여 전후 체중 차이의 모평균 ≤ 0 (효과 없거나 오히려 증가)

H_1 : 참여 전후 체중 차이의 모평균 > 0 (체중이 감소하였다, 방향 지정)

■ 예시 2: K 회사 고객만족도 변화 검증

K 회사는 기존 고객만족도 평균이 8.6점(표준편차 0.8점)이었다. 최근 200명 조사 결과 평균 8.8점이 나왔다. 기존 만족도와 유의미한 차이가 있는지 검증하고자 한다.

$H_0: \mu = 8.6$ (기존과 동일) | $H_1: \mu \neq 8.6$ (기존과 다름)

→ 이 경우 모분산(0.8^2)을 알고 있으므로 z 검정 통계량을 사용한다.



03. 가설 검정 방법

HYPOTHESIS TESTING METHODS

■ 양측검정 vs 단측검정

양측 검정(Two-sided test): $H_1: \mu \neq \mu_0$ — 방향 없이 '다른지 여부'만 판단한다. 기각역이 분포의 양쪽 꼬리에 위치하며, 차이의 방향에 관심이 없을 때 사용한다.

단측 검정(One-sided test): $H_1: \mu > \mu_0$ 또는 $\mu < \mu_0$ — 방향성을 포함하여 '더 큰지' 또는 '더 작은지'를 판단한다. 기각역이 한쪽 꼬리에만 위치하므로, 동일 유의수준에서 양측검정보다 검정력이 높다.

■ 가설검정 4단계 절차

- ① 데이터 분석 목적 명확화 — 어떤 목적으로 분석하는지 명확히 하고, 표본을 통한 모집단 특성 추론이라는 통계적 접근이 분석 목적에 부합하는지 확인한다.
- ② 데이터 수집·확보 및 가설 설정 — 분석 목적에 맞는 데이터를 수집하고, 검증하고자 하는 내용을 귀무가설(H_0)과 대립가설(H_1)로 명시적으로 설정한다.
- ③ 검정 통계량 계산 — 수집된 데이터의 종류(연속형/범주형)와 인자 수에 따라 적절한 검정 도구(z, t, χ^2, F)를 결정하고 통계량을 계산한다.
- ④ 귀무가설 채택/기각 결정 — 산출된 p -값을 사전에 설정한 유의수준(α)과 비교한다. $p < \alpha$ 이면 귀무가설을 기각하고 대립가설을 채택하며, $p \geq \alpha$ 이면 귀무가설을 기각할 충분한 증거가 없다고 판단한다.



04. 가설 검정 오류

HYPOTHESIS TESTING ERRORS

	H_0 채택 (기각 못함)	H_0 기각
H_0 참 (실제)	✓ 올바른 결정 (신뢰수준 $1-\alpha$)	✗ 제1종 오류 (α)
H_0 거짓 (실제)	✗ 제2종 오류 (β)	✓ 올바른 결정 (검정력 $1-\beta$)

■ 제1종 오류 (α , Type I Error) — 거짓 양성(False Positive)

실제로는 H_0 이 참인데 잘못 기각하는 오류이다. 유의수준(α)은 제1종 오류를 허용하는 최대 확률을 의미하며, 통상 1%, 5%, 10%로 설정한다. 예를 들어 실제로 효과가 없는 약을 '효과가 있다'고 판정하는 경우이다.

■ 제2종 오류 (β , Type II Error) — 거짓 음성(False Negative)

실제로는 H_0 이 거짓인데(즉, 효과가 있는데) 이를 놓쳐서 H_0 을 채택하는 오류이다. 예를 들어 실제로 효과가 있는 약을 '효과가 없다'고 판정하는 경우에 해당한다.

■ 검정력 (Power = $1 - \beta$)

H_0 이 거짓일 때 이를 올바르게 기각할 확률이다. 검정력이 높을수록 실제 효과를 놓치지 않을 가능성이 높다.

■ 두 오류의 트레이드오프 관계

α 를 낮추면(기준을 엄격하게 하면) 제1종 오류는 줄지만, 반대로 실제 효과를 놓칠 확률(β)이 증가한다. 이 트레이드오프를 적절히 관리하는 것이 가설검정 설계의 핵심이다.



05. 검정 통계량과 p-값

TEST STATISTICS & p-VALUE

통계량	분포	사용 조건
z 통계량	정규분포 (N)	모분산을 알고 있을 때
t 통계량	t분포 (자유도 n-1)	모분산을 모를 때 (소표본)
χ^2 통계량	카이제곱분포	분산 검정, 명목형 변수 독립성
F 통계량	F분포	두 집단 분산 비교, 분산분석

■ p-값 (p-value)의 정의

H_0 이 참이라는 전제 하에 현재 통계량 이상의 극단값이 나타날 확률

→ 제1종 오류(α)를 범할 확률로도 해석 가능 | p값이 작을수록 H_0 에 반하는 증거가 강함

■ 판단 기준

$p < \text{유의수준}(\alpha) \rightarrow H_0$ 기각, H_1 채택 (통계적으로 유의미)

$p \geq \text{유의수준}(\alpha) \rightarrow H_0$ 채택 (기각 불충분)

※ 신뢰수준 = 1 - 유의수준 (예: 유의수준 5% → 신뢰수준 95%)



06. 가설 평가 기준 설정

HYPOTHESIS EVALUATION CRITERIA

유형	조건	검정 통계량
① 한 집단 vs 특정값	모분산 알면 z, 모르면 t	z 또는 t 검정
② 두 집단 평균 비교	독립 두 집단	z 또는 t 검정
③ 동일 집단 전후 비교	쌍체(paired) 데이터	쌍체 t 검정 (paired t-test)

분산 검정 유형	검정 통계량
한 집단의 모분산 vs 특정값	χ^2 (카이제곱) 검정
두 집단의 모분산 비교	F 검정



■ 검정 전 확인 사항

모집단의 정규성 가정 충족 여부 확인 필수 | 데이터 유형 → 가설 유형 → 통계량 순서로 선택

■ 쌍체 t-검정 실행 결과

PAIRED T-TEST: DIET PROGRAM EFFECTIVENESS

CODE 1 / SECTION 1



■ 핵심 결과 (Key Results)

- 표본 크기 (n): 10명
- 평균 차이 (전 - 후): 1.238 kg
- 표준편차: 1.1228
- t 통계량: 3.4868
- p-value (양측): 0.0069
- 유의수준 α : 0.05
- 판정: 귀무가설 기각 (H_0 Reject)

■ 결과 해석 (Interpretation)

- p-value(0.0069) < α (0.05) 이므로 귀무가설(H_0 : 차이=0)을 기각한다.
- 다이어트 프로그램 전후의 평균 체중 차이가 통계적으로 유의미함을 확인했다.
- 평균 1.238kg 감소 효과가 있으며, 이는 단순 우연이 아닌 프로그램의 실제 효과로 해석된다.
- 동일 표본의 전후 비교이므로 쌍체 t-검정(paired t-test)을 사용하는 것이 적절하였다.

SECTION 2

· STATISTICAL ANALYSIS MODELS

통계 기반 분석모델

기술통계·상관분석·회귀분석,

분산분석(ANOVA)·주성분분석(PCA)·판별분석

02



07. 통계 기반 분석모델 개요

STATISTICAL ANALYSIS MODELS OVERVIEW

■ 빅데이터 분석의 핵심

빅데이터 분석은 단순한 데이터 수집·처리 기술만이 아니라, 통계와 데이터마이닝 기법을 결합하여 데이터로부터 의미 있는 지식과 정보를 추출하는 것이 핵심이다.

■ 종속변수 유무에 따른 분석 방향

종속변수 있음 → 예측·분류 모델 | 종속변수 없음 → 군집·연관 모델

■ 분석 목적별 기법 분류

분석 목적	종속변수	대표 기법
예측 (Prediction)	연속형	회귀분석, 신경망, ARIMA
분류 (Classification)	범주형	로지스틱 회귀, 의사결정트리, SVM
군집 (Clustering)	없음	K-평균, 계층적 군집
연관 (Association Rule)	없음	연관규칙 분석 (장바구니)



08. 기술통계 & 상관분석

DESCRIPTIVE STATISTICS & CORRELATION

■ 기술통계 (Descriptive Statistics) — 분석의 첫 단계

수집한 데이터의 분포와 특성을 초기에 파악하는 과정으로, 모든 분석의 출발점이 된다.

중심 경향(Central Tendency): 평균(Mean), 중앙값(Median) — 데이터의 대표값

퍼짐 정도(Dispersion): 분산(Variance), 표준편차(SD), 범위(Range) — 데이터의 흩어진 정도

분포 형태: 왜도(Skewness, 비대칭성), 첨도(Kurtosis, 뾰족한 정도) — 정규분포로부터의 이탈 정도

시각화 도구: 히스토그램(분포 파악) / 박스플롯(이상치·사분위수) / 산점도(변수 간 관계)

■ 상관분석 (Correlation Analysis) — 두 변수 간 상호 연관성 파악

두 변수가 함께 변하는 정도를 정량적으로 측정한다. 변수의 유형에 따라 적용하는 상관분석 방법이 다르다. 상관계수는 연관의 '정도'를 나타내는 것이며, 인과관계를 의미하지는 않는다.

방법	대상 변수	원리	측정 내용
피어슨 (Pearson)	수치형 (연속형)	공분산을 표준화한 상관계수	$-1 \leq r \leq 1$, 선형 연관성
카이제곱 (χ^2)	명목형 (범주형)	분류표 발생빈도 기반 독립성 검정	교차분석, 빈도 비교
스피어만 (Spearman)	순서형	원데이터 대신 순위를 이용	순위 상관계수, 비선형 관계도 일부 포착



■ 피어슨 상관계수 (Pearson Correlation Coefficient)

두 수치형 변수 간의 선형적 연관성을 계량적으로 나타내는 지표이다. 공분산(Covariance)은 두 변수가 함께 변하는 정도를 나타내지만 변수의 단위에 의존적이어서 그 크기만으로 연관성의 강도를 판단하기 어렵다. 따라서 공분산을 각 변수의 표준편차로 나누어 표준화한 것이 피어슨 상관계수(r)이다.

$$r = \text{Cov}(X, Y) / (\text{SD}(X) \times \text{SD}(Y)), \quad -1 \leq r \leq 1$$

$r = 1$: 완전한 양의 선형관계 | $r = -1$: 완전한 음의 선형관계 | $r = 0$: 선형관계 없음
 $|r| > 0.7$ 이면 강한 상관, $0.3 \sim 0.7$ 이면 중간 상관, < 0.3 이면 약한 상관으로 통상 해석한다.

■ 카이제곱(χ^2) 검정 — 명목형 변수의 독립성 검정

명목형(범주형) 변수 간에는 상관계수를 계산하는 것이 큰 의미가 없다. 따라서 분류표(교차표) 상의 발생빈도를 기반으로 두 변수 간의 독립성 여부를 추론하는 χ^2 검정을 사용한다.

■ 스피어만 순위 상관계수 (Spearman Rank Correlation)

원 데이터 대신 순위(rank)를 이용하여 상관계수를 산출한다. 비선형 단조관계도 일부 포착 가능하며, 순서형 변수뿐 아니라 이상치에 민감하지 않은 분석이 필요할 때도 활용된다.



■ 회귀분석의 목적과 원리

회귀분석은 종속변수와 하나 이상의 독립변수 간의 수학적 관계식(회귀식)을 도출하여, 독립변수의 값이 주어졌을 때 종속변수의 값을 예측하거나 변수 간 관계를 설명하는 통계 기법이다.

핵심 원리인 최소제곱법(Ordinary Least Squares, OLS)은 실제 관측값과 회귀식에 의한 예측값 사이의 오차(잔차) 제곱합을 최소화하는 회귀계수를 추정하는 방법이다. 이를 통해 데이터에 가장 잘 적합하는 직선(또는 평면)을 찾는다.

■ 회귀분석 종류

종류	독립변수	종속변수	특징
단순회귀	1개 (수치형)	1개 (수치형)	가장 기본적인 형태
다중회귀	2개 이상 (혼합 가능)	1개 (수치형)	실무에서 가장 많이 활용

※ 로지스틱 회귀는 종속변수가 범주형인 분류 모델 기법이다.



방법	방향	절차	특징
후진 제거법 (Backward)	전체 → 제거	모든 독립변수 포함 후 유의하지 않은 것 순차 제거	제거 시마다 회귀식 재추정
전진 선택법 (Forward)	없음 → 추가	가장 영향 큰 변수부터 하나씩 추가	추가 시 부분검정으로 중요도 평가
단계별 선택법 (Stepwise)	추가+제거 동시	전진 선택 + 후진 제거 절충형	가장 많이 활용되는 방법

■ 변수선택법의 필요성

다중회귀에서 독립변수가 많을수록 모델이 복잡해지고 과적합 위험이 커진다. 변수선택법은 종속변수에 유의미한 영향을 미치는 핵심 독립변수만을 선별하여, 설명력은 유지하면서 모델의 복잡도를 줄이는 것이 목적이다.

■ 회귀분석 결과 해석 시 주의점

회귀계수의 부호(+/-)는 독립변수가 종속변수에 미치는 영향의 방향을 나타내고, 크기는 영향의 강도를 나타낸다. 다만, 회귀분석은 상관관계를 보여줄 뿐 인과관계를 직접 증명하지는 않으므로 해석에 주의가 필요하다. 다중공선성(독립변수 간 높은 상관)이 있으면 회귀계수 추정이 불안정해지므로 VIF 등으로 사전 점검하는 것이 바람직하다.



10. 분산분석 & 주성분분석 & 판별분석

ANOVA · PCA · DISCRIMINANT ANALYSIS

■ ANOVA (분산분석, Analysis of Variance)

2개 이상의 집단 간 평균 차이가 통계적으로 유의미한지를 검정하는 기법이다. 기본 원리는 전체 데이터의 변동(총변동)을 집단 간 변동과 집단 내 변동으로 분해하여, 집단 간 변동이 집단 내 변동에 비해 충분히 큰지를 F분포를 이용하여 평가하는 것이다.

F통계량 = 집단 간 분산(MSB) / 집단 내 분산(MSW) → F값이 클수록 집단 간 차이가 유의미

종류: 일원분산분석(독립변수 1개) / 이원분산분석(2개) / 다변량분산분석 / 공분산분산분석

■ PCA (주성분분석, Principal Component Analysis)

변수가 많을 때 p개의 원래 변수를 p보다 적은 k개의 주성분(Principal Component)으로 요약하여 차원을 축소하는 비지도학습 기법이다. 주성분은 원래 변수들의 선형 결합으로 구성되며, 분산이 최대가 되는 방향으로 순서대로 추출된다.

변수가 많을수록 PCA의 가치가 크며, 2~3개 주성분만으로도 데이터의 주요 특성을 시각화(biplot)할 수 있다.




■ 판별분석 (Discriminant Analysis)

이미 알려진 집단 정보(종속변수)를 바탕으로 판별규칙과 판별함수를 도출하는 다변량 통계 기법이다. 도출된 판별함수를 이용하여 새로운 개체가 어떤 집단에 속하는지를 분류할 수 있다. 분류 모델의 한 종류로, 로지스틱 회귀와 함께 통계적 분류 기법으로 분류된다.

기술통계 실행 결과

DESCRIPTIVE STATISTICS - IRIS SEPAL LENGTH

CODE 2 / SECTION 2



핵심 결과 (Key Results)

- 데이터셋: iris (150 obs × 4 vars)
- 대상 변수: Sepal Length (cm)
- 평균 (Mean): 5.843
- 중앙값 (Median): 5.800
- 범위 (Range): 4.30 ~ 7.90
- 표준편차 (SD): 0.8281
- 왜도 (Skewness): 0.3149
- 첨도 (Kurtosis): -0.5521


결과 해석 (Interpretation)

- 평균(5.843)과 중앙값(5.800)이 거의 일치하여 분포의 대칭성이 양호하다.
- 왜도(Skewness)=0.315 > 0 이지만 0에 가까워 약한 우편향(우측 꼬리)을 보인다.
- 첨도(Kurtosis)=-0.552 < 0 으로 정규분포 대비 다소 평평한(완만한) 분포 형태이다.
- 박스플롯에서 이상치(outlier)가 거의 관찰되지 않아 데이터 품질이 양호한 것으로 판단된다.

상관분석 실행 결과

CORRELATION ANALYSIS - PEARSON / CHI² / SPEARMAN

CODE 3 / SECTION 2



핵심 결과 (Key Results)

- Pearson r (SL ~ SW): -0.1176
- Pearson r (SL ~ PL): 0.8718
- Pearson r (SL ~ PW): 0.8179
- Chi² 통계량: 111.6339
- Chi² p-value: 0.000000
- Spearman ρ (SL ~ PL): 0.8819
- Spearman p-value: 0.000000



결과 해석 (Interpretation)

- Sepal Length-Petal Length 간 $r=0.872$ 으로 강한 양의 선형 관계($|r|>0.7$)를 확인하였다.
- Sepal Length-Sepal Width 간 $r=-0.118$ 로 두 변수 간 선형 관계는 매우 약하다.
- Chi² 검정 $p=0.0000 < 0.05$ 이므로 품종(target)과 Sepal Length 그룹은 독립이 아니다.
- Spearman $\rho=0.882$ 으로 순위 기반에서도 강한 양의 단조관계가 확인된다.

주성분분석 (PCA) 실행 결과

PRINCIPAL COMPONENT ANALYSIS - DIMENSION REDUCTION

CODE 4 / SECTION 2



핵심 결과 (Key Results)

- 원 변수 개수: 4개 (sepal/petal × length/width)
- PC1 분산 설명력: 92.46%
- PC2 분산 설명력: 5.31%
- PC3 분산 설명력: 1.71%
- PC4 분산 설명력: 0.52%
- PC1+PC2 누적: 97.77%
- 표준편차 (PC1): 2.0563


결과 해석 (Interpretation)

- PC1 단독으로 전체 분산의 92.5%를 설명하여 차원축소 효과가 매우 크다.
- PC1+PC2 누적 97.8%로, 4차원을 2차원으로 축소해도 정보 손실이 약 2.2%에 불과하다.
- Biplot에서 setosa(빨강)는 다른 두 품종과 PC1 축에서 명확히 분리되어 분류 가능성이 높음을 시사한다.
- petal length/width 화살표가 PC1과 거의 평행하여 PC1이 꽃잎 크기 종합 지표 역할을 함을 알 수 있다.

로지스틱 회귀분석 실행 결과

LOGISTIC REGRESSION - ENGINE TYPE BY MPG (mtcars)

CODE 5 / SECTION 2



핵심 결과 (Key Results)

- 데이터셋: mtcars (32대)
- 종속변수 (Y): vs (0=V형, 1=직렬 엔진)
- 독립변수 (X): mpg (연비)
- Intercept (β_0): -8.8331
- mpg 회귀계수 (β_1): 0.4304
- p-value (Intercept): 0.0052
- p-value (mpg): 0.0066

결과 해석 (Interpretation)

- 두 회귀계수 모두 $p < 0.01$ 로 통계적으로 유의미하다 (Intercept $p=0.005$, mpg $p=0.007$).
- mpg 계수가 양수(+0.430)이므로, 연비가 높을수록 직렬 엔진(vs=1)일 확률이 증가한다.
- 시그모이드 곡선이 0.5를 통과하는 $mpg \approx 20.5$ 부근이 분류 경계선 역할을 한다.
- 종속변수가 범주형(0/1)이므로 일반 선형회귀가 아닌 로지스틱 회귀를 사용하는 것이 적절하였다.

SECTION 3

· DATA MINING METHODS

데이터 마이닝 분석 기법

분류·예측·군집·연관규칙 모델,

변수 유형별 분석 기법 선택

03



11. 데이터 마이닝 개요 & 분류 모델

DATA MINING OVERVIEW & CLASSIFICATION

■ 데이터 마이닝 (Data Mining)의 정의와 위상

대용량 데이터에서 패턴·관계·규칙을 통계적으로 탐색하고 모델화하는 기법의 총칭이다. 기존 통계 분석이 연구자가 세운 가설을 검정하는 데 초점을 둔다면, 데이터 마이닝은 가설 검정을 넘어 데이터로부터 새로운 가설과 규칙을 발견하는 것으로 확장된 개념이다.

■ 분류 (Classification)의 정의

사전에 정의된 집단(클래스)으로 새로운 개체를 분류하는 지도 학습 기법이다. 군집(Clustering)과의 핵심적 차이점은 사전에 정의된 집단과 구분을 위한 정보(종속변수, 레이블)가 존재한다는 것이다.

■ 통계적 분류 기법

로지스틱 회귀분석: 선형 회귀와 달리 종속변수가 서열형·범주형·명목형일 때 사용된다. 분석대상이 두 개 이상의 집단으로 구분되는 경우, 개별 관측치가 어느 집단에 분류될 수 있는지를 분석하고 이를 예측하는 모델을 개발하는 통계 기법이다.
판별분석: 다변량 통계이론에 근거하여 판별함수로 집단을 분류한다.

■ 데이터 마이닝 기반 분류 기법

트리 기반: 의사결정트리(CART) | 최적화: SVM | 기계학습: 인공신경망 → 세부 내용은 다음 슬라이드



■ 의사결정트리 (CART 알고리즘)

의사결정규칙에 따라 관심 집단을 소집단으로 분류하는 트리 기반 기법이다. 각 독립변수를 이분화(binary split)하는 과정을 반복하여 이진트리를 형성한다.

CART 3단계: ① 트리 형성(변수선정·분지기준 결정) → ② 가지치기(분류오류가 크거나 부적절한 가지를 제거, 과적합 방지) → ③ 최종 트리에서 분류규칙 도출

■ SVM (Support Vector Machine, 서포트 벡터 머신)

수리 최적화 기법을 통한 분류 모델이다. 데이터를 분리하는 초평면(hyperplane) 중에서 데이터와의 거리가 가장 먼 것, 즉 마진(margin)이 최대인 초평면을 선택한다. 초평면에 가장 가까운 데이터 포인트들을 서포트 벡터라 하며, 이들이 초평면의 위치를 결정한다.

■ 인공신경망 (Artificial Neural Network)

인간 뇌의 신경망 신호전달 방식을 모사한 기계학습 기법이다. 기대 출력값과 실제 출력값 간의 오차를 시냅스 역할 노드의 가중치 조정으로 반영한다. 역전파 알고리즘(Back Propagation)은 출력층에서 입력층 방향으로 오차를 역방향 전파하여 가중치를 갱신하며, 신경망 구조가 안정화될 때까지 이 과정을 반복한다.

블랙박스 모델로서 해석이 어렵지만, 분류와 예측 양쪽 모두에 활용 가능하다.



■ CART 1단계: 트리 형성 (Tree Growing)

훈련 데이터를 바탕으로 각 독립변수의 가능한 분기점(split point)을 탐색한다. 각 분기에서 데이터를 두 그룹으로 나누는 최적의 변수와 기준값을 선택하며, 지니 불순도(Gini impurity) 또는 정보 이득(Information Gain) 등의 기준으로 분기의 '순수도'를 평가한다. 더 이상 분기가 의미 없을 때까지 이 과정을 재귀적으로 반복한다.

■ CART 2단계: 가지치기 (Pruning)

1단계에서 형성된 트리는 훈련 데이터에 과적합되어 있을 가능성이 높다. 가지치기는 트리가 너무 복잡해지는 것을 방지하기 위해 분류오류를 크게 할 위험이 있거나 부적절한 분류규칙을 가진 가지(branch)를 잘라내는 과정이다. 이를 통해 더 단순하고 일반화 성능이 좋은 트리를 얻는다.

■ CART 3단계: 분류규칙 도출 (Classification Rule)

가지치기가 완료된 최종 트리에서 각 말단 노드(leaf node)에 대응하는 분류규칙을 도출한다. 이 규칙은 'IF (조건1 AND 조건2) THEN 클래스 A' 형태의 직관적인 규칙으로 표현되므로 해석이 용이하다.

■ 의사결정트리의 장점

분류 규칙이 명확하여 해석이 쉬움 | 비선형 관계와 상호작용을 자동으로 포착 | 데이터 전처리(정규화 등)가 불필요



13. 예측 모델 & 시계열 분석

PREDICTION MODEL & TIME SERIES

■ 예측 (Prediction) 정의

미래의 예상 결과 추정 — 분류:추정과 유사하나 시간 개념이 추가된 분석
과거 데이터가 존재할 경우 분류용 모델 대부분을 예측에도 적용 가능
예측 모델 종류: 회귀분석 / 의사결정트리 / 인공신경망 / 시계열 분석

■ 시계열 분석 (Time Series Analysis)

시계열 데이터: 관측치가 시간적 순서를 가지는 데이터
분해법: 계절성(Seasonality) / 추세(Trend) / 불확실성(Random) 으로 분리하여 분석

■ ARIMA 모델 (Auto-Regressive Integrated Moving Average)

BOX-JENKINS 모델(ARMA)의 일반화된 형태
AR (자기회귀) + I (차분, 안정적 시계열 변환) + MA (이동평균) 결합
파라미터 p, d, q 필요 → `auto.arima()` 함수로 자동 최적 파라미터 탐색 가능



14. 군집화 & 연관규칙

CLUSTERING & ASSOCIATION RULES

■ 군집화 (Clustering) — 비지도학습의 대표적 기법

이질적인 전체 집단을 유사한 속성을 가진 동질적 소집단으로 세분화하는 작업이다. 분류(Classification)와 달리 사전에 정의된 집단 정보나 정답 레이블이 존재하지 않는다는 점이 핵심적인 차이이다.

방법	군집 수	방식	대표 알고리즘
계층적 군집	미리 정하지 않음	단계별 산출	응집분석(합쳐감), 분할분석(나눠감)
비계층적 군집	사전 지정 (K)	객체 배정 반복	K-평균 군집화

■ K-평균 군집화 절차

① 실루엣값(Silhouette Width)으로 최적 K 결정 → ② 초기 K개 군집 중심 지정 → ③ 각 개체를 가장 가까운 중심에 배정 → ④ 군집 중심 재계산 → ⑤ ③④ 반복(수렴까지)

■ 연관규칙 (Association Rule)

데이터에 숨어있는 동시 발생 사건 간의 규칙을 수치화하는 기법이다. '어떤 이벤트가 또 다른 이벤트를 동반하는가'를 표현하며, 장바구니 분석 등 마케팅에 활용된다.



지표	의미	해석
지지도 (Support)	전체 거래 중 A와 B가 동시에 포함된 거래 비율	규칙의 빈도, 너무 낮으면 규칙 의미 없음
신뢰도 (Confidence)	A를 포함한 거래 중 B도 포함된 비율	규칙의 강도, $P(B A)$ 로 해석
향상도 (Lift)	A와 B가 독립일 때 대비 동시 발생 비율	1보다 크면 양의 연관, 1이면 독립, 1 미만이면 음의 연관

■ 연관규칙의 평가 지표 해석

예시: '빵을 구매한 고객이 우유도 함께 구매한다'는 규칙에서

지지도 = $(\text{빵} \cap \text{우유 거래 수}) / \text{전체 거래 수} \rightarrow$ 이 규칙이 얼마나 자주 나타나는가

신뢰도 = $(\text{빵} \cap \text{우유 거래 수}) / \text{빵 거래 수} \rightarrow$ 빵을 사면 우유도 살 확률

향상도 = $\text{신뢰도} / P(\text{우유}) \rightarrow$ 빵 구매가 우유 구매 확률을 얼마나 높이는가

■ 연관규칙 분석의 활용

대형마트 상품 배치 최적화 | 온라인 쇼핑몰 추천 시스템 | 교차 판매(Cross-selling) 전략 수립 | 고객 행동 패턴 분석 등 주로 마케팅 영역에서 활용된다.



15. 변수 유형별 분석 기법 선택

SELECTING METHODS BY VARIABLE TYPE

■ [표 2-1] 종속변수가 있는 경우 — 독립·종속변수 유형 조합별 기법

독립변수(X) \ 종속변수(Y)	연속형 (Y)	범주형 (Y)
연속형 (X)	회귀분석, 인공신경망 모델	로지스틱 회귀분석, 판별분석, K-최근접 이웃기법
범주형 (X)	회귀분석, KNN, 인공신경망, 회귀나무	인공신경망, 분류나무, 로지스틱 회귀분석

■ [표 2-2] 종속변수가 없는 경우 — 독립변수 유형별 기법


독립변수(X) 유형	적용 기법
연속형 변수	주성분 분석, 군집분석, 상관분석
범주형 변수	연관성 규칙, 판별 분석

실무 포인트: 변수 유형 확인 → 종속변수 유무 확인 → 분석 목적 대조 → 기법 선택

■ 시계열 분석 & ARIMA 예측 결과

TIME SERIES & ARIMA - AIRPASSENGERS FORECAST

CODE 6 / SECTION 3



■ 핵심 결과 (Key Results)

- 데이터: AirPassengers (1949~1960)
- 관측 기간: 144개월 (12년)
- 전처리: log + 1차 차분
- ADF 통계량: -9.6313
- ADF p-value: 0.000000
- 모델: ARIMA(1,0,1)(0,1,1,12)
- 예측 기간: 120개월 (10년)
- 마지막 예측값: 870.4명



■ 결과 해석 (Interpretation)

- ADF 검정 p-value(0.0000) < 0.05 이므로 차분 후 시계열은 안정성(stationary) 조건을 만족한다.
- 원 시계열은 명확한 상승 추세 + 12개월 주기 계절성을 보여, 계절성 차분(D=1, m=12)을 추가하였다.
- ARIMA(1,0,1)(0,1,1,12) 모델로 향후 10년간 지속적 증가 추세 + 계절 변동을 예측한다.
- 시계열 분석은 시간 의존성이 핵심이므로 일반 회귀가 아닌 ARIMA 등 시계열 전용 모델이 필요하다.

K-Means 군집화 실행 결과

K-MEANS CLUSTERING - OPTIMAL K SELECTION

CODE 7 / SECTION 3



핵심 결과 (Key Results)

- 데이터: iris (150 obs × 4 vars)
- K=2 평균 실루엣: 0.6810
- K=3 평균 실루엣: 0.5528
- 실루엣 기준 최적 K: 2 (sil 최대)
- K=2 군집 크기: [53, 97]
- K=3 군집 크기: [62, 50, 38]
- K=3 between/total: 88.43%

결과 해석 (Interpretation)

- 실루엣값 기준 $K=2(0.681) > K=3(0.553)$ 로 통계적 최적 K는 2이다.
- 그러나 실제 iris 품종이 3종(setosa/versicolor/virginica)임을 고려해 K=3 군집화도 함께 수행하였다.
- K=3에서 $\text{between_SS}/\text{total_SS} = 88.4\%$ 로 88% 이상의 분산을 군집 간 변동으로 설명한다.
- 비지도학습이라 정답 라벨 없이도 데이터 구조에서 자연스러운 군집 경계가 드러남을 확인했다.

SECTION 4

- ENSEMBLE
- DERIVED VARIABLES
- VISUALIZATION

앙상블·파생변수·시각화

파생변수 생성, 배깅·부스팅·랜덤포레스트,
데이터 시각화 활용

04



16. 파생변수 생성 방법

DERIVED VARIABLE GENERATION

■ 파생변수 (Derived Variable) 정의

기존 변수에 특정 조건·함수를 적용해 새롭게 재정의한 변수

기존 데이터 이외에 분석모델에 필요한 변수를 생성·추가하여 활용하는 것이 목적

방법	설명	예시
① 단위 변환	단위·척도 변환	km → m, 달러 → 원, 파운드 → kg
② 표현형식 변환	형식 변환	날짜 → 요일, 성별 → 0/1 이진변수
③ 요약통계량 변환	집계 통계 생성	고객별 누적방문횟수, 월평균 구매액
④ 변수 결합	수학적 결합	매출액 ÷ 방문횟수 = 1회 평균매출액

■ 활용 이점

모델 설명력 향상 | 기존 변수로 표현하기 어려운 패턴과 인사이트 발굴 가능

예) 연령을 '나잇대별 이진 변수'로 변환 시 연령대 특성을 더 명확히 모델에 반영



17. 배깅 & 부스팅

BAGGING & BOOSTING

■ 앙상블 기법의 필요성

단일 알고리즘보다 여러 알고리즘을 결합하면 성능이 향상되는 경우 多
 분석모델 오류 = 편향(Bias) + 분산(Variance) — 두 오류는 트레이드오프 관계

모델 유형	편향(Bias)	분산(Variance)	대표 예시
고편향·저분산	크다 (부정확)	작다 (안정적)	로지스틱 회귀, KNN(K 클 때)
저편향·고분산	작다 (정확)	크다 (불안정)	인공신경망, SVM

■ 배깅 (Bagging = Bootstrap Aggregating) → 분산 감소 효과

복원추출(부트스트랩)로 여러 샘플 생성 → 각각 독립적으로 모델 학습 → 결과 결합 (분류: 다수결, 예측: 평균)
 고분산 모델(인공신경망, SVM 등)에 특히 효과적

■ 부스팅 (Boosting) → 편향 감소 효과

이전 모델이 틀린 데이터에 가중치 부여 → 순차적 학습으로 오류 집중 교정
 고편향 모델(로지스틱 회귀, KNN 등)에 특히 효과적



18. 랜덤 포레스트 & 데이터 시각화

RANDOM FOREST & DATA VISUALIZATION

■ 랜덤 포레스트 (Random Forest) — 분산 감소 앙상블

여러 의사결정트리를 임의로 학습하는 앙상블 방법 | 속도 빠르고 분류+회귀 모두 우수

무작위성 요소	내용
① 데이터 샘플링	복원추출로 부트스트랩 샘플 사용 (전체 데이터 미사용)
② 변수 분기	분기 시 전체 변수가 아닌 일부 변수에 대해서만 분기 시도

최종 결과: 분류 → 다수결(Majority Vote) | 예측 → 평균(Average)

■ 데이터 시각화 (Data Visualization)

빅데이터 분석 전 과정에서 활용 — 탐색(EDA) / 모델링 중 / 결과 보고

역할: 분석 결과를 쉽게 이해하고 의사결정자에게 주요 아이디어를 효과적으로 전달

■ 주요 시각화 유형


히스토그램 — 변수 분포 파악 | 박스플롯 — 이상치·분포 비교 | 산점도 — 변수 간 관계

시계열 플롯 — 추세·계절성 파악 | 상관행렬 플롯 — 다변수 상관 | biplot — PCA 결과 시각화

파생변수 생성 실행 결과

DERIVED VARIABLE GENERATION - AGE BINS

CODE 8 / SECTION 4



Derived: Age Group Binary Variables

	age20s	age30s	age40s	age50s
c01	1	0	0	0
c02	0	0	1	0
c03	0	1	0	0
c04	0	1	0	0
c05	0	0	1	0
c06	0	0	0	1
c07	1	0	0	0

핵심 결과 (Key Results)

- 원본 데이터: 고객 7명 (id, age)
- 원본 변수 개수: 2개
- 파생 후 변수 개수: 6개 (+4)
- 생성 방법: 연령 구간별 이진(0/1)
- age20s 조건: $20 \leq \text{age} < 30$
- age30s 조건: $30 \leq \text{age} < 40$
- age40s 조건: $40 \leq \text{age} < 50$
- age50s 조건: $50 < \text{age} < 60$


결과 해석 (Interpretation)

- 연속형 변수(age)를 4개의 이진 더미 변수(age20s~age50s)로 변환하는 형식 변환 기법을 적용했다.
- 연령대별 비선형 효과를 모델이 직접 학습할 수 있게 되어, 회귀모델·분류모델의 설명력이 향상된다.
- 단, age50s 조건이 'age > 50'(50 미포함)이라 50세 고객은 어떤 그룹에도 속하지 않는 미세한 누락 발생.
- 실무에서 파생변수는 도메인 지식 + 데이터 패턴 분석을 결합해 설계하는 것이 효과적이다.

■ 앙상블 - Bagging 실행 결과

BAGGING (BOOTSTRAP AGGREGATING) - VARIANCE REDUCTION

CODE 9 / SECTION 4



■ 핵심 결과 (Key Results)

- 기본 분류기: Decision Tree (max_depth=1)
- 트리 개수: 10 (n_estimators)
- 샘플링 방식: Bootstrap (복원추출)
- 훈련 샘플: 75개 (각 클래스 25)
- 테스트 샘플: 75개
- 정확도 (Accuracy): 0.9067
- 오류율 (Error Rate): 0.0933



■ 결과 해석 (Interpretation)

- Bagging 정확도 90.67% 로 단일 stump 대비 안정적 예측 성능을 달성하였다.
- 복원추출로 만든 다양한 부트스트랩 샘플에서 독립 학습 → 다수결 통합 방식으로 분산을 감소시켰다.
- Feature importance에서 petal length/width가 가장 큰 영향을 보이며, 이는 PCA 결과와도 일치한다.
- 고분산 모델(인공신경망, SVM)에 특히 효과적이며, max_depth=1 stump도 결합 시 강력한 모델이 된다.

앙상블 - Boosting (AdaBoost) 실행 결과

BOOSTING (ADABOOST) - BIAS REDUCTION

CODE 10 / SECTION 4



핵심 결과 (Key Results)

- 알고리즘: AdaBoost (SAMME)
- 기본 분류기: Decision Tree (max_depth=1)
- 트리 개수: 10 (n_estimators)
- 학습 방식: 순차적 가중치 부여
- Boosting 정확도: 0.8933
- Bagging 정확도 (비교): 0.9067
- Boosting 오류율: 0.1067


결과 해석 (Interpretation)

- Boosting 정확도 89.33%, Bagging 90.67% 으로 현재 데이터에서는 비슷한 성능을 보였다.
- 이전 모델이 틀린 샘플에 가중치를 부여해 순차 학습하므로, 편향(bias) 감소에 효과적이다.
- Feature importance가 petal 변수에 집중되어, 분류에 결정적인 변수를 자동으로 식별함을 확인했다.
- 고편향 모델(로지스틱 회귀, KNN)에 특히 효과적이며, 노이즈 데이터에는 과적합 위험이 있어 주의가 필요하다.

■ 앙상블 - Random Forest 실행 결과

RANDOM FOREST - BAGGING + RANDOM FEATURE SELECTION

CODE 11 / SECTION 4



■ 핵심 결과 (Key Results)

- 트리 개수 ($n_{\text{estimators}}$): 100
- 분기 시 변수 선택: $\text{sqrt}(p) = 2$ 개
- 훈련 샘플: 105개
- 테스트 샘플: 45개
- OOB 정확도: 0.9333
- OOB 오류율: 0.0667
- 테스트 정확도: 0.9778

■ 결과 해석 (Interpretation)

- OOB(Out-of-Bag) 정확도 93.33%, 테스트 정확도 97.78% 로 매우 우수한 성능이다.
- Bootstrap 샘플링 + 분기 시 일부 변수만 사용하는 이중 무작위성으로 트리 간 상관성을 줄여 분산을 감소시킨다.
- OOB 추정은 별도 검증셋 없이 학습 중 검증이 가능해 데이터 효율성이 높다.
- Feature importance에서 petal length/width가 압도적이며, sepal 변수의 기여도는 상대적으로 낮다.

SECTION 5

· MODEL EVALUATION & VALIDATION

빅데이터 모델 평가·검증

데이터셋 분할, 과적합, 교차검증,
예측·분류·군집모델 성능평가 지표

05



19. 훈련·평가·검증 데이터 세트

TRAIN · EVAL · TEST DATASETS

■ 데이터 분할의 필요성

모델 평가의 객관성 확보 — 좋은 샘플 선택이 모델 성능에 큰 영향을 미침

분할 방법: 미리 정해진 비율로 무작위(random) 분할

■ 2분할 vs 3분할 비교

구성	분할	특징
2분할	훈련 + 검증	간단, 데이터 수가 적을 때 활용
3분할 (권장)	훈련 + 평가 + 검증	모델 선택·튜닝이 가능하여 권장

■ 각 데이터셋의 역할

데이터셋	역할
훈련 (Training)	모델 파라미터 학습에 사용 — 가장 많은 비중
평가 (Evaluation)	모델 선택 및 하이퍼파라미터 튜닝
검증 (Test)	최종 성능 측정 — 반드시 한 번만 사용



20. 과적합 (Overfitting)

OVERFITTING

■ 과적합 (Overfitting) 정의

제한된 훈련 데이터 세트에 너무 과하게 특화되어, 새로운 데이터에 대한 오차가 매우 커지는 현상을 말한다. 훈련 데이터에 존재하는 노이즈나 우연한 패턴까지 학습하여, 모델이 훈련 데이터에서는 오차가 거의 없지만 실제 데이터에서는 예측 성능이 크게 떨어진다.

■ 적합 수준 비교 (PDF 그림 3-1 기반)

(b) 과소적합(Underfitting): 단순히 직선으로 추정하는 경우로, 훈련 데이터뿐 아니라 실제 데이터에서도 오차가 크다. 모델이 너무 단순하여 데이터의 특성을 충분히 반영하지 못한다.

(c) 적절한 적합: 약간의 오차가 존재하지만 훈련 데이터의 특성을 잘 나타내며, 새로운 데이터에 대해서도 좋은 결과가 나올 가능성이 높다. 이상적인 상태이다.

(d) 과적합(Overfitting): 예측모델이 훈련 데이터의 모든 데이터를 오차 없이 추정하지만, 새로운 데이터에서는 오차가 매우 커질 확률이 높다.

■ 과적합의 불가피성

훈련 데이터셋은 실제 데이터의 부분집합에 불과하므로, 훈련셋만으로는 실제 데이터에서의 오차 증가 지점을 정확히 예측하기 어렵다. 이 문제를 해결하기 위해 교차 유효성 검사(Cross Validation)를 활용한다.



■ 과적합이 발생하는 근본 원인

모든 분석모델은 훈련 데이터셋을 기반으로 구축된다. 그런데 훈련 데이터셋은 실제 전체 데이터의 일부분(부분집합)에 불과하므로, 훈련셋에 존재하는 노이즈나 우연한 패턴까지 모델이 학습하게 된다. 결국 훈련 데이터에 과도하게 특화된 모델은 새로운 데이터에 대해 일반화 성능이 떨어진다.

■ 과적합 감지 방법

훈련 오차와 검증 오차를 동시에 추적하여, 훈련 오차는 계속 감소하는데 검증 오차가 증가하기 시작하는 지점이 과적합이 시작되는 시점이다.

■ 과적합 완화를 위한 접근법

- ① 교차 유효성 검사(k-fold CV): 데이터를 k등분하여 훈련과 검증을 순환하므로 모든 데이터를 활용하면서도 과적합을 감지할 수 있다. (→ 다음 슬라이드 참조)
- ② 가지치기(Pruning): 의사결정트리에서 불필요한 가지를 제거하여 모델 복잡도를 낮춘다.
- ③ 앙상블 기법: 배깅·랜덤포레스트는 분산을 줄여 과적합 위험을 완화한다.
- ④ 충분한 데이터 확보: 데이터 양이 많을수록 모델이 노이즈를 일반적 패턴으로 혼동할 가능성이 줄어든다.



21. 교차 유효성 검사

CROSS VALIDATION

■ 교차 유효성 검사가 필요한 이유

보유 데이터의 크기가 작을 때, 훈련/검증 데이터를 한 번만 분할하면 검증 결과가 특정 분할에 의존하여 불안정해진다. 교차검증은 동일한 데이터를 여러 번 다르게 분할하여 모든 데이터를 훈련과 검증에 모두 활용함으로써, 모델 성능의 신뢰성 있는 추정치를 얻는 방법이다.

■ K-겹 교차검증 (K-fold Cross Validation) 절차

- ① 전체 데이터를 k 등분한다.
- ② k 번 반복: 매번 $k-1$ 개 묶음을 훈련셋으로, 나머지 1개 묶음을 검증셋으로 사용한다.
- ③ k 번의 예측 오차(또는 분류오류율)의 평균을 최종 성능 지표로 사용한다.

반복	훈련셋	검증셋
1회차	셋 2 + 셋 3	셋 1
2회차	셋 1 + 셋 3	셋 2
3회차	셋 1 + 셋 2	셋 3

k 번의 예측 오차 평균을 최종 성능으로 사용 | 분류 모델에도 동일하게 적용 가능 (예측오차 → 분류오류율)



22. 예측모델 성능평가 지표

PREDICTION MODEL EVALUATION METRICS

■ 평가 방법 개요

훈련셋으로 모델 구축 → 검증셋(실제값 y_i)과 예측값 비교 → 예측오차 산출

지표	정식 명칭	수식 개요	특징
MAE	평균절대 오차 (Mean Absolute Error)	절대오차 평균	이상치 덜 민감, 계산 쉽고 직관적
MSE	평균제곱 오차 (Mean Squared Error)	제곱오차 평균	큰 오차를 더 크게 반영
RMS	표준 오차 (Root Mean Square error)	MSE의 제곱근	MSE 수치 보정, 원래 단위 해석 가능
MAPE	평균 절대 백분 오차 비율 (MAPE)	실제값 대비 오차 비율 평균	상대적 오차 비율, 크기 다른 데이터 비교

■ 사용 기준

이상치 민감도 / 단위 해석 필요 여부 / 데이터 크기 비교 여부에 따라 선택
실무에서는 MAE와 RMS를 함께 확인하여 이상치 영향도를 파악하는 경우가 많음



23. 분류모델 성능평가: 혼동행렬

CLASSIFICATION EVAL: CONFUSION MATRIX

	예측: 참(Positive)	예측: 거짓(Negative)
실제: 참 (Positive)	TP 진양성 (True Positive)	FN 위음성 (False Negative)
실제: 거짓 (Negative)	FP 위양성 (False Positive)	TN 진음성 (True Negative)

지표	수식	의미
오류율 (Error Rate)	$(FP+FN) / \text{전체}$	잘못 분류된 비율
정확도 (Accuracy)	$(TP+TN) / \text{전체}$	올바르게 분류된 비율
민감도 (Sensitivity)	$TP / (TP+FN)$	실제 참을 참으로 판정한 비율
특이도 (Specificity)	$TN / (TN+FP)$	실제 거짓을 거짓으로 판정한 비율

예시: 10,000개 데이터 → 오류율 0.028 / 정확도 0.9725 / 민감도 0.9746



24. 분류모델 성능평가: ROC 곡선

CLASSIFICATION EVAL: ROC CURVE

■ ROC 곡선 (Receiver Operating Characteristic)

분류모델에서 민감도와 특이도는 서로 트레이드오프 관계에 있다. 분류 기준값(threshold)을 엄격하게 하면 특이도는 높아지지만 민감도가 낮아지고, 느슨하게 하면 반대가 된다. ROC 곡선은 이 기준값을 연속적으로 변경하며 민감도(y축)와 1-특이도(x축)의 관계를 그린 그래프이다.

■ ROC 곡선 해석

북서쪽 코너에 가까울수록 분류 성능이 우수하다. 이는 민감도가 높으면서 동시에 위양성률(1-특이도)이 낮은, 즉 두 가지 모두 좋은 상태를 의미한다.

45도 대각선은 무작위 분류 수준(동전 던지기)을 의미하며, ROC 곡선이 이에 가까울수록 모델이 무용하다.

■ AUC (Area Under the Curve) — 정량적 성능 척도

ROC 곡선 아래 면적을 계산한 값으로, 모델의 전반적인 분류 성능을 하나의 숫자로 요약한다.

AUC = 1.0: 완벽한 분류 | AUC $\approx$ 0.5: 무작위 수준 | AUC = 0.834: 우수한 분류 (ROCR 예시)

■ 실무 활용

문제 상황에 따라 민감도와 특이도 중 어느 쪽을 우선시할지 결정하는 데 ROC 곡선이 도움을 준다. 예를 들어 암 진단에서는 놓치는 환자를 줄이기 위해 민감도를 최우선하고, 스팸 메일 필터에서는 정상 메일을 잘못 차단하지 않기 위해 특이도를 우선한다.



■ 군집 평가의 어려움

정답 종속변수(라벨)가 없어 객관적 성능 평가가 어려움
 공통 원칙: 군집 내 밀도↑ & 군집 간 거리↑ = 좋은 군집해

■ 내부 평가 — 외부 정보 불필요, 군집해 자체로만 평가

지표	계산 원리	해석
던 지수 (Dunn Index)	군집 간 거리 / 군집 내 최대거리	클수록 우수
CH 지수 (Calinski-Harabasz)	군집 간 분산 / 군집 내 분산 비율	클수록 우수

■ 외부 평가 — 기존에 알려진 군집 해와 비교


지표	계산 원리
랜드 지수 (Rand Index)	두 군집 해에서 일치하는 데이터 쌍의 비율
자카드 지수 (Jaccard Index)	공통 포함 쌍 / 적어도 한쪽 포함 쌍

실무 권장: 가능하다면 내부평가 + 외부평가를 모두 적용하여 종합 판단

■ 예측모델 평가 - ARIMA 오차 지표

PREDICTION EVALUATION - MAE / MSE / RMS / MAPE

CODE 12 / SECTION 5



■ 핵심 결과 (Key Results)

- 모델: ARIMA(4,1,4)
- 훈련 데이터: 293개
- 테스트 데이터: 25개
- MAE (평균절대오차): 0.146120
- MSE (평균제곱오차): 0.038011
- RMS (표준오차): 0.194964
- MAPE (평균절대백분오차): 1.6878 %



■ 결과 해석 (Interpretation)

- MAE=0.1461, RMS=0.1950 로 두 지표가 비슷해 큰 이상치 (outlier)는 거의 없다고 판단된다.
- MSE는 큰 오차에 더 큰 패널티를 주므로, MAE와 RMS를 함께 보면 오차 분포 특성을 파악할 수 있다.
- MAPE=1.69% 는 실제값 대비 상대 오차로, 단위가 다른 데이터 간 비교에 유용한 지표이다.
- 4개 지표를 종합하여 모델의 정확도와 안정성을 다각도로 평가하는 것이 권장된다.

K-fold 교차검증 (K=5) 실행 결과

5-FOLD CROSS VALIDATION - REGRESSION MODEL

CODE 13 / SECTION 5



핵심 결과 (Key Results)

- 모델: Random Forest Regressor
- Fold 개수 (K): 5
- 타겟 변수: Sepal Length (cm)
- Fold별 MAE 평균: 0.2742
- Fold별 MAE 표준편차: 0.0452
- 전체 MSE: 0.1247
- 전체 MAPE: 4.75 %

결과 해석 (Interpretation)


- 평균 MAE=0.274, MAPE=4.75% 로 sepal length 예측이 비교적 정확하게 수행되었다.
- 각 Fold에서 모든 데이터가 한 번씩 검증셋이 되므로, 단일 분할 대비 성능 추정의 신뢰성이 높다.
- Fold 간 MAE 분산이 작을수록 모델 안정성이 높음을 의미하며, 이상 패턴 감지에도 활용 가능하다.
- 데이터가 부족할 때 K-fold CV는 모든 데이터를 훈련+검증에 활용해 데이터 효율성을 극대화한다.

■ 분류모델 평가 - 혼동행렬 & ROC/AUC


CLASSIFICATION EVALUATION - CONFUSION MATRIX & ROC

CODE 14 / SECTION 5

Confusion Matrix
Acc=1.0000, Sens=1.0000, Spec=1.0000



ROC Curve



■ 핵심 결과 (Key Results)

- 이진 분류: setosa(1) vs others(0)
- TP (진양성): 15
- TN (진음성): 30
- FP (위양성): 0
- FN (위음성): 0
- 정확도 / 오류율: 1.0000 / 0.0000
- 민감도 / 특이도: 1.0000 / 1.0000
- AUC: 1.0000


■ 결과 해석 (Interpretation)

- AUC=1.0000 로 ROC 곡선 아래 면적이 1.0에 가까워 완벽한 분류 성능을 보인다.
- 민감도(=재현율)와 특이도가 모두 높은 이상적 분류기로, 오분류가 전혀 없다.
- setosa 품종이 다른 두 품종과 변수 공간에서 명확히 분리되기 때문에 쉬운 분류 문제이기도 하다.
- 실무에서는 도메인에 따라 민감도(암 진단) 또는 특이도(스팸 필터) 중 우선순위를 결정해 임계값을 조정한다.

■ 군집모델 평가 - 던 지수 & 외부평가

CLUSTERING EVALUATION - INTERNAL & EXTERNAL METRICS

CODE 15 / SECTION 5



■ 핵심 결과 (Key Results)

- 모델: K-Means (K=3, scaled)
- 테스트 샘플: 45개
- Dunn Index (↑ 좋음): 0.1294
- Davies-Bouldin (↓ 좋음): 0.8237
- Calinski-Harabasz (↑ 좋음): 66.60
- Rand Index (외부): 0.8222
- Jaccard Index (외부): 0.0617

■ 결과 해석 (Interpretation)

- 내부평가: Dunn=0.129, DB=0.824 로 군집 간 분리는 양호하나 일부 군집의 밀집도는 개선 여지가 있다.
- 외부평가: Rand Index=0.822 로 실제 품종 라벨과 군집 결과가 약 82% 일치한다.
- Jaccard Index(0.062)가 낮은 것은 클러스터 라벨 번호가 실제 클래스와 무관하게 부여되기 때문이다.
- 군집 평가는 정답 라벨이 없는 경우가 많아 내부+외부 지표를 종합 판단하는 것이 권장된다.

SECTION 6

· BIG DATA MODEL OPERATIONS

빅데이터 모델 운영방안

모델 개발·운영 6단계 프로세스,
운영시스템 적용·성능 추적·개선방안

06



26. 빅데이터 모델 개발·운영 프로세스

BIG DATA MODEL DEV & OPS PROCESS

■ 빅데이터 모델 개발 및 운영 단계 (6단계)

단계	명칭	핵심 활동
1	분석 목적 정의	문제 정의, 빅데이터 모델 적용 가능성 판단
2	가설 검토	가설 수립, 통계적으로 유의미한 결론 도출 방향 설정
3	데이터 준비 및 처리	수집·저장, 변수 정의·일관성 점검, 결측치 처리, 파생변수 생성, 훈련/평가/검증 데이터셋 분할
4	모델링 및 분석	분석 유형 및 모델 선택, 훈련 데이터로 모델 도출
5	정확도 및 성능 평가	검증 데이터로 분석모델 성능 측정
6	운영	운영시스템과 통합, 분석목적에 맞게 분석모델 활용

각 단계는 선형 진행뿐 아니라 피드백 루프 형태로 반복될 수 있음 — 특히 3·4·5단계는 순환적



27. 모델 운영시스템 적용 방안

MODEL DEPLOYMENT STRATEGY

■ 운영시스템 통합의 필요성

수집 데이터로 도출된 분석모델을 실제 비즈니스 의사결정에 연결하기 위해 운영시스템과의 통합이 필요

■ 통합 케이스 2가지

케이스	조건	통합 난이도
Case A	운영시스템 개발언어 = 분석 언어 (Python, Java 등)	낮음 — 직접 통합 가능
Case B	통계 패키지 (R, SAS 등) 사용	높음 — 인터페이스 개발 필요

■ 결과 전달 3가지 방식

전달 방식	설명
① 직접 호출	인터페이스를 통해 분석 모듈 구동 → 결과값 직접 수신
② 파일 전달	CSV 등 파일 형태로 간접 전달
③ DBMS 경유	데이터베이스를 통한 간접 전달

핵심: 모델 개발 초기부터 운영시스템 통합 방안을 명확히 수립할 것



28. 모델 성능 추적 (추적 신호)

MODEL PERFORMANCE TRACKING SIGNAL

■ 운영 후 지속 모니터링의 필요성

처음에는 성능이 좋은 모델이라도 시간 경과에 따라 제반 상황이 변하면 성능이 저하됨
→ 지속적인 성능 추적(모니터링)이 필수적으로 요구됨

■ 추적 신호 (Tracking Signal, TS)

정의: $TS = \text{예측 오차들의 합} / \text{평균절대편차(MAD)}$

정상 범위: $-4 \leq TS \leq 4$ (0 부근이 이상적)

범위 이탈 시: 예측모델 점검 필요 신호로 해석

■ 관리도 (Control Chart) 활용

상한 (UCL) = +4 / 하한 (LCL) = -4

TS가 관리 한계를 벗어나면 즉시 점검 트리거 발동

■ 추적 신호 해석

$TS > 0$: 예측값이 지속적으로 실제값보다 낮게 나옴 (과소 추정)

$TS < 0$: 예측값이 지속적으로 실제값보다 높게 나옴 (과대 추정)



29. 모델 개선 방안

MODEL IMPROVEMENT STRATEGY

■ 개선 필요 조건

추적 신호(TS)가 ± 4 한계를 초과하여 모델 성능 저하가 확인된 경우

개선 방안	내용	적합한 상황
① 동일 모델 재학습	최신 데이터 업데이트 후 동일 알고리즘 재적용	데이터 변화가 성능 저하의 원인인 경우
② 모델 교체	다른 알고리즘 후보 비교 평가 → 최적 모델로 교체	알고리즘 자체가 분석 목적에 부적합한 경우

■ 운영 원칙

시스템 운영에 지장이 없도록 단계적으로 개선 진행

■ 모델 생명주기 (Model Life Cycle)

개발 → 검증 → 운영 → 점검 → 개선 → (반복)

전개된 모델의 생명주기(life cycle)를 이해하고 운영 주기·정밀도 등의 평가 기준에 따라 개선방안 수립



30. 핵심 개념 종합 정리

KEY CONCEPTS SUMMARY

단원	핵심 키워드
학습 1: 가설 설정	귀무·대립가설 / 양측·단측검정 / 제1·2종 오류 / 검정력 / 유의수준 / 신뢰수준 / p-값 / Z-t- χ^2 -F 통계량
학습 2: 모델 개발	기술통계·상관분석·회귀분석·ANOVA·PCA·판별분석 / 분류·예측·군집·연관 / ARIMA / 파생변수 / 배경·부스팅·랜덤포레스트
학습 3: 모델 평가	훈련·평가·검증 데이터셋 / 과적합 / K-fold CV / MAE·MSE·RMS·MAPE / 혼동행렬·민감도·특이도 / ROC-AUC / 던지수·CH지수·랜즈지수
학습 4: 모델 운영	6단계 운영 프로세스 / 운영시스템 통합 / 인터페이스 개발 / 추적 신호(TS) / 관리도 / 모델 생명주기
분석 목적	대표 기법
예측 (Prediction)	회귀분석, 의사결정트리, 인공신경망, ARIMA
분류 (Classification)	로지스틱 회귀, CART(의사결정트리), SVM, 인공신경망
군집 (Clustering)	K-평균 군집화, 계층적 군집화
연관 (Association Rule)	연관규칙 분석 (장바구니 분석)



■ 코드 작성

- 에러 발생 시 디버깅
- 섹션별 깔끔하게 취합 및 정리
- R -> python 변환
- 이해되지 않는 내용 확인

■ PPT 작성

- 코드 결과값(차트) 내용 분석 도움
- 최종 내용 검토



감사합니다

서강대학교 AI.SW 대학원
소프트웨어 및 시스템공학과