

대분류 / 20
정보통신

중분류 / 01
정보기술

소분류 / 01
정보기술전략·계획

세분류 / 05
빅데이터분석
(구.빅데이터기획·분석)

학습모듈 / 06

06

통계 기반 데이터 분석

LM2001010506_15v1

빅데이터분석(구.빅데이터기획·분석) 학습모듈

01. 빅데이터 분석 기획




02. 빅데이터 수집



03. 빅데이터 저장



04. 빅데이터 처리



05. 분석용 데이터 탐색



06. 통계 기반 데이터 분석




07. 머신러닝 기반 데이터 분석



08. 텍스트 마이닝 기반 데이터 분석



09. 빅데이터 분석 결과 시각화




NCS 학습모듈의 이해

※ 본 학습모듈은 「NCS 국가직무능력표준」 사이트(<http://www.ncs.go.kr>) 에서 확인 및 다운로드 할 수 있습니다.

(1) NCS 학습모듈이란?

- 국가직무능력표준(NCS: National Competency Standards)이란 산업현장에서 직무를 수행하기 위해 요구되는 지식·기술·소양 등의 내용을 국가가 산업부문별·수준별로 체계화한 것으로 산업현장의 직무를 성공적으로 수행하기 위해 필요한 능력(지식, 기술, 태도)을 국가적 차원에서 표준화한 것을 의미합니다.
- 국가직무능력표준(이하 NCS)이 현장의 ‘직무 요구서’라고 한다면, NCS 학습모듈은 NCS의 능력단위를 교육훈련에서 학습할 수 있도록 구성한 ‘교수·학습 자료’입니다. NCS 학습모듈은 구체적인 직무를 학습할 수 있도록 이론 및 실습과 관련된 내용을 상세하게 제시하고 있습니다.




- NCS 학습모듈은 다음과 같은 특징을 가지고 있습니다.

첫째, NCS 학습모듈은 산업계에서 요구하는 직무능력을 교육훈련 현장에 활용할 수 있도록 성취목표와 학습의 방향을 명확히 제시하는 가이드라인의 역할을 합니다.

둘째, NCS 학습모듈은 특성화고, 마이스터고, 전문대학, 4년제 대학교의 교육기관 및 훈련기관, 직장교육기관 등에서 표준교재로 활용할 수 있으며 교육과정 개편 시에도 유용하게 참고할 수 있습니다.

- NCS와 NCS 학습모듈 간의 연결 체제를 살펴보면 아래 그림과 같습니다.



(2) NCS 학습모듈의 체계

- NCS 학습모듈은 1.학습모듈의 위치, 2.학습모듈의 개요, 3.학습모듈의 내용 체계, 4.참고 자료, 5.활용 서식/부록 으로 구성되어 있습니다.

1. NCS 학습모듈의 위치

- NCS 학습모듈의 위치는 NCS 분류 체계에서 해당 학습모듈이 어디에 위치하는지를 한 눈에 볼 수 있도록 그림으로 제시한 것입니다.

예시 : 이·미용 서비스 분야 중 네일미용 세분류

NCS-학습모듈의 위치

대분류	이용·숙박·여행·오락·스포츠
중분류	이·미용
소분류	아·미용 서비스

세분류	능력단위	학습모듈명
헤어미용	네일 샵 위생 서비스	네일샵 위생서비스
피부미용	네일 화장물 제거	네일 화장물 제거
메이크업	네일 기본 관리	네일 기본관리
네일미용	네일 랩	네일 랩
이용	네일 팁	네일 팁
	젤 네일	젤 네일
	아크릴릭 네일	아크릴 네일
	평면 네일아트	평면 네일아트
	융합 네일아트	융합 네일아트
	네일 샵 운영관리	네일샵 운영관리

학습모듈은

NCS 능력단위 1개당 1개의 학습모듈 개발을 원칙으로 합니다. 그러나 필요에 따라 고용 단위 및 교과단위를 고려하여 능력단위 몇 개를 묶어서 1개의 학습모듈로 개발할 수 있으며, NCS 능력단위 1개를 여러 개의 학습모듈로 나누어 개발할 수도 있습니다.

2. NCS 학습모듈의 개요

구 성

- NCS 학습모듈 개요는 학습모듈이 포함하고 있는 내용을 개략적으로 설명한 것으로서 **학습모듈의 목표**, **선수 학습**, **학습모듈의 내용 체계**, **핵심 용어**로 구성되어 있습니다.

학습모듈의 목표	해당 NCS 능력단위의 정의를 토대로 학습목표를 작성한 것입니다.
선수 학습	해당 학습모듈에 대한 효과적인 교수·학습을 위하여 사전에 이수해야 하는 학습모듈, 학습 내용, 관련 교과목 등을 기술한 것입니다.
학습모듈의 내용 체계	해당 NCS 능력단위요소가 학습모듈에서 구조화된 방식을 제시한 것입니다.
핵심 용어	해당 학습모듈의 학습 내용, 수행 내용, 설비·기자재 등 가운데 핵심적인 용어를 제시한 것입니다.

활 용 안 내

예시 : 네일미용 세분류의 ‘네일 기본관리’ 학습모듈

네일 기본관리 학습모듈의 개요

학습모듈의 목표

고객의 네일 보호와 미적 요구 충족을 위하여 효과적인 네일 관리로 프리에지 형태 만들기, 큐티를 정리하기, 컬러링하기, 보습제 도포하기, 마무리를 할 수 있다.

선수학습

네일숍 위생서비스(LM1201010401_14v2)

학습모듈의 내용체계

학습	학습 내용	NCS 능력단위 요소	
		코드번호	요소 명칭
1. 프리에지 형태 만들기	1-1. 네일 파일에 대한 이해와 활용	1201010403_12v2.1	프리엣지 모양 만들기
	1-2. 프리에지 형태 파일링		
2. 큐티를 정리하기	2-1. 네일 기본관리 매뉴얼 이해	1201010403_14v2.2	큐티를 정리하기
	2-2. 큐티를 관리		
3. 컬러링하기	3-1. 컬러링 매뉴얼 이해	1201010403_14v2.3	컬러링
	3-2. 컬러링 방법 선정과 작업		
	3-3. 쉘 컬러링 작업		
4. 보습제 도포하기	4-1. 보습제 선정과 도포	1201010403_14v2.4	보습제 바르기
	4-2. 각질제거		
5. 네일 기본관리 마무리하기	5-1. 유분기 제거	1201010403_14v2.5	마무리하기
	5-2. 네일 기본관리 마무리와 정리		

핵심 용어

프리에지, 니퍼, 퓨셔, 폴리시, 네일 파일, 스퀘어형, 스퀘어 오프형, 라운드형, 오발형, 포인팅형

학습모듈의 목표는

학습자가 해당 학습모듈을 통해 성취해야 할 목표를 제시한 것으로, 교수자는 학습자가 학습모듈의 전체적인 내용흐름을 파악할 수 있도록 지도하는 것이 필요합니다.

선수 학습은

교수자나 학습자가 해당 모듈을 교수 또는 학습하기 이전에 이수해야 할 학습내용, 교과목, 핵심 단어 등을 표기한 것입니다. 따라서 교수자는 학습자가 개별 학습, 자기 주도 학습, 방과 후 활동 등 다양한 방법을 통해 이수할 수 있도록 지도하는 것이 필요합니다.

핵심 용어는

학습모듈을 통해 학습되고 평가되어야 할 주요 용어입니다. 또한 당해 모듈 또는 타 모듈에서도 핵심 용어를 사용하여 학습내용을 구성할 수 있으며, 「NCS 국가 직무능력표준」 사이트(www.ncs.go.kr)에서 색인(찾아보기) 중 하나로 이용할 수 있습니다.

3. NCS 학습모듈의 내용 체계

구 성

- NCS 학습모듈의 내용은 크게 **학습**, **학습 내용**, **교수·학습 방법**, **평가**로 구성되어 있습니다.

학습	해당 NCS 능력단위요소 명칭을 사용하여 제시한 것입니다. 학습은 크게 학습 내용, 교수·학습 방법, 평가로 구성되며 해당 NCS 능력단위의 능력단위 요소별 지식, 기술, 태도 등을 토대로 학습 내용을 제시한 것입니다.
학습 내용	학습 내용은 학습 목표, 필요 지식, 수행 내용으로 구성하였으며, 수행 내용은 재료·자료, 기기(장비·공구), 안전·유의 사항, 수행 순서, 수행 tip으로 구성한 것입니다. 학습모듈의 학습 내용은 업무의 표준화된 프로세스에 기반을 두고 실제 산업현장에서 이루어지는 업무활동을 다양한 방식으로 반영한 것입니다.
교수·학습 방법	학습 목표를 성취하기 위한 교수자와 학습자 간, 학습자와 학습자 간의 상호 작용이 활발하게 일어날 수 있도록 교수자의 활동 및 교수 전략, 학습자의 활동을 제시한 것입니다.
평가	평가는 해당 학습모듈의 학습 정도를 확인할 수 있는 평가 준거, 평가 방법, 평가 결과의 피드백 방법을 제시한 것입니다.

활 용 안 내

예시 : 네일미용 세분류의 ‘네일 기본관리’ 학습모듈의 내용

학습 1	프리에지 형태 만들기(LM1201010403_14v2.1)
학습 2	큐티클 정리하기(LM1201010403_14v2.2)
학습 3	컬러링하기(LM1201010403_14v2.3)
학습 4	보습제 도포하기(LM1201010403_14v2.4)
학습 5	네일 기본관리 마무리하기(LM1201010403_14v2.5)

학습은

해당 NCS 능력단위요소 명칭을 사용하여 제시하였습니다. 학습은 일반교과의 '대단원'에 해당되며, 모듈을 구성하는 가장 큰 단위가 됩니다. 또한 완성된 직무를 수행하기 위한 가장 기본적인 단위로 사용할 수 있습니다.

학습내용은

요소 별 수행준거를 기준으로 제시하였습니다. 일반교과의 '중단원'에 해당합니다.

학습목표는

모듈 내의 학습내용을 이수했을 때 학습자가 보여줄 수 있는 행동수준을 의미합니다. 따라서 일반 수업시간의 과목목표로 활용할 수 있습니다.

필요지식은

해당 NCS의 지식을 토대로 해당 학습에 대한 이해와 성과를 높이기 위해 알아야 할 주요 지식을 제시하였습니다. 필요지식은 수행에 꼭 필요한 핵심 내용을 위주로 제시하여 교수자의 역할이 매우 중요하며, 이후 수행순서 내용과 연계하여 교수·학습으로 진행할 수 있습니다.

학습목표

- 고객의 요구에 따라 네일 폴리시 색상의 침착을 막기 위한 베이스코트를 아주 얇게 도포할 수 있다.
- 작업 매뉴얼에 따라 네일 폴리시를 얼룩 없이 균일하게 도포할 수 있다.
- 작업 매뉴얼에 따라 네일 폴리시 도포 후 컬러 보호와 광택 부여를 위한 톱코트를 바를 수 있다.

필요 지식 /

□ 컬러링 매뉴얼

컬러링 작업 전, 이세톤 또는 네일 폴리시 리무버를 사용하여 손톱표면과 큐티클 주변, 손톱 밑 부분까지 깨끗하게 유분기를 제거해야 한다. 컬러링의 순서는 Base coating 1회 → Polishing 2회 → 컬러수정 → Top coating 1회 → 최종수정의 순서로 한다. 베이스코트는 착색을 방지하고 발림성 향상을 위해 가장 먼저 도포하며 컬러링의 마지막에 컬러의 유지와 광택을 위해 톱코트를 도포한다. 네일 보강제(Nail Strengthner)를 바를 시에는 베이스코트를 도포하기 전에 사용한다.

수행 내용 / 컬러링 매뉴얼 실습하기

재료·자료

- 컬러링 관련 네일 미용 자료들
- 정리바구니, 베이스코트, 네일 폴리시, 튜코트, 오렌지우드스틱, 탈지면, 폴리시리무버, 디스펜서 등

기기(장비·공구)

- 컴퓨터, 빔 프로젝터, 스크린 등

안전·유의사항

- 컬러링 재료들의 분체를 직접적으로 받지 않도록 유의한다.
- 컬러링 제품들이 대부분 유리병에 들어 있기 때문에 깨지지 않도록 각별히 조심한다.
- 컬러링 제품들은 상온에 마르기 때문에 개봉 후 뚜껑을 잘 닫도록 한다.

수행 순서

1) 네일 폴리시를 바르게 잡는다.

1. 손바닥에 네일 폴리시를 놓고 약지 소지를 이용하여 네일 폴리시를 잡는다.
2. 폴리시를 왼 손의 엄지와 검지로 고객의 작업손가락을 잡는다.
3. 폴리시를 왼 손의 중지 손가락을 굳게 펴서 받침대가 되도록 한다.
4. 반대편 손으로 네일 폴리시의 뚜껑을 열고 소지 손가락을 펴서 네일 폴리시를 왼 중지 손가락 위에 받쳐놓는다.
5. 다양한 형태의 폴리시를 잡아본다.

수행 tip

- 흰색이 많이 섞인 네일 폴리시의 경우는 붓의 각도를 높이 세워 빠르게 브러시 작업을 해야 붓 자국이 나지 않는다.
- 컬러링은 기본 2회 정도이나 컬러에 따른 도포량과 컬러감에 따라 1~3회 사이로 증감할 수 있다.

수행 내용은

모듈에 제시한 것 중 기술(Skill)을 습득하기 위한 실습 과제로 활용할 수 있습니다.

재료·자료는

수행 내용을 수행하는데 필요한 재료 및 준비물로 실습 시 필요 준비물로 활용할 수 있습니다.

기기(장비·공구)는

수행 내용을 수행하는데 필요한 기본적인 장비 및 도구를 제시하였습니다. 제시된 기기 외에도 수행에 필요한 다양한 도구나 장비를 활용할 수 있습니다.

안전·유의사항은

수행 내용을 수행하는데 안전상 주의해야 할 점 및 유의사항을 제시하였습니다. 수행 시 유념해야 하며, NCS의 고려사항도 추가적으로 활용할 수 있습니다.

수행 순서는

실습과제의 진행 순서로 활용할 수 있습니다.

수행 tip은

수행 내용에서 수행의 수월성을 높일 수 있는 아이디어를 제시하였습니다. 따라서 수행tip은 지도상의 안전 및 유의사항 외에 전반적으로 적용되는 주요점 및 수행과제 목적에 대한 보충설명, 추가사항 등으로 활용할 수 있습니다.

학습3 교수·학습 방법

교수·학습 방법은

학습목표를 성취하는데 필요한 교수 방법과 학습 방법을 제시하였습니다.

교수 방법

- 컬러링 제품의 성분과 컬러별 정도의 차이, 베이스코트와 튜코트의 역할, 폴리시 잡는 방법, 큐어링 시간 등의 내용을 화면 자료와 함께 설명한다.
- 서식지를 활용하여 네일 컬러링 방법을 그림으로 그려 보게 한 뒤, 다양한 컬러링의 매뉴얼을 그려서 숙지하도록 한다.
- 젤 컬러링 시 주의사항을 계속 숙지시키도록 하며, 큐어링 시간에 대해 작성하도록 한다.

교수 방법은

해당 학습활동에 필요한 학습내용, 학습내용과 관련된 학습자료명, 자료 형태, 수행내용의 진행 방식 등에 대하여 제시하였습니다. 또한 학습자의 수업참여도를 제고하기 위한 방법 및 수업진행상 유의사항 등도 제시하였습니다. 선수학습이 필요한 학습을 학습자가 숙지하였는지 교수자가 확인하는 과정으로 활용할 수도 있습니다.

학습 방법

- 컬러링을 위한 재료의 필요성과 사용방법을 숙지하고 컬러링 매뉴얼 과정에 맞추어 작업 내용을 이해한다.
- 컬러링의 다양성에 대한 용어를 숙지하고 진행과정에 맞추어 내용을 작업한다.
- 젤 컬러링 시 적합한 큐어링 시간을 선택해서 큐어링 해본다.

학습 방법은

해당 학습활동에 필요한 학습자의 자기주도적 학습 방법을 제시하였습니다. 또한 학습자가 숙달해야 할 실기능력과 학습과정에서 주의해야 할 사항 등으로 제시하였습니다. 학습자가 학습을 이수하기 전에 반드시 숙지해야 할 기본 지식을 학습하였는지 스스로 확인하는 과정으로 활용할 수 있습니다.

학습3 평가

평가 준거

- 평가자는 학습자가 학습 목표 및 평가 항목에 제시되어 있는 내용을 성공적으로 수행하였는지를 평가해야 한다.
- 평가자는 다음 사항을 평가해야 한다.

학습내용	평가항목	성취수준		
		상	중	하
컬러링 매뉴얼 이해	- 고객의 요구에 따라 네일 폴리시 색상의 칠착을 막기 위한 베이스코트를 아주 얇게 도포할 수 있다.			
	- 작업 매뉴얼에 따라 네일 폴리시를 일찍 얹어 균일하게 도포할 수 있다.			
	- 작업 매뉴얼에 따라 네일 폴리시 도포 후 컬러 보호와 광택 부여를 위한 톱코트를 바를 수 있다.			

평가 방법

- 작업장 평가

학습내용	평가항목	성취수준		
		상	중	하
컬러링 매뉴얼 이해	- 고객의 요구에 따라 네일 폴리시 색상의 칠착을 막기 위한 베이스코트를 아주 얇게 도포할 수 있다.			
	- 작업 매뉴얼에 따라 네일 폴리시를 일찍 얹어 균일하게 도포할 수 있다.			
	- 작업 매뉴얼에 따라 네일 폴리시 도포 후 컬러 보호와 광택 부여를 위한 톱코트를 바를 수 있다.			

피드백

- 작업장 평가
 - 작업 결과물을 확인하여 수정사항을 제시하고 수정 부분을 인지하도록 한다.

평가는

해당 NCS 능력단위 평가방법과 평가 시 고려 사항을 준용하여 작성하였습니다. 교수자 및 학습자가 평가항목 별 성취수준을 확인하는데 활용할 수 있습니다.

평가 준거는

학습자가 해당 학습을 어느 정도 성취하였는지를 평가하기 위한 기준을 제시하고 있습니다. 학습목표와 연계하여 단위수업 시간에 평가항목 별 성취수준을 평가하는데 활용할 수 있습니다.

평가 방법은

NCS 능력단위의 평가방법을 준용하였으며, 평가 준거에 따른 평가방법을 2개 이상 제시하였습니다. 평가방법으로는 포트폴리오, 문제해결 시나리오, 서술형 시험, 논술형 시험, 사례연구, 평가자 체크리스트, 작업장 평가 등이 있으며, NCS의 능력단위 요소 별 수행 수준을 평가하는데 가장 적절한 방법을 선정하여 활용할 수 있습니다.

피드백은

평가 후에 학습자들에게 평가 결과를 피드백하여 부족한 부분을 알려주고, 학습 결과가 미진한 경우, 해당 부분을 다시 학습하여 학습목표를 달성하는 데 활용할 수 있습니다.

4. 참고 자료

참고자료

- 김미원(2011). 『Nail Study』. 서울: 사)한국네일저서서비스협회.
- 민방경(2015). 『미용사(네일)평가』. 서울: 예문사.
- 박은주(2014). 『네일미용』. 서울: 정담미디어.

참고자료는

해당 학습모듈의 필요지식에 대한 출처와 인용한 참고자료 및 사이트를 제시하였습니다.

5. 활용 서식/부록

활용서식

프리에지 형태 실습지

1. 프리에지 형태의 이해

모양	이름	특징
	() Square nail	-강한 느낌의 사각형태 -네일의 양끝 모서리 부분이 90° 사각의 형태이다. () -발톱의 형태 활용 -내인성 발톱의 보정시에 적음

활용서식은

평가 서식, 실습시트 등 교수학습 시 활용 가능한 다양한 서식들로 구성하였습니다. 과제 진행에서 평가에 이르기까지 필요한 서식을 해당 학습모듈의 특성에 맞춰 개발하거나 기존의 양식을 활용하여 제시하였습니다.

부록

네일 기본관리 도구와 재료 목록

목록	비고	준비
위생가운	흰색	작업자 착용
위생 마스크	흰색	작업자 착용
보호안경	투명한 렌즈 (안경으로 대체 가능)	작업자 착용
재료정리함	재질, 색상 무관	작업대

부록은

활용서식 이외에 교수학습과정에서 참고할 수 있는 자료가 있는 경우 제시하였습니다.

[NCS-학습מוד의 위치]

대분류	정보통신	
중분류	정보기술	
소분류	정보기술 전략 · 계획	

세분류	능력단위	학습מוד명
정보기술전략		
정보기술 컨설팅	빅데이터 분석 기획	빅데이터 분석 기획
정보기술기획	빅데이터 수집	빅데이터 수집
SW제품기획	빅데이터 저장	빅데이터 저장
빅데이터분석	빅데이터 처리	빅데이터 처리
	분석용 데이터 탐색	분석용 데이터 탐색
	통계 기반 데이터 분석	통계 기반 데이터 분석
	머신러닝 기반 데이터 분석	머신러닝 기반 데이터 분석
	텍스트마이닝 기반 데이터 분석	텍스트 마이닝 기반 데이터 분석
	빅데이터 분석 결과 시각화	빅데이터 분석 결과 시각화

차 례

학습모듈의 개요	1
학습 1. 가설 설정하기	
1-1. 가설 설정	3
1-2. 가설 평가를 위한 기준설정	12
• 교수·학습 방법	21
• 평가	22
학습 2. 빅데이터 모델 개발하기	
2-1. 빅데이터 분석모델 설계	24
2-2. 빅데이터 분석모델 확장 및 활용	54
• 교수·학습 방법	64
• 평가	65
학습 3. 빅데이터 모델 평가 검증하기	
3-1. 빅데이터 분석모델 평가	67
• 교수·학습 방법	85
• 평가	86
학습 4. 빅데이터 모델 운영방안 마련하기	
4-1. 빅데이터 모델 운영시스템 적용방안	88
4-2. 빅데이터 모델 운영 및 개선 방안 수립	92
• 교수·학습 방법	95
• 평가	96

통계 기반 데이터 분석 학습모듈의 개요

학습모듈의 목표

수집된 내·외부 데이터 및 정형·비정형 데이터를 활용하여 분석 목적에 따라 가설을 설정하고 필요한 데이터 세트를 편성하여 통계기반 데이터 분석 모델을 만들고 평가할 수 있다.

선수학습

빅데이터 기획 및 분석, 분석용 데이터 탐색(2001010505_15v1)

학습모듈의 내용 체계

학습	학습 내용	NCS 능력단위 요소	
		코드번호	요소 명칭
1. 가설 설정하기	1-1. 가설 설정	2001010506_15v1.1	가설 설정하기
	1-2. 가설 평가 위한 기준설정		
2. 빅데이터 모델 개발하기	2-1. 빅데이터 분석모델 설계	2001010506_15v1.2	빅데이터 모델 개발하기
	2-2. 빅데이터 분석모델 확장 및 활용		
3. 빅데이터 모델 평가 검증하기	3-1. 빅데이터 분석모델 평가	2001010506_15v1.3	빅데이터 모델 평가 검증하기
4. 빅데이터 모델 운영방안 마련하기	4-1. 빅데이터 모델 운영시스템 적용방안	2001010506_15v1.4	빅데이터 모델 운영방안 마련하기
	4-2. 빅데이터 모델 운영 및 개선 방안 수립		

핵심 용어

가설검증, 예측 모델, 분류 모델, 클러스터링 모델, 연관 모델, 앙상블 모델

학습 1 가설 설정하기(LM2001010506_15v1.1)

학습 2	빅데이터 모델 개발하기(LM2001010506_15v1.2)
학습 3	빅데이터 모델 평가 검증하기(LM2001010506_15v1.3)
학습 4	빅데이터 모델 운영방안 마련하기 (LM2001010506_15v1.4)

1-1. 가설 설정

학습 목표

- 빅데이터 분석 프로젝트의 목적 달성을 위하여 비즈니스 도메인과 수집된 데이터를 파악할 수 있다.
- 프로젝트의 목적에 적합한 모델 개발을 위하여 데이터의 사전탐색을 통하여 가설을 설정할 수 있다.

필요 지식 /

① 통계기반 빅데이터 분석 개요

빅데이터 분석은 대량의 정형·비정형 데이터로부터 의미 있는 정보를 추출하고, 숨겨진 패턴 혹은 그간 인지하지 못했던 다양한 데이터 간의 관계를 발견해내어 정보를 추출, 분석하는 과정이다. 이러한 분석을 통해 기업은 궁극적으로 더 나은 의사결정을 수행하는데 그 목적이 있다. 빅데이터 분석을 위해서는 데이터 수집, 처리를 위한 다양한 IT 기술의 도움이 필요하지만, 데이터로부터 의미 있는 정보를 도출해내기 위해서는 결국 통계 및 데이터 마이닝 기법들이 빅데이터 분석의 기초이자 핵심이라 할 수 있다.

통계분석은 불확실한 상황에서 더 객관적인 근거에 기반을 둔 의사결정을 수행하기 위해 데이터를 수집하고, 처리, 분류, 분석 및 해석을 하는 일련의 체계를 의미한다. 분석을 지원하기 위한 다양한 통계 기법들이 존재하며, 분석목적에 부합하는 통계 기법들을 선택하고 데이터를 처리, 분석, 해석을 지원하기 위한 다양한 통계 툴(R, SAS 등)들이 존재한다. 반면 데이터 마이닝 기반 분석은 통계 및 수학적 기술들을 활용하여 빅데이터를 분석하고 이를 통해 새로운 상관관계, 추세, 예측, 분류 등을 찾아내고 수행하는 과정이다. 이러한 데이터마이닝은 기계학습, 패턴인식 등과 관련하여 빅데이터 분석에 있어서 가장 기본적인 통계기반 분석기술들의 집합이라 볼 수 있다.

본 장에서는 이러한 통계기반 빅데이터 분석 기법들에 대해 살펴보고 통계기반 빅데이터 분석과 관련된 제반 내용을 살펴보고자 한다. 이에 먼저 통계분석의 기본인 가설설정 및 가설

검정에 관한 내용을 살펴보고 이후 통계 및 데이터마이닝 기반 빅데이터 분석모델들에 대해 알아보도록 한다.

② 가설 개요

수집된 내·외부 데이터 및 정형·비정형 데이터를 활용하고 다양한 빅데이터 기반 분석을 통해서 비즈니스적으로 유의미한 지식, 정보를 추출하게 된다. 예를 들어 수집된 과거 데이터 즉 표본으로부터 특정 변수의 미래값을 예측, 평가하기 위한 예측모델을 도출하기 위해 다양한 통계적인 방법론이 적용되고, 도출된 모델이 얼마나 데이터를 잘 반영하고 있는지 모델의 유의성 검증을 위해 가설을 설정하고 가설검정을 시행하게 된다. 이와 같이 가설설정 및 가설검증은 모델 유의성 검토를 포함한 다양한 상황에서 통계적 검증을 위해 시행되게 되며, 이들에 대한 올바른 이해가 필요하다. 먼저 가설이란 무엇인지에 대해 살펴본다.

1. 가설의 정의

가설이란 모집단의 특성, 특히 모수에 대한 가정 혹은 잠정적인 결론이다. 이러한 가설을 검증하기 위해 알고 싶은 내용을 기술한 가설의 종류에는 귀무가설과 대립가설이 있다.

2. 귀무가설과 대립가설

대립가설(alternative hypothesis)은 표본을 통해 확실한 근거를 가지고 입증하고자 하는 가설로서 연구가설(research hypothesis)이라고도 한다. 대립가설과 반대되는 가설을 귀무가설(null hypothesis)이라 부르며 현재까지 주장되어 온 것이거나 기존과 비교하여 변화 혹은 차이가 없음을 나타내는 가설이다. 예를 들어 한 제약회사가 기존 약 A와 비교하여 효과가 향상된 두통약 B를 개발했다고 가정해보자. 제약회사는 신약 B가 효과가 있음을 입증하고자 할 것이다. 이러한 상황에서 귀무가설은 “두통약 A와 B 간의 효과 차이가 없다”와 같이 나타낼 수 있는 반면, 대립가설은 “두통약 A와 B 간의 효과 차이가 존재한다”와 같이 나타낼 수 있다. 귀무가설은 H_0 , 대립가설은 H_1 와 같이 표기한다.

③ 가설검정 개요

분석하고자 하는 대상 모집단의 추출된 표본으로부터 분석목적에 적합한 과학적 추론을 위해서 가설검정을 시행하게 된다. 가설검정이란 모집단에 대한 통계적 가설을 세우고 표본을 추출한 다음, 그 표본을 통해 얻은 정보를 이용하여 통계적 가설의 진위를 판단하는 과정이다. 즉, 표본을 활용하여 모집단에 대입해보았을 때 새롭게 제시된 대립 가설이 옳다고 판단할 수 있는지를 평가하는 과정이다. 대부분 귀무가설이 참이라는 전제하에서 표본을 통하여 귀무가설이 옳지 않다는 것을 보임으로써 귀무가설을 기각시키고 대신 대립가설을 채택하게 되는 것이다. 따라서 귀무가설이 참이 아니라는 것을 표본을 통하여 통

계적으로 증명하지 못한다면 귀무가설을 기각할 수 없게 되는 것이다. 이를 위해 귀무가설이 참이라는 전제로 아주 예외적인 표본의 통계값이 나타날 확률이 일정수준(대개, 1%, 5% 혹은 10%) 이하일 경우에만 (즉, 표본 조사를 통해 얻은 통계값이 매우 극단적일 경우) 귀무가설을 기각하고 대립가설을 채택하게 되는 것이다. 이는 귀무가설이 옳다는 전제하에서 표본조사를 하였으므로 극단적인 통계값을 얻게 된다는 의미는 귀무가설이 참이라는 전제가 잘못되었음을 의미하고 귀무가설을 기각하게 되는 것이다. 다음은 가설검정과 관련하여 고려해야 하는 사항들에 대해 알아본다.

1. 가설 검정 방법

일반적으로 가설검정 방법은 대립가설의 형태에 따라서 양측검정과 단측검정이 있다.

(1) 양측검정

모수 θ (혹은 모수들의 함수)에 대해 표본자료를 바탕으로 모수가 특정값 θ_0 과 통계적으로 같은지 여부를 판단하기 위해 귀무가설을 $H_0 : \theta = \theta_0$, 대립가설을 $H_1 : \theta \neq \theta_0$ 와 같이 설정하는 경우를 양측검정이라 한다.

(2) 단측검정

모수 θ 에 대한 귀무가설이 $H_0 : \theta = \theta_0$ 일 때, θ 가 특정 값 θ_0 보다 클 경우(혹은 작은 경우)에만 귀무가설을 기각하게 되는 경우를 단측검정이라 한다. 이 경우의 대립가설은 $H_1 : \theta > \theta_0$ 혹은 $H_1 : \theta < \theta_0$ 와 같다.

2. 가설 검정의 오류

통계적인 방법에 근거하여 주어진 가설을 검증하는 데 있어 모집단 전체를 통해 검증하는 것이 아닌 모집단으로부터 추출된 표본을 기반으로 모집단에 대한 결론을 내리는 것이기 때문에 다음과 같은 통계적인 오류가 발생할 가능성이 항상 존재한다.

(1) 제1종 오류

귀무가설이 참인데 잘못하여 이를 기각하게 되는 오류를 제1종 오류라 한다.

(가) 유의수준(level of significance)

제1종 오류를 범할 최대 허용확률을 의미하며, α 로 표기한다.

(나) 신뢰수준(level of confidence)

귀무가설이 참일 때 이를 참이라고 판단하는 확률 (즉, $1 - \alpha$)을 신뢰수준이라 한다.


(2) 제2종 오류

귀무가설이 참이 아닌데 잘못하여 이를 채택하게 되는 오류를 제2종 오류라 한다.

(가) 검정력

제2종 오류를 범할 최대 허용확률을 β 라 할 때, 귀무가설이 참이 아닌 경우 이를 기각할 수 있는 확률(즉, $1 - \beta$)을 검정력이라 한다.

		참값 (실제현상)	
		H_0	H_1
채택	H_0	올바른 결정 ($1 - \alpha$)	제2종 오류 (β)
(통계적 결정)	H_1	제1종 오류 (α)	올바른 결정 ($1 - \beta$)



[그림 1-1] 가설 검정의 오류 (단측검증 예시)


3. 검정 통계량과 p-값

(1) 검정 통계량

검정 통계량은 가설검정의 대상이 되는 모수를 추론하기 위해 사용되는 표본 통계량으로, 귀무가설이 참이라는 전제하에서 모집단으로부터 추출된 확률표본의 정보를 이용하여 계산된다.

(2) p-값

귀무가설이 참이라는 가정에 따라 주어진 표본 데이터를 회소 또는 극한값으로 얻을 확률값을 p-값이라고 한다. 이는 검정 통계량 및 이의 확률분포에 근거하여 귀무가설이 참일 때 귀무가설을 기각하게 되는 제1종 오류를 범할 확률로도 볼 수 있다.



[그림 1-2] 검정 통계량과 p-값과의 관계 ([그림 1-1] 참조)

수행 내용 / 가설 설정 및 검정하기

재료 · 자료

- 분석 세부 계획 수립을 위한 조직 내/외부 정보
- 통계 및 연구방법론 관련 도서/논문

기기(장비 · 공구)

- 컴퓨터, 프린터
- 문서 편집 도구
- 인터넷

안전 · 유의 사항

- 해당 없음

수행 순서

① 데이터 분석 목적과 비즈니스 문제에 대한 이해를 명확히 한다.

어떠한 목적으로 데이터를 분석하고자 하는지에 대해 명확한 판단이 선행되어야 한다. 표본을 통해 모집단의 특성을 추론하는 통계적 접근방법이 데이터 분석의 목적에 부합하는지를 명확히 파악하는 것이 필요하다.

1. 데이터 분석 목적 예시

한 제약회사는 새롭게 개발한 신 다이어트 프로그램이 체중감소에 탁월한 효과가 있다고 광고한다. 이에 체중감소 효과 여부를 분석하고자 한다.

② 데이터분석을 위한 데이터 수집/확보 계획을 수립하고 필요 데이터를 수집한다.

1. 데이터 수집/확보 계획 작성하기

데이터 분석 목적을 명확히 한 후 분석에 필요한 데이터들을 어떻게 확보할 것인지에 대한 세부 계획서를 작성한다. 계획서에는 데이터의 소스(조직 내외 여부 등)를 파악하고 각 소스별로 데이터 수집계획을 수립해야 한다.

2. 데이터 수집/확보 계획에 따라 필요한 데이터를 수집한다.

필요 데이터가 운영시스템에 운영시스템 접근 및 조회 권한이 있는 사내 담당자들과의 협업을 통해 분석을 위한 필요 데이터를 수집한다. 만일, 외부 데이터 수집이 필요한 경우, 데이터 구매 등의 다양한 절차를 통해 데이터를 별도로 수집해야 한다.

(1) 데이터 분석 예시에 대한 데이터 수집 방안

다이어트 프로그램의 체중감소 효과분석을 위해 다이어트 프로그램에 참여하기를 희망하는 지원자들을 모집했다. 이들에 대해 먼저 다이어트 프로그램 참석 전 체중을 측정하고 1개월간 다이어트 프로그램을 진행한 후에 다시 지원자들의 체중을 측정하였다. 예를 들어 10명의 지원자에 대해 <표 1-1>과 같은 데이터를 수집하였다고 가정하자.

<표 1-1> 지원자별 다이어트 프로그램 참여 전후 체중 데이터 예시

지원자	다이어트 프로그램 참여 전	다이어트 프로그램 참여 후
1	57.90	58.31
2	64.68	61.27
3	66.30	66.43
4	59.97	58.39
5	74.12	73.71
6	72.71	71.72
7	72.50	70.59
8	68.36	66.83
9	78.86	76.84
10	49.24	48.17
평균	66.46	65.23
표준편차	8.86	8.71

③ 분석 모델에 대한 가설을 설정한다.

수집된 데이터를 바탕으로 모집단의 특성을 통계적으로 검정하고자 하는 목적에 따라서 귀무가설 및 대립가설을 설정한다. 일반적으로 귀무가설은 분석가설에 포함된 오직 하나의 통계량을 찾는 형식으로 구성된다. 그리고 귀무가설은 모집단의 분포, 특히 모수를 기반으로 표현되어야 한다는 점이다. 표본의 통계량은 가설을 세우는 데 이용되나 귀무가설 및 대립가설을 설정하는 데는 직접 이용할 수 없다. 정리하면, 가설검증을 하는 목적은 주어진 표본의 통계치를 이용하여 모집단의 특성을 추론하는 것이기 때문에 귀무가설은 모집단을 나타내는 모수로 표현되어야 한다. 또 대립가설은 귀무가설과 정반대로 중복되지 않도록 설정해야 한다.

1. 데이터 분석 예시에 대한 가설설정

다이어트 프로그램의 체중감소 효과분석을 위해 다음과 같은 가설을 설정할 수 있다.

(1) 양측검증

- 귀무가설 H_0 : 다이어트 프로그램 참여 전의 체중과 참여 후의 체중의 차이에 대한 모평균은 0이다.

- 대립가설 H_1 : 다이어트 프로그램 참여 전의 체중과 참여 후의 체중의 차이에 대한 모평균은 0이 아니다.

(2) 양측검증

- 귀무가설 H_0 : 다이어트 프로그램 참여 전의 체중과 참여 후의 체중의 차이에 대한 모평균은 0이다.
- 대립가설 H_1 : 다이어트 프로그램 참여 전의 체중과 참여 후의 체중의 차이에 대한 모평균은 0보다 크다. (즉, 다이어트 프로그램은 효과가 있다.)

2. 추가적인 가설설정 예제

- (1) 사례 1: K 회사는 기존에 고객만족도 점수가 평균이 8.6점이고 표준편차가 0.8점으로 알고 있었다. 그러나 최근 200명 고객을 대상으로 고객만족도 조사를 한 결과 평균 8.8점으로 나타났다. 이에 K 회사는 최근 조사를 바탕으로 기존에 알고 있던 고객만족도 평균이 8.6점이 아니라고 통계적으로 주장할 수 있는지 검증하고자 한다.

- 귀무가설 H_0 : K 회사의 고객만족도 점수의 평균은 8.6점이다.
- 대립가설 H_1 : K 회사의 고객만족도 점수의 평균은 8.6점이 아니다.

- (2) 사례 2: H고등학교 남자 선생님들은 결혼 후 살이 찐다고 주장하고 있다. 이를 위해 H고등학교가 속한 도시에 있는 고등학교에 재직 중인 결혼한 남자 선생님들을 표본 추출 하여 결혼 기간과 결혼 전후 몸무게 데이터를 구하여 분석하였다. 결혼 기간과 몸무게 증가가 상관관계가 있다고 할 수 있는지를 통계적으로 검증하고자 한다.

- 귀무가설 H_0 : 결혼 기간과 몸무게 증가 간의 상관관계가 없다. (즉, 상관계수는 0이다.)
- 대립가설 H_1 : 결혼 기간과 몸무게 증가 간의 상관관계가 있다. (즉, 상관계수는 0이 아니다.)

④ 유의수준을 결정하고 검정방법을 선택한 후 유의수준을 고려해 임계치를 산출한다.

1. 유의수준을 결정한다.

대립가설 채택 여부를 결정하기 위해서 유의수준을 결정해야 한다. 통계학적으로 유의수준 (제1종 오류를 범할 최대허용확률)을 어떻게 결정하는지에 대한 명확한 이론은 없는 관계로 통상적으로 허용되는 수준으로 결정하게 되며 통상적으로 0.1, 0.05, 0.01 중 하나를 채택하게 된다. 이후, 분석의 목적에 적절한 검정방법을 선택한다.

(1) 데이터 분석 예시에 대한 유의수준 결정


본 예시에서는 유의수준 0.05(5%)에서 다이어트 프로그램의 효과 여부를 알아보기 위한 가설채택 여부를 결정한다고 가정하자.

2. 검정방법을 결정하고 검정 통계량 값을 구한다.

데이터의 종류, 인자 수, 데이터의 평균 혹은 분산에 대한 검정 여부 등에 따라서 적절한 통계분석 도구와 검정 통계량을 결정한다. 여기서 검정 통계량이란 통계적 가설 검정에 사용되는 통계량을 말하며 확률표본의 함수로 표현된다. 그리고 귀무가설이 참이라는 전제 하에서 표본으로부터의 검정 통계량의 값을 구한다. 가설검정을 확률분포를 활용하게 되는데, 확률분포에 따라서 검정 통계량으로 대개 Z 통계량(정규분포), t 통계량(t분포), χ^2 통계량(χ^2 분포), F 통계량(F분포)을 사용한다. 검정 통계량에 해당하는 분포를 활용하여 p-값을 결정한다. 자세한 내용은 다음 절에서 다루기로 한다.

⑤ 가설 채택 여부를 결정한다.

가설검정 시 p-값과 유의수준을 비교하여 귀무가설 혹은 대립가설을 채택하는 절차를 거치게 된다. p-값은 귀무가설이 참이라는 전제하에서 구한 검정 통계량의 값이 나타날 가능성으로 해석할 수 있으며, p-값이 유의수준보다 작으면(즉, 검정 통계량의 값이 나타날 가능성이 작으면) 귀무가설을 기각하고 대립가설을 채택하게 되며 p-값이 유의수준보다 크면 귀무가설을 채택하게 된다.



[그림 1-3] 가설검정의 단계

수행 tip

- 데이터 분석의 목적에 표본 데이터를 통한 모집단의 특성을 추론하는 통계 기반 데이터 분석이 부합하는지를 파악하는 것이 중요하므로 적합도 판단 및 가설설정과 관련하여 전문가의 조언을 받아서 진행되어야 한다.
- 가설검정을 시행하기 전에 그래프 분석을 통해서 데이터의 전체적인 모습을 보고 이상치 확인 및 제거작업 등을 통해서 정확한 가설검정 결과를 도출할 수 있도록 해야 한다.

1-2. 가설 평가를 위한 기준설정

학습 목표 • 분석 모델의 가설 평가를 위한 통계치의 기준을 설정하고 적용할 수 있다.

필요 지식 /


① 가설검정을 통한 평균 차이 분석법

모집단의 평균과 관련한 다양한 가설검정 및 관련 검정 통계량에 대해 알아본다.

1. 집단평균과 특정 평균의 비교

한 집단의 평균 μ 가 특정 평균값 μ_0 과 같은지를 비교하는 경우, 가설은 다음과 같이 설정한다.

- 귀무가설 H_0 : 모평균이 특정 평균값과 같다. ($\mu = \mu_0$)
- 대립가설 H_1 : 모평균이 특정 평균값과 같지 않다. ($\mu \neq \mu_0$)



[그림 1-4] 모집단평균이 특정 값과 일치하는지 여부를 판단하기 위한 가설검정

(1) 검정 통계량

평균이 μ , 분산 σ^2 인 정규분포를 따르는 모집단에 대해 모평균 μ 에 대한 가설을 검정하기 위해서, n 개의 표본을 추출하여 이의 표본 평균 및 표본 표준편차를 각각 $\bar{X}$ 와 s 라고 하자.

(가) 모집단의 표준편차 σ 를 아는 경우

검정통계량은 $Z = \frac{\bar{X} - \mu_0}{\sigma / \sqrt{n}}$ 으로 표준정규분포를 따른다.


(나) 모집단의 표준편차 σ 를 모르는 경우

검정통계량은 $T = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$ 으로 $t_{(n-1)}$ 분포를 따른다. 여기서 T 통계량의 자유도는 $n-1$ 인데, 자유도란 통계적 추적 시 표본에서 모집단에 대한 정보를 주는 독립적인 자료의 개수로서, 표본의 개수가 n 일 때 표본 표준편차 s 에 대해 $\bar{X}$ 관계식이 있으므로 자유도는 $n-1$ 이 된다.

2. 두 집단 평균의 비교

두 집단의 모평균이 서로 같은지 여부를 비교하기 위한 경우로, 두 모집단의 모평균을 각각 μ_1 과 μ_2 라 하면 가설설정은 다음과 같다.

- 귀무가설 H_0 : 두 모집단의 평균은 같다. ($\mu_1 = \mu_2$ 혹은 $\mu_1 - \mu_2 = 0$)
- 대립가설 H_1 : 두 모집단의 평균은 같지 않다. ($\mu_1 \neq \mu_2$ 혹은 $\mu_1 - \mu_2 \neq 0$)



[그림 1-5] 두 집단 간의 모평균의 일치여부를 판단하기 위한 가설검정

(1) 검정 통계량

평균이 μ_i , 분산 σ_i^2 인 정규분포를 따르는 모집단 $i = 1, 2$ 에 대해 두 모평균 μ_i 간의 차이에 대한 가설을 검정하기 위해서, 각 모집단으로부터 n_i 개의 표본을 추출하여 이의 표본 평균 및 표본 표준편차를 각각 $\bar{X}_i$ 와 s_i 라고 하자.

(가) 두 모집단의 표준편차 σ_i 를 아는 경우

검정통계량은 $Z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$ 으로 표준정규분포를 따른다.

(나) 모집단의 표준편차 σ_i 를 모르는 경우


$$\text{검정통계량은 } T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \quad \text{으로 } t_{(n_1 + n_2 - 2)} \text{ 분포를}$$

따른다.

3. 동일한 집단의 두 평균 비교

일반적으로 연구의 효과성 검증을 위해 동일한 집단을 대상으로 실험 전후의 결과값을 비교하여 차이가 존재하는지를 검증한다. 이러한 상황에서 평균적으로 실험 전후의 차이가 존재하는지를 검정하기 위한 경우로, 동일한 집단의 실험 전후 차이에 대한 모평균을 μ_D 라 하면 가설설정은 다음과 같다.

- 귀무가설 H_0 : 차이에 대한 모평균은 0과 같다. ($\mu_D = 0$)
- 대립가설 H_1 : 차이에 대한 모평균은 0이 아니다. ($\mu_D \neq 0$)



[그림 1-6] 동일한 집단의 실험 전후 두 평균 비교를 위한 가설검정

(1) 검정 통계량

모집단에서 n 개의 표본을 추출하여 이의 실험 전후의 차이에 대한 표본 평균 및 표본 표준편차를 각각 $\bar{D}$ 와 $s_{\bar{D}}$ 라 하자. 이때 검정통계량은 $T = \frac{\bar{D}}{s_{\bar{D}}/\sqrt{n}}$ 으로 $t_{(n-1)}$ 분포를 따른다.

② 가설점정을 통한 분산차이 분석법

모평균에 대한 가설검정 외에도 모분산에 대한 가설검정 (예를 들면, 측정오차 허용범위)이 요구되는 경우도 많다.

1. 집단 모분산과 특정분산의 비교

한 집단의 분산 σ^2 이 특정 평균값 σ_0^2 과 같은지를 비교하는 경우, 가설은 다음과 같이 설정한다.

- 귀무가설 H_0 : 모분산이 특정 분산값과 같다. ($\sigma^2 = \sigma_0^2$)
- 대립가설 H_1 : 모분산이 특정 분산값과 같지 않다. ($\sigma^2 \neq \sigma_0^2$)

(1) 검정 통계량

모분산 σ^2 에 대한 가설을 검정하기 위해서, n 개의 표본을 추출하여 이의 표본 분산을 s^2 라고 하자. 이때 검정통계량은 $\chi^2 = \frac{(n-1)s^2}{\sigma^2}$ 으로 $\chi^2_{(n-1)}$ 분포를 따른다.

2. 집단 모분산과 특정분산의 비교

두 집단의 모분산이 서로 같은지 여부를 비교하기 위한 경우로, 두 모집단의 모분산을 각각 σ_1^2 과 σ_2^2 라 할 경우 가설설정은 다음과 같다.

- 귀무가설 H_0 : 두 모집단의 모분산은 같다. ($\sigma_1^2 = \sigma_2^2$ 또는 $\frac{\sigma_1^2}{\sigma_2^2} = 1$)
- 대립가설 H_1 : 두 모집단의 모분산은 같지 않다. ($\sigma_1^2 \neq \sigma_2^2$ 또는 $\frac{\sigma_1^2}{\sigma_2^2} \neq 1$)

(1) 검정통계량

모집단 $i = 1, 2$ 에 대해 두 모분산 σ_i^2 간의 차이에 대한 가설을 검정하기 위해서, 각 모집단으로부터 개의 표본을 추출하여 이의 표본 분산을 각각 $s_i^2 (i = 1, 2)$ 라고 하자. 이러한 경우의 검정통계량은 $F = \frac{s_j^2}{s_k^2}$ ($s_j^2 > s_k^2, j, k = 1, 2, j \neq k$)으로 $F_{(n_j-1, n_k-1)}$ 분포를 따른다.

수행 내용 / 가설평가를 위한 기준설정하기

재료·자료

- 통계 및 연구방법론 관련 도서/논문
- 통계 패키지 활용방법 등을 소개한 도서

기기(장비·공구)

- 컴퓨터, 프린터
- 문서 편집 도구
- 인터넷

안전·유의 사항

- 해당 없음

수행 순서

① 데이터 분석 목적 및 가설을 바탕으로 가설검정을 위한 적합한 검정 통계량을 결정한다.

가설 검정하는 방법은 데이터가 연속형 데이터인지 이산형 데이터인지에 따라서 또는 모집단의 평균 혹은 분산에 관한 검정인지 등에 따라서 적합한 검정방법이 존재하며 가설에 부합하는 검정 통계량 및 이에 대한 분포를 결정해야 한다.

1. 데이터 분석 예시에 대한 검정방법 선택 및 검정 통계량 결정

학습 내용 1-1의 수행내용 ②에서 살펴보았던 데이터 분석 예시를 살펴보도록 하자. 예제의 경우, 동일한 지원자를 대상으로 다이어트 프로그램 수행 전·후 체중을 기록하여 이들 간의 평균차이가 통계적으로 유의하게 차이가 존재하는지를 알아보고자 하므로 동일한 집단의 두 평균 비교에 해당된다. 따라서 검정통계량은

$$T = \frac{\bar{D}}{s_{\bar{D}}/\sqrt{n}}$$
로 한다. (이때, 다이어트 프로그램 수행 전·후 체중의 차이에 대한

표본 평균 및 표본 표준편차를 각각 $\bar{D}$ 와 $s_{\bar{D}}$ 이라 함).

② 각 검정방법에서의 모집단에 대한 가정을 확인하고 표본 데이터가 검정방법의 가정에 부합하는지를 확인한다.

모집단에 대한 가정에 따라 검정방법별로 적합한 검정 통계량이 있게 된다. 예를 들어 평

균 차이 분석법에서는 기본적으로 데이터가 정규분포를 따른다는 가정을 한다. 따라서 주어진 데이터가 이러한 가정을 만족하는지를 확인해야 한다.

③ 검정방법에 적합한 검정 통계량 결정과 p-값을 산출한다.

주어진 데이터를 가지고 검정 통계량 계산에 요구되는 표본 평균 혹은 표본 분산 등을 R을 포함한 다양한 통계 패키지를 활용하여 계산하고, 검정 통계량의 분포를 확인하여 p-값을 계산한다.

1. 데이터 분석 예시에 대한 p-값 산출

(1) 1-1절에서 살펴보았던 데이터 분석 예시 데이터 불러오기

예를 들어 예시 데이터가 “diet.csv” 파일형식으로 [그림 1-1]과 같이 저장되어 있다고 가정하자.

	A	B	C
1	Subject	Before	After
2	1	57.9	58.31
3	2	64.68	61.27
4	3	66.3	66.43
5	4	59.97	58.39
6	5	74.12	73.71
7	6	72.71	71.72
8	7	72.5	70.59
9	8	68.36	66.83
10	9	78.86	76.84
11	10	49.24	48.17
12			

[그림 1-7] Diet.csv 파일 저장내용 예시

```
> # “diet.csv”파일에 있는 내용을 가져온다.
> data <- read.csv("diet.csv",header=T)
> attach(data)
> names(data)
[1] "Subject" "Before"  "After"
```


(2) 검정 통계량 분포를 확인하여 p-값을 계산

본 예제의 경우 두 집단이 차의 평균이 0인지 아닌지를 검정한다. 이 경우 앞서 살펴본 T 검정 통계량을 바탕으로 쌍체 t검정을 수행하여 p-값을 계산한다.

```

> # "diet.csv" 파일에 있는 내용을 가져온다.
> diff <- Before - After
> diff
[1] -0.41  3.41 -0.13  1.58  0.41  0.99  1.91  1.53  2.02  1.07
> # "diet.csv" 파일에 있는 내용을 가져온다.
> boxplot(diff)

```



[그림 1-8] 다이어트 전후 차이에 대한 box plot
(boxplot()함수 수행결과)

```

> # T 통계량 계산
> mean_diff <- mean(diff)
> mean_diff
[1] 1.238
> sd_diff <- sd(diff)
> sd_diff
[1] 1.122772
> t_stat <- mean_diff/(sd_diff/sqrt(length(diff)))
> t_stat
[1] 3.486815

```

만약 양측검증을 수행하는 경우 다음과 같은 명령어를 수행한다.

```

> t.test(Before, After, alternative=c("two.sided"), paired=TRUE,
conf.level=0.95)

```

Paired t-test

data: Before and After

```
t = 3.4868, df = 9, p-value = 0.006864
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 0.434817 2.041183
sample estimates:
mean of the differences
      1.238
```

위에서 보드시피 p-값은 0.006864이다.

반면, 단측검증을 수행하는 경우 다음과 같은 명령어를 수행한다.

```
> t.test(Before, After, alternative=c("greater"), paired=TRUE,
conf.level=0.95)

Paired t-test

data: Before and After
t = 3.4868, df = 9, p-value = 0.003432
alternative hypothesis: true difference in means is greater than 0
95 percent confidence interval:
 0.58715      Inf
sample estimates:
mean of the differences
      1.238
```

위에서 보드시피 p-값은 0.003432이다.

④ 귀무가설을 채택 혹은 기각한다.

유의수준과 p-값을 활용하여 귀무가설 채택 여부를 결정하게 된다.

1. 데이터 분석 예시에 대한 귀무가설 채택 여부 결정

양측검정, 단측검정 모두 p-값이 유의수준보다 작으므로, 유의수준 5% 기준으로 귀무가설을 기각하고 대립가설을 채택하게 된다. 즉, 가설검정을 통해 다이어트 프로그램이 체중감소에 효과가 있음을 알 수 있다.

수행 tip

- 가설검증 방법별로 모집단에 대한 가정 (예: 정규성, 등분산 등)을 하는 경우가 있으며 이럴 때 검정 통계량에 해당하는 표본 통계값을 산출하기에 앞서 표본 데이터를 가지고 모집단에 대한 가정을 만족하는지를 확인해야 한다.

교수 방법

- 가설검정의 필요성에 관해 설명한다.
- 통계적 분석에 있어서 가설의 정의와 분석상황에 적합한 귀무가설 및 대립가설을 설정할 수 있도록 지도한다.
- 가설검정 방법 및 가설검정에 오류가 발생할 수 있음을 설명하고 그 오류의 종류들에 대해 이해할 수 있도록 지도한다.
- 유의수준, 신뢰수준, 검정력 등 가설검정과 관련한 주요사항들의 개념 및 차이점을 설명한다.
- 통계적 분석을 통한 모집단의 특성을 이해하기 위해서 가설검정을 어떠한 절차를 통해 시행하게 되는지에 대해 이해가 가능하도록 지도한다.
- 통계적 분석목적에 따라 어떠한 검정 통계량을 선택해야 하는지, 검정방법 적용에 있어 가정은 무엇인지 등에 대해서 교육한다.

학습 방법

- 가설검정의 필요성에 대해 학습한다.
- 통계적 분석에 있어서 가설의 정의와 분석상황에 적합한 귀무가설 및 대립가설을 설정할 수 있도록 학습한다.
- 가설검정 방법 및 가설검정에 오류가 발생할 수 있음을 이해하고 그 오류의 종류들에 대해 이해한다.
- 유의수준, 신뢰수준, 검정력 등 가설검정과 관련한 주요사항들의 개념 및 차이점을 이해한다.
- 통계적 분석을 통한 모집단의 특성을 이해하기 위해서 가설검정을 어떠한 절차를 통해 시행하게 되는지에 대해 숙지한다.
- 통계적 분석목적에 따라 어떠한 검정 통계량을 선택해야 하는지, 검정방법 적용에 있어 가정은 무엇인지 등에 대해서 학습한다.

학습1 평 가

평가 준거

- 평가자는 학습자가 학습 목표를 성공적으로 달성하였는지를 평가해야 한다.
- 평가자는 다음 사항을 평가해야 한다.

학습 내용	평가 항목	성취수준		
		상	중	하
가설 설정	- 빅데이터 분석 프로젝트의 목적 달성을 위하여 비즈니스 도메인과 수집된 데이터를 파악할 수 있다.			
	- 프로젝트의 목적에 적합한 모델 개발을 위하여 데이터의 사전탐색을 통하여 가설을 설정할 수 있다.			
가설 평가를 위한 기준설정	- 분석 모델의 가설 평가를 위한 통계치의 기준을 설정하고 적용할 수 있다.			

평가 방법

- 평가자 질문

학습 내용	평가 항목	성취수준		
		상	중	하
가설 설정	- 가설 및 가설검정의 개념과 정의 이해도			
	- 각 분석사례에 대해서 분석목적에 따른 적합한 귀무가설 및 대립가설 설정 여부에 대한 평가			
	- 가설검정 절차에 대한 이해도			
	- 가설검정의 두 가지 오류 및 차이점에 대한 이해도			
	- 유의수준, 검정통계량, p-값 등 가설검정 관련 개념에 대한 이해도			
가설 평가를 위한 기준설정	- 분석목적별로 모집단 모수에 대한 가설을 세우고 경우별로 검증을 위한 적합한 검정통계량 선택 여부에 대한 평가			

• 문제 해결 시나리오

학습 내용	평가 항목	성취수준		
		상	중	하
가설 평가를 위한 기준설정	- 주어진 데이터 세트를 이용하여 가설검증을 위한 검정통계량 계산 및 검증을 R 통계프로그램으로 수행할 수 있는 능력			
	- 가설검정 결과를 통해 가설 채택 여부를 결정하고 활용할 수 있는 능력			

• 사례 연구

학습 내용	평가 항목	성취수준		
		상	중	하
가설 설정	- 가설검정 절차에 따른 수행 사례 조사			
가설 평가를 위한 기준설정	- 가설검정을 위해서 어떠한 검정통계량들이 있는지 추가적인 경우에 관한 사례 조사 및 연구			

피드백

1. 평가자 질문

- 모집단과 표본 집단의 차이, 모수에 대한 정의 등을 이해하지 못하는 학생에게는 선 수강 과목에서 다른 내용을 숙지할 수 있도록 추가 과제 요구를 통해 이해도를 높일 수 있다.
- 가설설정에서 귀무가설과 대립가설의 차이점 및 각각의 가설을 어떻게 설정해야 할지 정확히 이해하지 못하는 학생들에게는 관련 자료 수집 및 요약, 다수의 예제를 해결하는 과제 등을 통해 이해도를 높일 수 있다.
- 검정통계량에서 언급되고 있는 다양한 확률분포에 대해 이해하지 못하는 학생들에게는 선 수강 과목에서 다른 내용을 다시 숙지할 수 있도록 추가 과제 요구를 통해 이해도를 높일 수 있다.

2. 문제 해결 시나리오

- 검정통계량 계산 및 가설검증에 대한 R 통계 프로그래밍 사용법이 익숙하지 않은 경우, 이에 대한 보완 실습과 보충과제를 통하여 학습자들이 사용법에 익숙해질 수 있도록 지도한다.

3. 사례 연구

- 평가자는 추가로 다양한 실제 사례를 조사하여 학습자들이 더욱 다양한 가설검정 사례를 접할 수 있도록 학습기회를 제공하고 가설검정을 수행하기 위한 검정통계량들에 대해 어떤 때 사용되는 것이며 이에 대한 수리적 의미를 스스로 사례연구를 통해 이해할 수 있도록 지도한다.

학습 1	가설 설정하기 (LM2001010506_15v1.1)
학습 2	빅데이터 모델 개발하기 (LM2001010506_15v1.2)
학습 3	빅데이터 모델 평가 검증하기(LM2001010506_15v1.3)
학습 4	빅데이터 모델 운영방안 마련하기 (LM2001010506_15v1.4)

2-1. 빅데이터 분석모델 설계

학습 목표

- 설정된 가설을 검증하기 위하여 분석모델을 설계할 수 있다.
- 모델을 완성도를 평가하기 위한 성능평가 기준을 설정할 수 있다.
- 모델에 적용하는 독립변수와 종속변수의 데이터 유형에 따라 다양한 분석기법을 적용할 수 있다.

필요 지식 /

① 통계적 분석 기반 빅데이터 분석모델


확률·통계적 기법을 적용하여 어떤 현상을 추정, 예측을 검증하는 기법들로, 가장 단순한 기술통계를 비롯하여 상관분석, 회귀분석, 분산분석, 주성분분석 등이 있다.

1. 기술 통계

데이터 분석의 목적으로 수집된 데이터를 확률·통계적으로 정리·요약하는 기초적인 통계를 말한다. 평균, 분산, 표준편차, 왜도와 첨도, 빈도 등 데이터에 대한 대략적인 통계적 수치를 계산하고 도출하거나 막대 그래프, 파이 그래프 등 그래프를 활용하여 데이터에 대한 전반적인 이해를 돕는 데 목적이 있으며 더욱 심도 있는 통계적 분석을 위한 척도로 활용한다. 따라서 이러한 기술 통계는 분석의 초기 단계에서 데이터 분포의 특징을 파악하려는 목적으로 주로 산출한다.

2. 상관 분석(Correlation Analysis)

상관분석은 두 개 이상의 변수 간에 존재하는 상호 연관성의 정도 — 즉, 하나의 변수가 다른 변수와 어떤 밀접성을 가지고 변화 하는가 — 를 측정하여 분석하는 방법이다. 두 변수 사이의 연관 정보를 알아내는 것을 단순 상관분석이라고 하며, 셋 또는 그 이상의 변수들 사이의 연관 정도를 분석하는 것을 다중 상관분석이라고 한다. 데이터의 속성에 따라서 수치적, 명목적, 순서적 데이터 등을 가지는 변수 간의 상관분석이 있다.



[그림 2-1] 상관 분석

(1) 수치적 데이터 변수의 상관분석

수치적 데이터 변수로 이루어진 두 변수 간의 선형적 연관성을 계량적으로 파악하기 위한 통계적 기법으로, 일반적으로 피어슨 상관분석(Pearson correlation analysis)을 선형관련성 정도로 측정하는 척도로 사용한다.

변수들 사이의 연관성의 정도는 특정변수의 분산 중 다른 변수와 함께 변화하는 분산인 공분산이 어느 정도가 되는가에 따라 좌우되며, 공분산이 클수록 상관관계가 높다고 볼 수 있다. 다만 공분산은 변수의 단위에 의존적이기에 값의 크기를 통한 연관성의 정도를 파악하기 어려우므로 표준화를 통해 상관관계의 정도를 나타내는 정량화된 지표가 상관계수이다. 대표적으로 피어슨 상관계수 $r(\in [-1, 1])$ 은 다음과 같이 정의한다.

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

(2) 명목적 데이터 변수의 상관분석

항목들을 분류하기 위한 명목적 데이터 변수들로 이루어진 두 변수 간의 연관성을 계량적으로 파악하기 위한 통계적 기법들로, 분석 기법으로는 교차분석이라고 불리는 χ^2 검정을 이용한다. 수치적 데이터 변수와 달리 분류의 의미를 지닌 명목적 데이터 변수 간의 상관계수를 계산하는 것이 큰 의미가 있지 않다. 따라서 명목적 변수들로 구성된 분류표 상의 발생빈도를 기반으로 명목적 데이터 변수 간의 연관성을 추론하기 위한 χ^2 검정을 사용한다.

(3) 순서적 데이터 변수의 상관분석

순서가 중요한 의미가 있는 순서적 데이터 변수들로 이루어진 두 변수 간의 연관성

및 상관관계를 검정하기 위한 통계적 분석 기법들로, 예를 들면 고객의 매장방문 빈도와 월별 구매액 간의 상관관계를 파악하고자 하는 문제가 이에 해당한다. 주로 스피어만 순위 상관계수(Rank correlation coefficient)를 통해서 분석을 수행한다. 스피어만 순위 상관계수는 원 데이터 대신 이들의 순위를 이용하여 상관계수를 결정한다. 예를 들어 두 (수치형) 변수 x 와 y 에 대해 x 값들의 순위를 $r_1^x, r_2^x, \dots, r_n^x$, y 값들의 순위를 $r_1^y, r_2^y, \dots, r_n^y$ 라 할 때 스피어만 순위 상관계수 r_s 는

$$r_s = \frac{\sum_{i=1}^n (r_x^i - \bar{r}_x)(r_y^i - \bar{r}_y)}{\sqrt{\sum_{i=1}^n (r_x^i - \bar{r}_x)^2} \sqrt{\sum_{i=1}^n (r_y^i - \bar{r}_y)^2}} = 1 - \frac{6 \sum_{i=1}^n (r_x^i - r_y^i)^2}{n(n^2 - 1)}$$

와 같이 정의된다.

3. 회귀분석(regression analysis)

연속형 변수들에 대해 종속변수와 독립변수 간의 상관관계에 따른 수학적 관계식을 도출하여 어떠한 독립변수들의 값이 주어졌을 때 이에 따른 종속변수 값을 예측하고 이 수학적 관계식이 얼마나 관계를 잘 설명하고 있는지를 판별할 때도 활용되는 분석방법이다.

회귀분석 모델은 독립변수와 종속변수의 개수 및 형태에 따라서 다양한 세부 모델들로 분류한다. 단순회귀모형은 독립변수와 종속변수가 1개씩이며 모두 수치형 변수인 경우를 일컬으며, 2개 이상의 독립변수(수치형 혹은 범주형)와 1개의 수치형 종속변수에 대한 회귀분석 모델을 다중회귀모형이라 한다.

회귀분석 모델을 도출한 이후에는 이에 대한 적합성을 평가해야 한다. 먼저, 객관적으로 도출된 회귀식이 통계적으로 유의한지를 평가하기 위해 분산분석표를 활용한다. 모델이 얼마나 잘 설명력을 가지는 지를 확인하기 위해서는 결정계수 R^2 을 확인한다. 그리고 회귀분석 결과를 신뢰하고 효과적으로 활용하기 위해 다음과 같은 4가지 전제조건이 있다.

- 선형성: 독립변수와 종속변수 간에는 선형관계가 존재한다.
- 등분산성: 잔차(추정오차)들은 같은 분산을 갖는다.
- 독립성: 잔차들은 서로 독립이다.
- 정규성: 잔차는 평균이 0이고 분산이 σ^2 인 정규분포를 따른다.

이상의 가정들 만족 여부는 잔차들의 그래프를 통해 확인한다.

회귀모델은 종속변수와 이 변수와의 상관관계가 있는 독립변수들을 어떻게 선택하지는 중요한 사안이다. 독립변수 선택 방법으로는 후진 제거법, 전진 선택법, 단계별 선택법이 있다. 다음은 각각에 대해 알아본다.


- 후진 제거법(Backward elimination): 모든 독립변수를 사용하여 하나의 회귀식을 수립하고 회귀식에서 중요하지 않은 독립변수값들에 대한 검정을 한 후, 그 값이 가장 작

은 변수부터 차례로 제거하고 남은 나머지 독립변수들을 바탕으로 회귀식을 다시 추정하는 방법이다.

- 전진 선택법(Forward selection): 종속변수에 가장 큰 영향을 줄 것으로 판단되는 하나의 독립변수를 이용하여 회귀식을 수립한 후, 단계마다 중요하다고 판단되는 독립변수를 하나씩 회귀식에 추가하여 회귀모델을 다시 추정하여 새로운 독립변수의 부분검정을 통해 중요 정도를 계산하는 방법이다.
- 단계별 선택법(Stepwise selection): 본 선택법은 후진 제거법과 전진 선택법의 절충적인 형태로, 전진 선택법에 따라 종속변수에 가장 큰 상관관계가 있는 독립변수를 택함과 동시에 각 단계에서 후진 제거법과 같이 회귀식에서 중요하지 않은 독립변수를 제거하는 방법으로, 본 선택법이 가장 많이 활용되고 있다.

4. 분산 분석(Analysis of Variance, ANOVA)


두 개 이상의 집단 간 비교를 수행하고자 할 때 집단 내의 분산, 총 평균과 각 집단의 평균 차이에 의해 생긴 집단 간 분산 비교로 얻은 F 분포를 이용하여 가설검정을 수행하는 방법이다. 이때, 검정 통계량인 F -검정 통계량 값은 집단 내 분산 대비 집단 간 분산이 몇 배 더 큰지를 나타내는 값으로 해석된다. 따라서 분산 분석은 복수의 집단을 비교할 때 분산을 계산함으로써 집단 간에 통계적인 차이가 있다고 할 수 있는지, 혹은 차이가 없다고 할 수 있는지를 판정하는 분석방법이다. 분산 분석은 독립변수와 종속변수의 수에 따라서 일원분산 분석, 이원분산 분석, 다변량 분산 분석, 공분산 분석으로 나눌 수 있다. 일원분산 분석은 집단을 나누는 요인인 독립변수가 1개이고 종속변수도 1개인 경우로 독립변수에 의한 집단 사이의 종속변수 평균 차이를 비교하기 위한 분석이며, 이원분산 분석은 독립변수가 2개이고 종속변수가 1개일 경우에서의 집단 간 종속변수의 평균 차이를 분석하는 방법이다. 다변량 분석은 종속변수가 2개 이상인 경우에서 집단 간 종속변수의 평균 차이를 비교하는 방법이고, 마지막으로 공분산 분석은 연속형 외생변수가 종속변수에 미치는 영향을 제거한 후, 순수한 집단 간 종속변수의 평균 차이를 평가하는 방법이다.



[그림 2-2] 분산 분석

5. 주성분 분석(Principal Component Analysis, PCA)

많은 변수의 분산방식(분산·공분산)의 패턴을 간결하게 표현하는 주성분 변수를 원래 변수의 선형결합으로서 추출하는 통계기법이다. 주성분 변수는 원래 변수 정보를 축약한 변수이며, PCA는 일부 주성분에 의해 원래 변수의 변동이 충분히 설명되는지 알아보는 분석방법이다. 따라서 P 개의 변수가 있는 경우 이를 통해 얻은 정보를 P 보다 상당히 적은 K 개의 변수로 요약하는 것이다. 이로써 가장 적은 수의 주성분을 사용하여 분산의 최대량을 설명한다.



[그림 2-3] 주성분 분석

6. 판별 분석(discriminant analysis)

집단에 대한 정보로부터 집단을 구별할 수 있는 판별규칙 혹은 판별함수를 만들고, 다변량 기법으로 조사된 집단에 대한 정보를 활용하여 새로운 개체가 어떤 집단인지를 탐색하는 통계기법이다.

② 데이터 마이닝 빅데이터 분석모델 분류

대용량 데이터로부터 데이터 내에 존재하는 패턴, 관계 혹은 규칙 등을 탐색하고 통계적인 기법들을 활용하여 모델화하며 이를 통해 데이터 분석 및 더 나아가 유용한 정보, 지식 등을 추출하는 과정을 데이터 마이닝이라 한다. 데이터 마이닝은 기존 통계적 기법에서 주로 다루던 가설의 검정에 머무르는 것이 아니고, 더욱 확장하여 데이터로부터 의미 있는 새로운 가설 혹은 규칙 등을 찾아내는 통계기반 분석 기법들이라 볼 수 있으며, 데이터 마이닝 기법들은 예측, 분류, 군집화, 연관규칙 추출 등의 목적에 따라 구분할 수 있다.

1. 분류(classification) 및 분류모델

분류는 범주형 변수 혹은 이산형 변수 등의 범주를 예측하는 것이다. 즉, 다수의 속성 혹은 변수를 가지는 객체들을 사전에 정해진 그룹이나 범주 중의 하나로 분류하는 것을 말한다. 이러한 분류규칙을 생성하기 위해서는 훈련 데이터를 바탕으로 규칙을 생성하고 새로운 객체를 범주 중에 하나로 분류하는 데 있어 생성된 분류규칙에 따르게 된다. 효과적인 분류를 위한 분류모델은 크게 다음과 같이 구분할 수 있다.

(1) 통계적 방법

로지스틱 회귀분석, 판별 분석 등과 같은 다변량 통계이론에 근거한 방법들이 있다. 먼저 로지스틱 회귀분석은 선형 회귀 분석과 달리 종속 변수가 서열형, 범주형 혹은 명목형 데이터면 사용되는 기법으로, 분석대상이 두 개 혹은 그 이상의 집단으로 구분되는 경우에 개별 관측치들이 어느 집단에 분류될 수 있는지를 분석하고 이를 예측하는 모델을 개발하는 데 사용되는 통계기법이다.


(2) 트리기반 기법

트리형태의 분지방법을 이용하는 기법인 의사결정트리는 의사결정규칙에 따라 관심 대상이 되는 집단을 몇 개의 소집단으로 분류하는 분석 기법으로, 대표적으로 CART (Classification and Regression Trees) 알고리즘 등이 있다. CART 기법은 각 독립변수를 이분화하는 과정을 반복하여 이진트리 형태를 형성함으로써 분류를 수행하는 방법을 말한다. CART는

- ◆ 의사결정트리 형성: 훈련 데이터를 바탕으로 트리를 형성해나가는 과정으로 변수선택, 분지기준 결정 등을 수행
- ◆ 가지치기: 트리구조가 너무 복잡해지면 분류규칙 또한 복잡한 것을 의미하므로, 형성된 트리의 일부 가지를 절단하여 단순한 트리 구조를 생성. 이는 분류오류를 크게 할 위험이 크거나 부적절한 분류규칙을 가지고 있는 가지를 제거하는 것임.
- ◆ 분류: 최종적으로 완성된 트리를 바탕으로 분류규칙을 도출
과 같은 3단계 과정을 통해 진행된다.

(3) 최적화 기법


수리 최적화 기법을 통한 분류 모델로는 서포트 벡터 머신 기법 등이 있다. 서포트 벡터 머신은 데이터를 분리하는 초평면(hyperplane) 중에서 데이터들과 거리가 가장 먼 초평면을 선택하여 분리하는 확정적 모델 기반의 이진 선형 분류 방법으로, 최대 마진 분류기라고도 합니다. 여기서, 초평면에 가장 가까운 곳에 위치한 데이터를 서포트 벡터라고 합니다.



[그림 2-4] 서포트 벡터 머신

(4) 기계학습 기법

블랙박스 모델로 대표적으로 인공 신경망 모델을 들 수 있다. 인공 신경망 모델은 분류와 예측을 할 때 사용하는 분석방법으로, 인간의 뇌가 신경망의 신호전달체계를 통해 학습하는 방식을 모사한 데이터 마이닝 기법의 일종이다. 이 방법은 기대 출력 값과 실제 출력 값 간의 비교를 통해 계산된 오차를 시냅스 역할을 하는 노드에 가중치 조정으로 모델에 반영한다. 이와 같은 일련의 과정을 신경망 구조가 안정화될 때까지 반복함으로써 예측 혹은 분류 모델을 구축해간다. 이러한 오차들을 출력계층에서 입력계층으로 역방향으로 반영하는 역전파 알고리즘(back propagation algorithm)을 통해 모델을 안정화하며 학습 과정을 기계적으로 단축한다.



[그림 2-5] 인공 신경망 모델링 구조

2. 예측(prediction) 및 예측모델

예측은 미래의 예상되는 결과에 대해 다룬다는 것을 제외하면, 앞서 살펴보았던 분류 혹은 추정과 상당히 유사하다. 측정될 변수를 알고 이에 대한 과거 데이터가 존재한다면, 분류와 추정을 위한 대부분의 모델들이 예측에도 사용될 수 있다. 예측모델로는 회귀분석, 의사결정트리, 인공 신경망 모델, 시계열 분석 등을 포함한다.

(1) 시계열 분석

어떤 관측치 등의 데이터 변화를 시간의 움직임에 따라 이것을 계열화하였을 때, 이와 같은 데이터를 시계열이라 한다. 즉, 시계열 데이터는 관측치가 시간적 순서를 가지게 된다. 이러한 데이터를 통해 미래의 값을 예측하는 기법을 시계열 분석이라고 한다. 시계열 데이터 분석 기법들의 예로 다음과 같은 기법들이 있다.

- ◆ 분해법: 시계열을 추세, 순환, 계절 및 불규칙 변동으로 분해하여 각 변동을 추정하여 해석하는 방법을 말한다.
- ◆ 평활법: 과거와 현재 값의 (가중)평균으로 미래값을 예측하는 방법으로, 이동평균법, 지수 평활법 등이 있다.


- ◆ ARIMA (Auto-regressive Integrated Moving Average) 모델: 과거의 관측값과 오차를 사용해서 현재의 시계열 값을 설명하는 BOX-JENKINS 모델(ARMA)을 일반화한 것으로 시계열 데이터의 과거 치들이 설명변수인 AR과 과거의 오차항들이 설명변수인 MA 모델의 합성어이다.

3. 군집화(clustering) 및 군집화 모델

이질적인 집단을 몇 개의 동질적인 소집단으로 세분화하는 작업을 군집화라 한다. 즉, 유사한 속성들을 갖는 집단 내 객체들을 모아서 하나의 소집단을 구성하여 전체 집단을 몇 개의 군집으로 나누는 작업을 일컫는다. 군집화가 사전에 정의된 집단과 이들의 구분을 위한 사전정보가 존재하지 않는다는 점에서 분류와 구분된다. 군집방법은 크게 계층적 방법과 비 계층적 방법으로 구분한다. 계층적 방법은 사전에 군집 수를 정하지 않고 단계적으로 단계별 군집결과를 산출하는 방법으로, 각 객체를 하나의 소집단으로 간주하고 단계적으로 유사한 소집단들을 합쳐 새로운 소집단을 구성해가는 응집분석법과 그 반대로 전체 집단으로부터 시작하여 유사성이 떨어지는 객체들을 분리해가는 분할분석법이 있다. 반면, 비계층적 방법은 군집을 위한 소집단의 개수를 정해놓고 각 객체 중 하나의 소집단으로 배정하는 방법이다. 군집화 모델로 인공 신경망 모델, K 평균 군집화 등이 있다.

(1) K 평균 군집화

K 평균 군집화는 앞서 설명한 군집방법 중 대표적인 비 계층적 군집방법으로 K개 소집단의 중심좌표를 이용하여 각 객체와 중심좌표 간의 거리를 산출하고, 가장 근접한 소집단에 배정한 후 해당 소집단의 중심좌표를 업데이트하는 방식으로 군집화하는 방식이다.



[그림 2-6] 동일 데이터에 대해 K=2일 때와 4일 때의 K 평균 군집화 결과 예시

4. 연관규칙(association rule) 및 연관규칙 모델

연관규칙이란 데이터에 숨어있는 동시에 발생하는 사건 혹은 항목 간의 규칙 - 특히, ‘어떤 이벤트가 또 다른 어떤 이벤트를 동반하는가’ 를 표현 - 수치화하는 것이다. 연관 규칙분석 혹은 장바구니 분석은 주로 마케팅에 활용되는 기법으로 고객 구매데이터를 분석하여 어떠한 상품이 또 다른 어떠한 상품과 함께 판매될 확률이 높은가를 보여주는 연관규칙을 도출하는 기법이다.

③ 독립변수와 종속변수의 데이터 유형에 따른 분석 기법

독립변수와 종속변수가 주어져 있는 경우에는 이들을 이용하여 주어진 독립변수에 대한 종속변수의 값을 예측, 분류하는 분석모델을 개발하게 된다. 이때, 독립변수와 종속변수의 데이터 유형(연속형, 범주형)에 따라서 앞서 살펴본 다양한 통계적 혹은 데이터 마이닝 기반 분석 기법들의 분류가 가능하다. <표 2-1>은 독립변수와 종속변수의 데이터 유형에 따른 가능한 조합에 대해 앞서 살펴본 분석모델 중 어떠한 분석모델이 해당하는지를 분류하여 정리하였다.

<표 2-1> 독립변수와 종속변수의 데이터 유형에 따른 분석 기법들

		종속변수 (Y)	
		연속형	범주형
독립변수 (X)	연속형 변수	회귀분석 인공 신경망 모델 K-최근접 이웃기법	로지스틱 회귀분석 판별분석 K-최근접 이웃기법
	범주형 변수	회귀분석 인공 신경망 분석 회귀나무 기법	인공 신경망 모델 분류나무 로지스틱 회귀분석

독립변수 간의 혹은 독립변수 내의 관계를 탐색적으로 분석하여 의미 있는 정보를 추출하기 위한 분석 기법들이 이 경우에 해당한다. <표 2-2>는 이 경우에 해당하는 분석모델들을 독립변수의 데이터 유형에 따라 분류하였다.

<표 2-2> 종속변수가 없는 경우, 독립변수의 데이터 유형에 따른 분석 기법들

독립변수 (X)	
연속형 변수	범주형 변수
주성분 분석 군집분석	연관성 규칙 판별 분석
상관분석	

수행 내용 / 빅데이터 분석모델 설계하기

재료 · 자료

- 분석 대상 데이터

기기(장비 · 공구)

- 컴퓨터, 프린터
- R, SAS 등을 포함한 통계분석 소프트웨어
- 인터넷

안전 · 유의 사항

- 해당 없음

수행 순서

- ① 비즈니스 문제에 대한 명확한 이해를 바탕으로 데이터 분석 목적을 명확히 하고, 분석을 위한 데이터를 수집한다.

어떠한 목적을 가지고 주어진 빅데이터를 분석하는 것인지, 분석을 위해서 어떠한 데이터 수집이 가능한지를 알아본다. 특히 독립변수들이 무엇이며 종속변수는 존재하는지 여부 등을 확인한다.

② 통계 및 데이터 마이닝 빅데이터 분석모델을 선정한다.

분석 목적에 부합하고 수집된 데이터의 변수들을 고려하여 적합한 빅데이터 분석모델을 결정해야 한다.

③ 선정한 빅데이터 분석모델을 수집한 데이터에 적용하여 분석모델을 구축한다.

분석 목적에 부합하고 수집된 데이터의 변수들을 고려하여 적합한 빅데이터 분석모델을 결정해야 한다. 2-1절에서 살펴보았던 각 통계 및 데이터 마이닝 분석모델 중 몇 가지 모델들에 대해서 간단한 예제 및 관련 데이터들을 통해 어떻게 분석모델을 구축할 수 있는지 통계 패키지 R을 활용하여 살펴보도록 하자.

1. 기술통계 분석

R에서 기본적으로 제공하는 데이터 중 EuStockMarkets를 통해 다양한 기술 통계치 및 그 래프 등에 대해 살펴보도록 한다.

(1) 데이터 내용 및 구조 파악

데이터 분석에 앞서 데이터와 관련된 기본적인 내용들을 확인한다.

```
> data(EuStockMarkets) # 데이터 세트를 사용하기 위한 명령어
> dim(EuStockMarkets) # 데이터 세트의 구조를 파악 (row, column)
[1] 1860    4
> EuStockMarkets # 데이터 세트 이름을 입력하면 해당 데이터를 출력
Time Series:
Start = c(1991, 130)
End = c(1998, 169)
Frequency = 260
      DAX    SMI    CAC    FTSE
1991.496 1628.75 1678.1 1772.8 2443.6
1991.500 1613.63 1688.5 1750.5 2460.2
1991.504 1606.51 1678.6 1718.0 2448.2
1991.508 1621.04 1684.1 1708.1 2470.4
1991.512 1618.16 1686.6 1723.1 2484.7
1991.515 1610.61 1671.6 1714.3 2466.8
....
1991.573 1605.75 1721.2 1757.9 2595.0
1991.577 1616.67 1725.3 1756.6 2595.6
```

```

1991.581 1619.29 1727.2 1754.7 2588.8
1991.585 1620.49 1727.2 1766.8 2591.7
1991.588 1619.67 1731.6 1766.5 2601.7
1991.592 1623.07 1724.1 1762.2 2585.4
> EuStockMarkets[, 'DAX'] # 'DAX'에 해당하는 데이터만 출력하기 위함. 데이
터 세트[행, 열] 형식으로 입력하며, 입력칸을 비우면 전체선택을 의미
Time Series:
Start = c(1991, 130)
End = c(1998, 169)
Frequency = 260
[1] 1628.75 1613.63 1606.51 1621.04 1618.16 1610.61 1630.75
1640.17 1635.47 1645.89 1647.84 1638.35 1629.93 1621.49
1624.74 1627.63 1631.99 1621.18 1613.42 1604.95 1605.75
[22] 1616.67 1619.29 1620.49 1619.67 1623.07 1613.98 1631.87
1630.37 1633.47 1626.55 1650.43 1650.06 1654.11 1653.60
1501.82 1524.28 1603.65 1622.49 1636.68 1652.10 1645.81
...
[211] 1746.88 1747.47 1753.10 1745.17 1745.72 1742.92 1731.68
1731.18 1728.09 1728.09 1731.29 1733.82 1745.78 1752.57
1748.13 1750.70 1747.91 1745.79 1735.34 171

```

(2) 요약데이터 확인

데이터에 대한 대략적인 통계적인 수치 등 요약데이터를 확인한다.

```

> summary(EuStockMarkets) # 데이터 세트를 요약하여 출력 (각 칼럼별 요
약데이터) 출력
      DAX      SMI      CAC      FTSE
Min.   :1402  Min.   :1587  Min.   :1611  Min.   :2281
1st Qu.:1744  1st Qu.:2166  1st Qu.:1875  1st Qu.:2843
Median :2141  Median :2796  Median :1992  Median :3247
Mean   :2531  Mean   :3376  Mean   :2228  Mean   :3566
3rd Qu.:2722  3rd Qu.:3812  3rd Qu.:2274  3rd Qu.:3994
Max.   :6186  Max.   :8412  Max.   :4388  Max.   :6179
> # 분포 및 중심화 경향 확인
> mean(EuStockMarkets[, 'DAX']) # 'DAX'데이터의 평균
[1] 2530.657

```

```

> median(EuStockMarkets[, 'DAX']) # 'DAX'데이터의 중앙값
[1] 2140.565
> range(EuStockMarkets[, 'DAX']) # 'DAX'데이터의 범위
[1] 1402.34 6186.09
> summary(EuStockMarkets[, 'DAX']) # 중심화 경향 및 분포 파악
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1402   1744   2141   2531   2722   6186
> # 퍼짐정도 확인
> var(EuStockMarkets[, 'DAX']) # 'DAX'데이터의 분산 계산
[1] 1176775
> sd(EuStockMarkets[, 'DAX']) # 'DAX'데이터의 표준편차 계산
[1] 1084.793
> # 분포의 비대칭성 확인
> install.packages("fBasics") # 왜도 및 첨도를 위한 내장함수를 포함
한 패키지 fBasic 설치
> library(fBasics)
> skewness(EuStockMarkets[, 'DAX']) # 왜도
[1] 1.532785
attr(,"method")
[1] "moment"
> kurtosis(EuStockMarkets[, 'DAX']) # 첨도
[1] 1.560439
attr(,"method")
[1] "excess"

```


(3) 그래프를 통한 데이터의 이해

분석하고자 하는 데이터를 그래프 등을 통한 시각화 기법을 활용하여 데이터에 대한 이해도를 높인다.

```


> hist(EuStockMarkets[, 'DAX']) # 히스토그램

```




[그림 2-7] EuStockMarkets 데이터 중 'DAX'에 해당하는 데이터에 대한 히스토그램 (hist() 함수 수행 결과)

```
> boxplot(EuStockMarkets[, 'DAX']) # boxplot 그리기
```




[그림 2-8] EuStockMarkets 데이터 중 'DAX'에 해당하는 데이터에 대한 박스플롯 (boxplot() 함수 수행 결과)

```
> plot(EuStockMarkets[, 'DAX'], EuStockMarkets[, 'SMI']) # 두 변수 간의 산점도 출력
```



[그림 2-9] EuStockMarkets 데이터 중 'DAX'에 해당하는 데이터와 'SMI'에 해당하는 데이터 간의 산점도 (plot() 함수 수행 결과)

```
> plot(EuStockMarkets) # 시계열 데이터 출력
```



[그림 2-10] EuStockMarkets 데이터를 각 변수별 시계열 데이터 플롯 (plot() 함수 수행 결과)


2. 상관분석

R의 corr 함수를 통해 상관계수를 파악하고 그래프를 통해 독립변수 간의 상관관계 분석을 수행한다.

```

> cor(EuStockMarkets[, 'DAX'], EuStockMarkets[, 'SMI']) # 'DAX'데이
터와 'SMI'데이터간의 상관계수를 계산
[1] 0.9911539
> cor(EuStockMarkets)
      DAX      SMI      CAC      FTSE
DAX  1.0000000 0.9911539 0.9662274 0.9751778
SMI  0.9911539 1.0000000 0.9468139 0.9899691
CAC  0.9662274 0.9468139 1.0000000 0.9157265
FTSE 0.9751778 0.9899691 0.9157265 1.0000000
> # 상관계수 행렬 plot
> install.packages("corrplot")
> library(corrplot)
> CorrEuStockMarkets <- cor(EuStockMarkets) # 상관계수 행렬 계산
> corrplot(CorrEuStockMarkets, method="ellipse") # 상관계수 행렬
plot하는 함수로, method로는 ellipse 이외에도 circle, square, number,
shade, color, pie 등이 있음

```



[그림 2-11] EuStockMarkets 데이터의 변수들 간의 상관계수들에 대한 상관계수 행렬 플롯 (corrplot() 함수 수행 결과)

3. 주성분 분석

본 예제에서는 대표적인 훈련 데이터인 iris를 이용하여 주성분 분석을 수행한다. iris 데이터는 iris 꽃의 품종을 분류한 데이터이다. 총 4개의 변수로 구분되어 있으며 Sepal length(꽃받침 길이), Sepal width(꽃받침 폭), Petal length(꽃잎 길이), Petal width(꽃잎 폭)으로 구성되어 있다. 데이터 분석 알고리즘에서 가장 많이 활용되는 데이터 중 하나이다. iris는 총 3가지의 품종으로 구성되어 있으며 setosa, versicolor, virginica로 구분되어 있다. 이 데이터를 이용하여 주성분 분석(PCA)을 R 프로그램을 통해 수행하는 절차는 다음과 같다.

```
> data(iris) # iris 데이터를 사용하기 위한 코드
> iris.pca <- prcomp(iris[,1:4]) # iris데이터 중 1~4칼럼의 데이터로 PCA수행
> iris.pca # 주성분분석 결과 출력
Standard deviations:
[1] 2.0562689 0.4926162 0.2796596 0.1543862

Rotation:
               PC1          PC2          PC3          PC4
Sepal.Length  0.36138659 -0.65658877  0.58202985  0.3154872
Sepal.Width   -0.08452251 -0.73016143 -0.59791083 -0.3197231
Petal.Length  0.85667061  0.17337266 -0.07623608 -0.4798390
Petal.Width   0.35828920  0.07548102 -0.54583143  0.7536574
```

iris 데이터의 첫 번째 칼럼부터 네 번째 칼럼까지인 Sepal length, Sepal width, Petal length, Petal width 데이터를 이용해 PCA 분석을 수행하여 위와 같은 결과를 얻었다. 새로운 주성분은 PC1, PC2 등과 같은 형태로 명명되며 표준편차가 높은 순으로 출력된다.


```
> summary(iris.pca) # PCA 결과 요약
Importance of components:
               PC1          PC2          PC3          PC4
Standard deviation    2.0563 0.49262 0.2797 0.15439
Proportion of Variance 0.9246 0.05307 0.0171 0.00521
Cumulative Proportion 0.9246 0.97769 0.9948 1.00000
```

요약 정보를 보는 summary 명령어를 이용하면 보다 보기 쉽게 결과를 확인할 수 있다. 다음은 predict 명령어를 통해서 새로운 주성분으로 계산된 값을 구할 수 있다.

```
> iris.predict <- predict(iris.pca) # 주성분 점수 계산
> iris.predict[, 1:2] # 주성분 1과 주성분 2의 점수 출력
```

	PC1	PC2
[1,]	-2.684125626	-0.319397247
[2,]	-2.714141687	0.177001225
[3,]	-2.888990569	0.144949426
[4,]	-2.745342856	0.318298979
[5,]	-2.728716537	-0.326754513
[6,]	-2.280859633	-0.741330449
[7,]	-2.820537751	0.089461385
[8,]	-2.626144973	-0.163384960
[9,]	-2.886382732	0.578311754
[10,]	-2.672755798	0.113774246
[11,]	-2.506947091	-0.645068899
[12,]	-2.612755231	-0.014729939
[13,]	-2.786109266	0.235112000
[14,]	-3.223803744	0.511394587
[15,]	-2.644750390	-1.178764636

> biplot(iris.pca) # 주성분 1과 주성분 2를 이용한 산점도 출력



[그림 2-12] iris 데이터 변수들을 통해 도출된 주성분 1과 2 (PC1 및 PC2)를 이용한 산점도 (biplot() 함수 수행 결과)

biplot 함수를 이용한 결과인 [그림 2-10]을 통해 살펴보면, 크게 2개의 군집이 형성되는 것을 확인할 수 있다. 원 데이터는 총 3가지 종류가 있는 데이터이므로 다소 부족함이 느껴지지만, 기존 4개의 변수로 표현하는 것보다 새로운 주성분 2개로 이 정도 군집을 형성하는 것이라면 충분한 이점이 있다고 할 수 있다. 본 예제에서는 4개의 변수를 2개의 주성분으로 나타내어 그 차이가 크지 않은 것 같지만, 많은 변수를 가지고 있는 데이터는 2~3개의 주성분으로 군집을 표현하거나 그 외의 분석이 가능하다면 PCA 분석의 효용은 매우 크다고 할 수 있다.

4. 분류: 로지스틱 회귀분석

로지스틱 회귀분석은 독립 변수들의 선형 결합을 통해 사건의 발생 여부 등을 분류하기 위한 목적으로 사용되는 통계기법이다. 로지스틱 회귀분석은 선형 회귀분석과는 다르게 종속변수가 범주형인 데이터인 경우에 사용된다. 본 예제에서는 통계분석 소프트웨어 R에서 제공하는 mtcars 데이터를 이용하고자 한다. mtcars 데이터는 1974년에 Motor Trend US magazine의 데이터로, 32종류의 자동차를 10가지 항목을 조사한 데이터이며, 총 10가지 항목은 다음과 같다.

- mpg: 연비 (Miles/(US) gallon)
- cyl: 실린더 개수 (Number of cylinders)
- disp: 배기량 (Displacement (cu.in.))
- hp: 마력 (Gross horsepower)
- drat: 후방차축 비율 (Rear axle ratio)
- wt: 무게 (Weight (1,000 lbs))
- qsec: 1/4 마일에 도달하는데 소요되는 시간 (1/4 mile time)
- vs: 엔진 (0 = V engine, 1 = S engine)
- am: 변속기 (0 = 자동, 1 = 수동)
- gear: 기어 개수 (Number of forward gears)
- carb: 기화기 개수 (Number of carburetors)

먼저 로지스틱 회귀분석을 위하여 mtcars의 일부 데이터를 추출하고 이를 바탕으로 로지스틱 회귀분석 모델을 구축하는 예제를 살펴보고자 한다.

```

> data(mtcars) # mtcars dataset 사용을 위한 코드
> dat <- subset(mtcars, select=c(mpg, am, vs))
> dat

```

	mpg	am	vs
Mazda RX4	21.0	1	0
Mazda RX4 Wag	21.0	1	0
Datsun 710	22.8	1	1
Hornet 4 Drive	21.4	0	1
Hornet Sportabout	18.7	0	0
Valiant	18.1	0	1
Duster 360	14.3	0	0
Merc 240D	24.4	0	1
Merc 230	22.8	0	1
Merc 280	19.2	0	1
Merc 280C	17.8	0	1
Merc 450SE	16.4	0	0
Merc 450SL	17.3	0	0
Merc 450SLC	15.2	0	0
Cadillac Fleetwood	10.4	0	0
Lincoln Continental	10.4	0	0
Chrysler Imperial	14.7	0	0
Fiat 128	32.4	1	1
Honda Civic	30.4	1	1
Toyota Corolla	33.9	1	1
Toyota Corona	21.5	0	1
Dodge Challenger	15.5	0	0
AMC Javelin	15.2	0	0
Camaro Z28	13.3	0	0
Pontiac Firebird	19.2	0	0
Fiat X1-9	27.3	1	1
Porsche 914-2	26.0	1	0
Lotus Europa	30.4	1	1
Ford Pantera L	15.8	1	0
Ferrari Dino	19.7	1	0

Maserati Bora	15.0	1	0
Volvo 142E	21.4	1	1

vs를 종속변수로, mpg(연속형 독립변수)와 am(범주형 독립변수)으로 로지스틱 회귀분석 모델을 생성하고자 한다.

```
> log_reg <- glm(vs ~ mpg, data=dat, family="binomial") # 로지스틱
회귀분석 실행
> log_reg # 회귀분석 모델 확인
Call: glm(formula = vs ~ mpg, family = "binomial", data = dat)

Coefficients:
(Intercept)      mpg
      -8.8331      0.4304

Degrees of Freedom: 31 Total (i.e. Null); 30 Residual
Null Deviance:      43.86
Residual Deviance: 25.53      AIC: 29.53
> summary(log_reg) # 회귀분석 모델 요약정보 확인
Call:
glm(formula = vs ~ mpg, family = "binomial", data = dat)

Deviance Residuals:
      Min       1Q   Median       3Q      Max
-2.2127  -0.5121  -0.2276   0.6402   1.6980

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  -8.8331     3.1623  -2.793  0.00522 **
mpg           0.4304     0.1584   2.717  0.00659 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 43.860  on 31  degrees of freedom
```

Residual deviance: 25.533 on 30 degrees of freedom

AIC: 29.533

Number of Fisher Scoring iterations: 6

로지스틱 회귀분석 모델에서는 glm() 함수를 사용한다. glm() 함수를 이용해서 모델을 만든 뒤 summary 함수를 통해 모델의 결과를 확인한다. 결과에서 p-value가 0.05보다 작은 변수는 통계적으로 유의미하다고 해석할 수 있는 변수들이다.

5. 예측: ARIMA 모델


이번 예제에 사용될 데이터는 AirPassengers 데이터로 1949년부터 1960년 사이에 매월 항공기 탑승승객수를 나타낸 데이터 세트이다. 이 데이터를 활용하여 ARIMA 모델을 적용하여 예측모델을 만들고자 한다.

(1) 데이터의 확인 및 이해

먼저 데이터를 살펴봄으로써 데이터에 대한 이해도를 높인다.


```
> data(AirPassengers)
> AirPassengers

  Jan Feb Mar Apr May Jun Jul Aug Sep Oct Nov Dec
1949 112 118 132 129 121 135 148 148 136 119 104 118
1950 115 126 141 135 125 149 170 170 158 133 114 140
1951 145 150 178 163 172 178 199 199 184 162 146 166
1952 171 180 193 181 183 218 230 242 209 191 172 194
1953 196 196 236 235 229 243 264 272 237 211 180 201
1954 204 188 235 227 234 264 302 293 259 229 203 229
1955 242 233 267 269 270 315 364 347 312 274 237 278
1956 284 277 317 313 318 374 413 405 355 306 271 306
1957 315 301 356 348 355 422 465 467 404 347 305 336
1958 340 318 362 348 363 435 491 505 404 359 310 337
1959 360 342 406 396 420 472 548 559 463 407 362 405
1960 417 391 419 461 472 535 622 606 508 461 390 432
> plot(AirPassengers)
```



[그림 2-13] AirPassengers 시계열 데이터에 대해 시간에 따른 항공기 탑승객 수에 대한 플롯 (plot() 함수 수행 결과)

```
> plot(stl(AirPassengers, s.window='periodic')) # 계절성
(seasonality), 추세 (trend), 불확실성 (random) 요소로 분해해서 그래프를 확인할 수 있다.
```




[그림 2-14] AirPassengers 시계열 데이터에 대해 계절성, 추세 및 불확실성으로 분해한 결과 플롯

또 이상의 시계열 데이터를 diff()함수와 log()함수 등을 활용하여 안정적인 시계열 데이터로 변환할 수 있다.

```

> install.packages("tseries")
> library(tseries)
> difflogAirPassengers <- diff(log(AirPassengers))
> plot(difflogAirPassengers)

```



[그림 2-15] AirPassengers 시계열 데이터에 diff 및 log함수를 적용한 데이터 플롯

변환한 결과물이 안정적인 시계열 데이터인지 아닌지를 tseries 패키지 내 `adf.test()` 함수로 확인할 수 있다.

```

> adf.test(difflogAirPassengers, alternative="stationary",
k=0)

```

Augmented Dickey-Fuller Test

```

data: difflogAirPassengers
Dickey-Fuller = -9.6003, Lag order = 0, p-value = 0.01
alternative hypothesis: stationary

```

이상의 결과를 통해 `difflogAirPassengers` 데이터 세트가 안정적인 시계열 데이터임을 확인할 수 있다.

(2) 예측 모델 생성

ARIMA 모델은 AR 모델과 MA 모델을 결합한 것으로 세 가지 파라미터 p , d , q 가 필요하다. 파라미터를 구하기 위해서는 KPASS test 4, ACF, PACF를 실제 그려서 적절한 파라미터를 찾아야 하지만, 이와 같은 작업을 자동으로 해주는 `auto.arima` 함수를 사용하면 p , d , q 를 자동으로 구해낼 수 있다.

```

> install.packages("forecast")
> library(forecast)
> auto.arima(difflogAirPassengers)
Series: difflogAirPassengers
ARIMA(1,0,1)(0,0,2)[12] with zero mean

Coefficients:
          ar1          ma1          sma1          sma2
      0.7033   -0.8898   0.8256   0.6999
s.e.  0.0873   0.0446   0.0778   0.1085

sigma^2 estimated as 0.003326:  log likelihood=197.56
AIC=-385.12   AICc=-384.68   BIC=-370.31

```

위에서 구한 파라미터를 기준으로 `log(AirPassengers)` 데이터 세트를 대상으로 하는 ARIMA 모델을 생성한다.

```

> fitted <- arima(log(AirPassengers), c(1, 0, 1), seasonal =
list(order = c(0, 1, 1), period = 12))
> fitted

Call:
arima(x = log(AirPassengers), order = c(1, 0, 1), seasonal =
list(order = c(0,
1, 1), period = 12))


Coefficients:
          ar1          ma1          sma1
      0.9959   -0.3994   -0.5526
s.e.  0.0050   0.0898   0.0741

sigma^2 estimated as 0.001345:  log likelihood = 245.61,  aic =
-483.22

```

ARIMA 모델을 생성한 뒤 향후 10년(120개월)간의 데이터를 예측해본 후 (predicted 변수에 저장됨), 기존 데이터 (AirPassengers)와 예측치를 이어서 그래프로 표현한다.

```
> predicted <- predict(fitted, n.ahead = 120)
> ts.plot(AirPassengers, exp(predicted$pred), lty = c(1,2)) #
predicted$pred 항목에 log(AirPassengers)의 예측치 값이 저장
```



[그림 2-16] AirPassengers 데이터를 바탕으로 생성한 ARIMA 모델 기반 10년 예측 데이터 플롯

[그림 2-16] 그래프에서 점선으로 표시된 부분이 예측치 이다.

6. 군집화: K 평균 군집화

이번 예제에서는 앞서 살펴보았던 iris 데이터를 이용하여 K 평균 군집화 모델을 구축하도록 한다.

(1) 군집 수 K 결정


군집화를 수행하기 전에 먼저 군집 수 K를 결정해야 한다. K-평균 군집화를 수행하기 위해서는 먼저 K값을 결정하고 각 군집에 대한 초기 군집 중심을 결정해야 한다. 초기 군집중심에 가까운 개체들이 해당 군집으로 소속되고 이후 소속된 개체들을 반영하여 군집 중심 값이 갱신된다. 이와 같은 과정을 반복하여 최종적으로 K 평균 군집화가 이루어진다. 군집 수 결정은 실루엣값을 이용하는데 실루엣 폭(Silhouette width) 값이 가장 큰 값을 찾아 군집 수로 결정하는 방법이 보편적이다.

```
> install.packages("cluster")
> library(cluster)
> data(iris)
```

```

> nc2=pam(iris, 2) # 데이터를 2개로 군집화 시행
> si2 = silhouette(nc2) # 실루엣값 계산
> summary(si2)
Silhouette of 150 units in 2 clusters from pam(x = iris, k = 2)
:
Cluster sizes and average silhouette widths:
      50      100
0.8397480 0.6039286
Individual silhouette widths:
      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-0.08665  0.62090  0.69790  0.68250  0.82490  0.88480
> plot(si2) # 실루엣 계산 결과 출력

```



[그림 2-17] iris 데이터를 K=2인 군집화 수행 후 실루엣 계산 결과에 대한 플롯

summary 평균값 및 [그림 2-17] 하단에 Average silhouette width 값을 확인할 수 있다. iris 데이터에서 군집을 2로 했을 때는 실루엣값이 0.68이다. 군집을 3으로 하는 경우 위와 같은 과정을 통해 다음과 같은 결과를 얻을 수 있다.

```

> nc3=pam(iris, 3); si3=silhouette(nc3);
> summary(si3)
Silhouette of 150 units in 3 clusters from pam(x = iris, k = 3)

```



```
"tot.withinss" "betweenss"  
[7] "size"          "iter"          "ifault"
```

위 결과에서도 확인할 수 있지만, iris 데이터는 setosa, versicolor, virginica 세 종류의 iris 꽃을 분류한 데이터로 실제 군집 수를 3으로 가정하고 K 평균 군집화를 수행한 경우가 더욱 정확도가 높다. 실루엣값이 2가 높게 나왔지만, 실제의 군집은 2가 아닐 수도 있다는 점을 인지하고, 실루엣값으로 군집화를 수행하되, 그 결과를 반드시 다시 확인해봐야 한다.

수행 tip

- 각 통계 및 데이터 마이닝 기반 빅데이터 분석모델별 특징 및 장단점을 이해하고 이를 바탕으로 분석 목적 및 분석대상 데이터 세트에 적합한 분석 기법을 선택하는 연습이 필요하다.

2-2. 빅데이터 분석모델 확장 및 활용

학습 목표

- 주어진 데이터 변수 추가하여 모델에서 필요한 파생변수(Derived Variable)를 생성하여 모델링에 활용할 수 있다.
- 단일 분석 기법이 아닌 앙상블(Ensemble) 기법을 적용하여 모델의 품질목표를 제고할 수 있다.
- 데이터 분석 모델링의 원활한 수행과 결과보고를 위하여 데이터 시각화를 사용할 수 있다.

필요 지식 /

① 파생변수 생성 및 추가를 통한 분석모델의 확장

파생변수는 기존 변수에 특정 조건 혹은 함수 등을 사용하여 새롭게 재정의한 변수를 의미한다. 기존 데이터 이외에 분석모델에서 필요로 하는 파생변수를 생성·추가하여 분석모델에 활용할 수 있다. 이러한 파생변수를 생성하는 방법에 대해 몇 가지 소개를 하면 다음과 같다:

1. 단위의 변환

주어진 변수의 단위 혹은 척도를 변환하여 새로운 단위로 표현함으로써 파생변수를 생성할 수 있다.

2. 표현형식의 변환

날짜정보를 바탕으로 요일을 도출한다든지, 남/여와 같이 성별로 표현된 데이터를 0/1과 같은 이진 변수로 변환하는 등 단순한 표현방법의 변환을 통해 파생변수를 생성할 수 있다.

3. 요약 통계량을 통한 변환

고객별 누적방문횟수를 계산하는 것과 같이 요약 통계량 등을 활용하여 파생변수를 생성할 수 있다.

4. 여러 변수의 결합을 통한 변환

기존 데이터의 변수들을 다양한 함수 등을 이용한 수학적 결합을 통해 새로운 변수를 정의하는 방식으로 파생변수를 생성할 수 있다. 예를 들면 매출액과 방문횟수 데이터를 이용하여 1회 평균매출액을 나타내는 파생변수를 생성할 수 있다. 또 앞서 살펴본 주성분 분석은 주어진 독립변수들의 선형조합으로 새로운 변수를 생성하는 것이므로, 이 또한 여러 변수의 결합을 통해 파생변수를 생성하는 방법으로 볼 수 있다.

② 앙상블(Ensemble) 기법을 활용한 분석모델의 확장

개별적인 분석모델을 결합하여 더 좋은 성능을 얻기 위해 다수의 분석모델을 사용하는 방법을 앙상블 기법이라 한다. 일반적으로 분석모델에 의한 오류는 편향(bias)과 분산(variance)으로 구분할 수 있는데, 편향은 반복적인 모델 학습 시 평균적으로 얼마나 정확한 추정이 가능한지에 대한 측정 지표이고, 분산은 반복적인 모델 학습 시 개별 추정이 얼마나 차이가 크게 나타나는지에 대한 측정 지표이다. 예를 들어 로지스틱 회귀분석, K-최근접 이웃 기법(K가 클 때) 등은 편향이 크고 분산이 작은 분석모델들이지만, 인공 신경망 모델, 서포트 벡터 머신 등은 편향이 작고 분산이 큰 분석모델들이다. 이처럼 각 분석모델은 서로 다른 사고방식 체계, 특징 및 장단점 등을 가지고 있어 단일 알고리즘 보다 여러 알고리즘을 결합하면 성능이 향상되는 경우가 많다. 따라서 앙상블 기법은 다수의 분석모델을 학습하여 오류감소를 추구한다. 앙상블 기법들로는 분산의 감소에 의한 오류 감소를 위한 배깅(Bagging), 랜덤 포레스트(Random forest), 편향의 감소에 의한 오류 감소를 위한 부스팅(Boosting) 등이 있다.

③ 데이터 시각화를 활용한 분석모델의 활용

빅데이터 분석 전 과정에서 활용이 가능한 데이터 시각화는 데이터 분석 결과를 더욱 쉽게 이해할 수 있도록 시각적인 수단을 통해 정보를 전달하는 과정을 의미한다. 데이터 분석 결과값들을 그래프 혹은 그림과 같은 시각적인 도구를 통해 의사 결정자에게 제공함으로써 데이터 분석결과를 쉽게 이해할 수 있도록 하고 주요결과 및 아이디어를 효과적으로 전달한다.

수행 내용 / 빅데이터 분석모델 확장 및 활용하기

재료 · 자료

- 분석 대상 데이터

기기(장비 · 공구)

- 컴퓨터, 프린터
- R을 포함한 통계분석 소프트웨어
- 인터넷

안전 · 유의 사항

- 해당 없음

수행 순서

① 파생변수를 활용하여 분석모델을 확장한다.

파생변수를 생성하는 다양한 방법이 존재하며, 본 예제에서는 ‘표현방식의 변환’에서 데이터의 내용을 이진 변수로 표현하는 예제를 살펴보고자 한다. 예를 들어 고객의 연령 정보가 있을 때 이를 10대, 20대, 30대, 40대와 50대 여부를 표현하는 파생변수들로 생성하고자 한다. 먼저 고객 id와 연령으로 구성된 데이터 세트를 생성한다.

```
> id <- c("c01", "c02", "c03", "c04", "c05", "c06", "c07")
> age <- c(25, 45, 31, 30, 49, 53, 27)
> customers <- data.frame(id, age, stringsAsFactors = F)
> customers
  id age
1 c01 25
2 c02 45
3 c03 31
4 c04 30
5 c05 49
6 c06 53
7 c07 27
> sapply(customers, class)
```

id	age
"character"	"numeric"

기존 데이터 세트에 ifelse() 함수를 이용하여 고객 연령에 해당하는 나잇대를 이진 변수로 표시하는 파생변수들을 추가하여 분석 시 이 파생변수들을 활용할 수 있게 된다.

```
> customers <- transform(customers,
+                           age20s = ifelse(age >= 20 & age < 30, 1, 0),
+                           age30s = ifelse(age >= 30 & age < 40, 1, 0),
+                           age40s = ifelse(age >= 40 & age < 50, 1, 0),
+                           age50s = ifelse(age > 50 & age < 60, 1, 0))
> customers
  id age age20s age30s age40s age50s
1 c01  25      1      0      0      0
2 c02  45      0      0      1      0
3 c03  31      0      1      0      0
4 c04  30      0      1      0      0
5 c05  49      0      0      1      0
6 c06  53      0      0      0      1
7 c07  27      1      0      0      0
```

위 결과에서 살펴보았듯이 기존 데이터 세트에 age20s, age30s, age40s, age50s과 같은 파생변수가 생성된 것을 확인할 수 있다.

② 앙상블 기법들을 활용하여 분석모델을 확장한다.

1. 배깅 (Bagging)

배깅(Bagging)은 Bootstrap aggregating의 줄임말로 주어진 데이터에 대해서 여러 개의 부트스트랩 자료를 생성하고 각 부트스트랩 자료를 모델링 한 후 결합하여 최종 예측 모델을 산출하는 방법이다. 여기서 부트스트랩이란 단순 복원 임의추출법을 통해 원 데이터로부터 크기가 동일한 여러 개의 표본 데이터 세트를 말하는 것이다. 배깅은 예측 모델의 변동성이 큰 경우 예측모델의 변동성을 감소시키기 위해 사용한다. 본 예제는 R에서 제공하는 iris 데이터를 이용하여 배깅에 대해 알아보도록 하자. 먼저 iris 데이터 적재 후 분석 모델을 생성한다.

```
> data(iris)
> train_index <- c(sample(1:50, 25), sample(51:100, 25), sample(101:150,
```

```

25)) # 총 150개 iris 데이터 중 임의로 2개의 데이터 세트로 나눈다.
> library(adabag) # 배깅을 위한 R 패키지 로딩
> bagging_iris <- bagging(Species ~ ., data = iris[train_index, ],
mfinal = 10, control = rpart.control(maxdepth = 1)) # 10개의 트리로
구성된 배깅 모델을 구축
> bagging_iris # 결과 출력
$formula
Species ~ .

$trees
$trees[[1]]
n= 75

node), split, n, loss, yval, (yprob)
      * denotes terminal node

1) root 75 45 virginica (0.3733333 0.2266667 0.4000000)
   2)  Petal.Length<  2.7   28      0   setosa   (1.0000000   0.0000000
0.0000000) *
   3)  Petal.Length>=2.7   47   17   virginica   (0.0000000   0.3617021
0.6382979) *
   :
$votes
      [,1] [,2] [,3]
[1,]    4    2    4
[2,]    5    4    1
[3,]    4    4    2
[4,]    5    2    3
[5,]    1    4    5
   :
$prob
      [,1] [,2] [,3]
[1,]  0.4  0.2  0.4
[2,]  0.5  0.4  0.1

```

```

[3,] 0.4 0.4 0.2
[4,] 0.5 0.2 0.3
[5,] 0.1 0.4 0.5
:
$class
[1] "setosa" "setosa" "setosa" "setosa" "virginica"
[6] "setosa" "versicolor" "versicolor" "virginica"
"virginica"
:
$importance
Petal.Length Petal.Width Sepal.Length Sepal.Width
70.42792 29.57208 0.00000 0.00000

$terms
Species ~ Sepal.Length + Sepal.Width + Petal.Length + Petal.Width
:
> predict_bagging_iris <- predict.bagging(bagging_iris, newdata =
iris[-train_index, ]) # 앞서 생성한 배깅모델을 활용하여 새로운 데이터에
대한 예측 수행

```

이상의 수행 코드 중, bagging_iris를 수행하면 다양한 정보가 제공되는데 tree 항목에서는 배깅에 사용된 10개의 트리 모델에 대한 정보가 출력되고, votes 항목에서는 각 모델을 통해 예측된 투표결과, prob 항목에서는 예측 확률 결과를 확인할 수 있다. 이 예제에서 두 번째 인스턴스의 투표 결과는 5, 4, 1이고 이에 따른 확률은 50%, 40%, 10%이며 이 결과로 setosa로 예측되었다. 이번 예제에서는 4개의 변수 중에서 Petal.Length의 중요도가 가장 높게 평가되었으며 수치는 70.43%임을 알 수 있다.

2. 부스팅(Boosting)

부스팅은 잘못 분류된 개체들에 관심을 가지고 이들을 더 잘 분류하기 위해서 잘못 분류된 개체들에 집중하여 새로운 분류 규칙을 만드는 단계를 반복하는 방법이다. 부스팅의 특징은 예측변수를 차례로 생성하는 것이다. 처음 원 데이터의 객체들에서는 동일한 가중치에서 시작하지만, 모델링을 통한 예측변수에 의해 오 분류된 개체들에는 높은 가중치를 부여하고, 정 분류된 객체들에는 낮은 가중치를 부여하여 오 분류된 객체들이 더 잘 분류되도록 하는 방법이다. 다시 말하면 부스팅은 예측모델의 정확도를 향상하는 방법의 하나이다. 본 예제에서도 역시 총 150개 iris 데이터에 대해 부스팅 방법에 대해 알아보자.

```

> data(iris)
> train_index <- c(sample(1:50, 25), sample(51:100, 25), sample(101:150,
25)) # 총 150개 iris 데이터 중 임의로 2개의 데이터 세트로 나눈다.
> library(adabag) # 부스팅을 위한 R 패키지 로딩
> boosting_iris <- boosting(Species ~ ., data = iris[train_index,
], mfinal = 10, control = rpart.control(maxdepth = 1)) # 부스팅을 위
한 10개의 트리가 생성되고 데이터를 기반으로 순차적 학습이 시작
> boosting_iris # 결과 출력
$formula
Species ~ .

$trees
$trees[[1]]
n= 75

node), split, n, loss, yval, (yprob)
      * denotes terminal node

1) root 75 45 virginica (0.3200000 0.2800000 0.4000000)
  2)  Petal.Length< 2.5 24 0 setosa (1.0000000 0.0000000
0.0000000) *
  3)  Petal.Length>=2.5 51 21 virginica (0.0000000 0.4117647
0.5882353) *
  :
$weights
[1] 0.3465736 0.4406868 0.4639693 0.2513264 0.4151887 0.4474916
0.2932033
[8] 0.3856933 0.2191410 0.3944527

$votes
      [,1] [,2] [,3]
[1,] 2.3375968 1.320130 0.0000000
[2,] 2.3375968 1.320130 0.0000000
[3,] 2.3375968 1.320130 0.0000000

```

```

[4,] 2.3375968 1.320130 0.0000000
[5,] 2.3375968 1.320130 0.0000000
:
$prob
      [,1]      [,2]      [,3]
[1,] 0.6390846 0.3609154 0.00000000
[2,] 0.6390846 0.3609154 0.00000000
[3,] 0.6390846 0.3609154 0.00000000
[4,] 0.6390846 0.3609154 0.00000000
[5,] 0.6390846 0.3609154 0.00000000
:
$class
[1] "setosa"      "setosa"      "setosa"      "setosa"      "setosa"
[6] "setosa"      "setosa"      "setosa"      "setosa"      "setosa"
:
$importance
Petal.Length Petal.Width Sepal.Length Sepal.Width
      50.86487      49.13513          0.00000          0.00000

$terms
Species ~ pesos + Sepal.Length + Sepal.Width + Petal.Length +
      Petal.Width
:
>      predict_boosting_iris      <-      predict.boosting(boosting_iris,
newdata = iris[-train_index, ]) # 앞서 생성한 부스팅 모델을 활용하여 새
로운 데이터에 대한 예측 수행

```

이상의 수행 코드 중, `boosting_iris`를 수행하면 부스팅 결과물을 출력하게 되며 생성된 10개 모델의 세부 내용이 출력된다. 에러율이 낮은 모델이 가중치가 높게 책정되며 이는 `weights` 항목으로 확인할 수 있다. 이번 예제에서는 3번 모델이 가중치가 가장 높으며 6, 2, 5 순서의 가중치가 계산되었다. 가중치가 가장 낮은 모델은 9번으로 0.219이다. `votes` 항목과 `prob` 항목에서는 특정 인스턴스의 클래스가 결정되는 과정을 확인할 수 있다. `vote` 항목은 10개의 모델을 통해서 어느 클래스에 속하는지 투표한 결과를 나타낸 것으로 이것을 바탕으로 `prob` 항목에서 확률이 계산된다. 이 예제에서는 첫 번째 인스턴스의 투표 결과는 2.3375968, 1.320130, 0.0000000, 이에 따른 확률로는 63.9% 36.1% 0.0%로 계산

되었고 이것으로 첫 번째 클래스인 setosa로 결정된 것을 확인할 수 있다.

3. 랜덤 포레스트(Random forest)

랜덤 포레스트는 여러 개의 의사결정트리를 임의로 학습하는 앙상블 방법이다. 다른 모델에 비해 속도가 현저히 빠르고 성능도 좋은 편이다. 분류 및 회귀문제 모두 다 양호한 성능을 나타낸다. 랜덤 포레스트는 두 가지 방법을 사용해서 다양한 의사결정트리를 만든다. 첫 번째는 의사결정트리를 만들 때 데이터를 복원추출로 샘플링 하여 해당 데이터에 대한 모델을 만들어가는 방식이다. 모델을 만들어 나갈 때 모든 데이터를 사용하지 않고 일부 데이터만을 사용하는 것이 특징이다. 두 번째는 노드 내에 데이터를 분기할 때 사용되는 기준을 정할 때 전체 변수를 대상으로 분기하는 것이 아니라 일부 변수에 대해서 분기를 시도하여 여러 의사결정트리를 생성한다. 여러 개의 의사결정트리 모델이 만들어지면 이들의 결과들을 종합하여 다수결(majority voting) 방식 등을 이용하여 최종값을 산출한다. 다음은 R에서 randomForest 패키지를 이용하여 랜덤 포레스트 기법을 적용하는 예제를 살펴보도록 한다.

```
> data(iris)
> index <- sample(2,nrow(iris),replace=TRUE,prob=c(0.7,0.3)) # 훈련 데이터
# 세트(1)과 검증 데이터 세트(2) 구분을 위해 7:3의 비율로 무작위 샘플링 수행
> training_data <- iris[index==1,]
> testing_data <- iris[index==2,]
> library(randomForest) # 랜덤 포레스트를 위한 R 패키지 로딩
> rf_iris <- randomForest(Species~., data=training_data, ntree=100,
proximity=TRUE) # 100개의 의사결정트리를 통해서 랜덤 포레스트를 학습
> rf_iris # 결과 확인
```

Call:

```
randomForest(formula = Species ~ ., data = trainData, ntree =
100, proximity = TRUE)
```

Type of random forest: classification

Number of trees: 100

No. of variables tried at each split: 2

OOB estimate of error rate: 2.63%

Confusion matrix:

	setosa	versicolor	virginica	class.error
setosa	34	0	0	0.00000000
versicolor	0	41	0	0.00000000

```
virginica      0      3      36 0.07692308  
> predicted_iris <- predict(rf_iris, newdata=testing_data) # 랜덤  
포레스트 모델을 이용하여 testing_data를 예측
```

수행 tip

- 파생변수를 생성하기 위한 다양한 방법에 대해 추가로 숙지하도록 한다.

교수 방법

- 통계적 분석기반 빅데이터 분석모델들에 대해 개념, 원리, 방법론에 관해 설명한다.
- 데이터 마이닝 기반 빅데이터 분석모델별로 분석목적(분류, 예측, 군집 등)별 기법들에 관해 개념, 원리, 방법론을 설명한다.
- 분석모델의 독립변수와 종속변수의 데이터 유형 및 종속변수 유무에 따라 통계 혹은 데이터 마이닝 기반 빅데이터 분석모델들이 어떻게 분류될 수 있을지 설명한다.
- 파생변수를 생성하거나 앙상블 기법들을 활용하여 빅데이터 분석모델 확장할 수 있음을 설명한다.

학습 방법

- 통계적 분석기반 빅데이터 분석모델들에 대해 개념, 원리, 방법론에 대해 학습한다.
- 데이터 마이닝 기반 빅데이터 분석모델별로 분석목적(분류, 예측, 군집 등)별 기법들에 대해 개념, 원리, 방법론을 학습한다.
- 분석모델의 독립변수와 종속변수의 데이터 유형 및 종속변수 유무에 따라 통계 혹은 데이터 마이닝 기반 빅데이터 분석모델들을 분류할 수 있도록 숙지한다.
- 파생변수를 생성하는 방법 및 앙상블 기법들을 숙지하여 빅데이터 분석모델을 확장할 수 있음을 숙지한다.

학습2 평 가

평가 준거

- 평가자는 학습자가 학습 목표를 성공적으로 달성하였는지를 평가해야 한다.
- 평가자는 다음 사항을 평가해야 한다.

학습 내용	평가 항목	성취수준		
		상	중	하
빅데이터 분석모델 설계	- 설정된 가설을 검증하기 위하여 분석모델을 설계할 수 있다.			
	- 모델을 완성도를 평가하기 위한 성능평가 기준을 설정할 수 있다.			
	- 모델에 적용하는 독립변수와 종속변수의 데이터 유형에 따라 다양한 분석 기법을 적용할 수 있다.			
빅데이터 분석모델 분석	- 주어진 데이터 변수 추가하여 모델에서 필요로 하는 파생변수(derived variable)를 생성하여 모델링에 활용할 수 있다.			
	- 단일 분석 기법이 아닌 앙상블(Ensemble) 기법을 적용하여 모델의 품질목표를 높일 수 있다.			
	- 데이터 분석 모델링의 원활한 수행과 결과보고를 위하여 데이터 시각화를 사용할 수 있다.			

평가 방법

- 평가자 질문

학습 내용	평가 항목	성취수준		
		상	중	하
빅데이터 분석모델 설계	- 통계적 분석기반 빅데이터 분석모델들에 대해 개념, 원리, 방법론에 대한 이해도			
	- 데이터 마이닝 빅데이터 분석모델들에 대해 분석목적(분류, 예측, 군집 등)별 분석 기법들에 대해 개념, 원리, 방법론에 대한 이해도			
	- 분석모델의 독립변수와 종속변수의 데이터 유형 및 종속변수 유무에 따른, 통계 혹은 데이터 마이닝 기반 빅데이터 분석모델들 분류에 관한 이해도			
빅데이터 분석모델 분석	- 파생변수를 생성하는 방법 및 앙상블 기법들에 대한 이해도 및 빅데이터 분석모델 확장 방안에 대한 이해도			

• 문제해결 시나리오

학습 내용	평가 항목	성취수준		
		상	중	하
빅데이터 분석모델 설계	- 통계적 분석기반 빅데이터 분석모델(기술통계, 상관 분석, 회귀분석, 분산분석, 주성분 분석, 판별분석)별로 데이터를 입력했을 때 R 통계프로그램을 활용하여 분석을 수행할 수 있는 능력			
	- 특정 데이터가 주어졌을 때 분석의 목적에 따라 데이터 마이닝 빅데이터 분석모델 중 적절한 방법론을 선택하고 방법론에 따라 분석을 수행하기 위해 R 통계 프로그램을 활용할 수 있는 능력			
	- 분석 결과를 적절하게 해석하고 모델의 적합성 여부를 판단할 수 있는 능력			

피드백

1. 평가자 질문

- 통계기반 혹은 데이터 마이닝 기반 빅데이터 분석모델들 각각에 대해 각 분석 기법의 개념을 제대로 이해하고 있는지, 각각의 분석 기법들의 세부적인 방법론들을 통계 패키지 혹은 개발언어들을 활용하여 실제 데이터에 적용, 분석할 수 있는지에 대해 그 이해도를 확인한다. 만일 이를 이해하지 못한 학생들에게는 관련 자료 수집 및 요약하는 과제를 요구하거나 혹은 기법별로 간단한 데이터와 예시를 활용한 실습을 통하여 이해도를 높일 수 있다.
- 예측 분석모델 확장을 위해 파생변수를 활용하는 방법과 앙상블 기법들에 대해 세부 개념과 적용방법에 대해 명확히 이해하고 있는지 대해 확인한다. 만일 이를 이해하지 못한 학생들에게는 관련 자료 수집 및 요약하는 과제를 요구하거나 혹은 추가 예시를 통해 이해도를 높일 수 있다.

2. 문제해결 시나리오

- 분석목적 및 적용한 분석모델에 따라서 R 통계프로그램을 통한 분석결과를 어떻게 해석할지에 어려움을 느낄 시에는 각 결과치가 나타내는 의미를 상기시키고 분석목적 및 상황에 따라서 그 결과를 어떻게 해석하는 것이 좋을지, 결과가 고무적인지 아닌지 등에 대해 스스로 고민하고 이해할 수 있도록 지도한다.

학습 1	가설 설정하기(LM2001010506_15v1.1)
학습 2	빅데이터 모델 개발하기(LM2001010506_15v1.2)
학습 3	빅데이터 모델 평가 검증하기 (LM2001010506_15v1.3)
학습 4	빅데이터 모델 운영방안 마련하기 (LM2001010506_15v1.4)

3-1. 빅데이터 분석모델 평가

학습 목표

- 구현된 모델은 모델 운영의 안정성과 적합성을 평가할 수 있다.
- 설정되어 있는 모델의 평가 절차 및 기준에 따라 구현된 모델을 평가할 수 있다.
- 모델 평가를 위한 데이터 세트는 훈련 데이터 세트와 구분, 관리되어 평가의 객관성을 확보할 수 있다.
- 모델 평가의 전 과정을 절차에 따라 진행되었음을 증적으로 확보해야 하고 모델 평가결과를 리포팅 할 수 있다.

필요 지식 /

① 훈련, 평가, 검증 데이터 세트

일반적으로 통계분석을 통해 좋은 결과를 얻으려면 표본조사를 할 때 전체를 대표할 수 있는 좋은 샘플을 취하고, 그 샘플로부터 전체를 잘 설명할 수 있는 모델을 만들어야 한다. 이와 같이 빅데이터 분석모델은 분석목적에 부합하는 적절한 모델이 선택되어야 함과 동시에 정확도 높은 모델을 만들기 위한 모델의 인자 값들을 찾아내기 위한 훈련 데이터의 질에 따라 학습 결과가 좌우된다.


일반적으로 데이터 세트는 훈련 데이터 세트, 검증 데이터 세트 등의 2개 혹은 훈련 데이터 세트, 평가 데이터 세트, 검증 데이터 세트 등의 3개의 분할 데이터 세트를 사용한다. 데이터를 훈련, 평가, 검증 데이터 세트로 나누는 작업은 미리 결정된 비율에 따라서 무작위로 나누는 등 다양한 방식으로 이루어진다. 각 데이터 세트의 목적에 대해 간단히 기술하면 다음과 같다.

- 훈련 데이터 세트: 일반적으로 가장 큰 데이터 세트로서 분석대상인 다양한 모델을 구축하기 위해 사용되는 데이터를 말한다. 다수의 모델을 개발하기 위해 일반적으로 동일한 훈련 데이터 세트가 사용된다.
- 평가 데이터 세트: 모델을 비교하여 가장 좋은 모델을 선택하기 위해 각각의 모델의 성과를 평가하기 위해 사용되는 데이터 세트이다.

- 검증 데이터 세트: 새로운 데이터를 가지고 선택된 모델의 성능을 평가할 용도로 사용되는 데이터 세트이다.

② 과적합(overfitting)

과적합이란 제한된 훈련 데이터 세트(모델 훈련에 사용한 한정된 데이터)에 너무 과하게 특화되어 새로운 데이터에 대한 오차가 매우 커지는 경우를 말한다.



[그림 3-1] 훈련 데이터 세트가 (a)와 같이 주어졌을 때의 과적합 예시

과적합의 의미를 위의 그림을 통해 살펴보자. (a)와 같은 훈련 데이터가 존재한다고 가정하자. (b)와 같이 단순히 직선으로 추정하는 경우는 훈련 데이터뿐만 아니라 실제 데이터에서도 오차가 클 수 있음을 알 수 있다. 반면, (d)의 경우를 살펴보면 예측모델 함수가 훈련 데이터 세트 상의 모든 데이터를 오차가 없이 추정하는 경우이다. 이 같은 경우, 새로운 데이터가 주어지는 경우는 오차가 커질 확률이 높다. (c)를 (b)와 (d)의 경우와 비교해보았을 때, 비록 약간의 오차가 존재하지만 예측모델이 훈련 데이터 세트 상의 데이터에 대한 특성을 잘 나타내고 있으며 새로운 데이터에 대해서도 좋은 결과가 나올 가능성이 높음을 알 수 있다. 이렇듯 빅데이터 분석모델을 구축하면서 과적합의 문제는 항상 존재한다고 볼 수 있으나 이를 해결하는 방법 또한 마땅치 않은 것이 현실이다. 이는 분석모델을 만드는 데 사용되는 훈련 데이터 세트는 실제 데이터의 부분집합이며, 훈련 데이터 세트만을 가지고 실제 데이터의 오차가 증가하는 지점을 정확히 예측하는 것 또한 불가능하기 때문이다.

③ 예측 빅데이터 분석모델 성능평가를 위한 검사 방법

빅데이터 분석모델을 선택하고 모델을 적용한 이후 모델의 성능 및 적합성, 안정성 등을 평가하는 과정은 빅데이터 분석 프로세스에서 핵심 단계 중 하나이다. 본 절에서는 빅데이터 모델 중 예측모델의 성능 평가를 위한 다양한 방법들에 대해 살펴보고자 한다.

1. 예측 오차

훈련 데이터 세트로부터 구축된 예측모델을 검증 데이터 세트의 독립변수들로 구성된 데이터를 예측모델에 적용하여 예측한 종속변수 값 $\hat{y}_i$ 과 검증 데이터 세트의 실제 종속변수

값 y_i 와 비교를 하여 예측오차 $y_i - \hat{y}_i$ 를 산출하는 척도로, 평균 절대편차(Mean Absolute Deviation; MAD), 평균제곱오차(Mean Squared Error; MSE), 표준오차(Root Mean Square error; RMS), 평균 절대 백분 오차 비율(Mean Absolute Percentage Error; MAPE) 등이 있다. 검증 데이터 세트 집합을 L , 이들의 데이터 크기를 n 라 하자.

(1) 평균절대 오차(Mean Absolute Error; MAE)

MAE는 예측 오차의 절대값들 평균을 나타내는 방법으로

$$MAE = \frac{1}{n} \sum_{y_i \in L} |y_i - \hat{y}_i|$$

와 같이 정의한다. 예측 오차의 절대값을 사용함으로써 +오차와 -오차가 다양하게 발생하더라도 오차 간 상쇄효과를 예방할 수 있으며 계산이 쉽고 이해가 용이하다.

(2) 평균제곱 오차(Mean Squared Error; MSE)

MSE는 예측 오차를 제곱하여 이를 합한 뒤 n 으로 나누어 계산된 평균값으로

$$MSE = \frac{1}{n} \sum_{y_i \in L} (y_i - \hat{y}_i)^2$$

와 같이 정의한다. 평균제곱 오차를 사용하면 큰 오차는 더욱 크게 반영되고 작은 오차는 상대적으로 적게 반영된다.

(3) 표준 오차(Root Mean Square error; RMS)

RMS는 평균제곱오차(MSE)의 제곱근 값으로 다음과 같이 정의한다.

$$RMS = \sqrt{\frac{1}{n} \sum_{y_i \in L} (y_i - \hat{y}_i)^2}$$

MSE로 예측오차를 평가하게 될 때 그 수치가 커지는 것을 제곱근을 취함으로써 보정한 값이다.

(4) 평균 절대 백분 오차 비율(Mean Absolute Percentage Error; MAPE)

MAPE는 실제 종속변수 값 대비 예측오차 비율의 절대값 들을 평균한 값으로 실제 데이터에서 오차가 어느 정도의 비율로 발생했는지 확인하려는 방법으로,

$$MAPE = \frac{1}{n} \sum_{y_i \in L} \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

와 같이 정의한다.

2. 교차 유효성(cross validation) 검사

보유하고 있는 데이터의 크기가 작아서 검증 데이터 세트를 분리해내기가 여의치 않으면 교차 유효성 기법을 사용한다. K-겹 교차검증(K-fold cross validation)이란 전체 데이터를 K 등분한 후 그 중 K-1 데이터 세트를 훈련 데이터 세트로 모델을 구축하고, 나머지 1개의 데이터 세트를 검증 데이터 세트로 구축된 모델을 검증함으로써 총 K 번의 모델구출과 검증을 할 수 있고 각 경우에서 예측 오차를 산출한 후 이들의 평균치를 최종 사용하

게 된다. 예를 들어 3-겹 교차검증의 경우, 전체 데이터를 3등분(각각을 데이터 세트 1, 2, 3이라 하자) 한 후, 데이터 세트 1과 2를 훈련 데이터 세트로 예측모델을 만들고 데이터 세트 3을 검증 데이터 세트로 이용하여 예측 오차를 산출한다. 그리고 다시 데이터 세트 1과 3을 훈련 데이터 세트로 예측모델을 만든 후 데이터 세트 2를 검증 데이터 세트로 하여 예측 오차를 산출하고 마지막으로 데이터 세트 2와 3을 훈련 데이터 세트로 예측모델 구축하고 데이터 세트 1을 검증 데이터 세트로 간주하여 예측 오차를 산출한다. 3번에 걸쳐 계산된 예측 오차들의 평균을 최종 예측 오차로 이용하는 방법이다.

④ 분류 빅데이터 분석모델 성능평가를 위한 검사 방법

본 절에서는 분류규칙에 대한 성능평가 검사방법에 대해 알아보도록 한다.

1. 분류오류율 검사

분류오류율은 분류규칙을 통해 추정된 범주와 실제 범주가 일치하지 않는 비율(잘못 분류된 데이터의 비율)을 의미한다. 훈련 데이터 세트로 구축된 분류모델을 검증 데이터 세트를 활용하여 분류오류율을 검사하고 성능을 평가한다. 데이터 크기가 충분하지 않으면 앞서 언급했던 교차 유효성 검사방법을 적용할 수 있으며 예측 오차 대신 분류오류율을 산출하여 평균 분류오류율을 최종 분류오류율로 이용할 수 있다.

2. 혼동 행렬(Confusion matrix) 검사

혼동 행렬은 일종의 정오 분류표로, 참과 거짓으로 분류하는 분류규칙을 가진 모델에 대해 다음과 같은 혼동 행렬을 만들 수 있다.

<표 3-1> 혼동 행렬의 구성

		예측	
		참	거짓
실제	참	진양성 (True Positive; TP)	가음성 (False Negative; FN)
	거짓	가양성 (False Positive; FP)	진음성 (True Negative; TN)

여기서 “진 (True)”의 의미는 실제와 예측이 일치하는 경우이며, “가 (False)”의 의미는 실제와 예측이 불일치함을 의미한다.

혼동행렬 <표 3-1>에서 진양성(TP), 가양성(FP), 가음성(FN), 진음성(TN)에 해당하는 각 셀에서는 각 경우에 해당하는 관측 수(훈련 데이터 세트를 활용)를 입력하게 되며 이를 통해 분류규칙 성능과 관련한 다양한 정보를 얻을 수 있게 된다. 예를 들어 TP의 경우 참으

로 예측했는데 실제 종속변수도 참인 경우의 데이터 수와 FN의 경우 거짓으로 예측했는데 실제 종속변수 값은 참인 경우의 데이터 수를 입력한다.

이러한 정보를 바탕으로 오류율, 정확도, 민감도, 특이도 등과 같은 정보를 계산할 수 있다.

(1) 오류율

오류율은 전체 데이터 수에서 잘못 분류한 데이터 수의 비율을 나타내는 것으로 식으로 표현하면 다음과 같다.

$$\text{오류율} = \frac{FP + FN}{TP + FP + FN + TN}$$

참고로 이는 앞서 살펴본 “분류오류율” 과 동일하다.

(2) 정확도(accuracy)

정확도는 전체 중에서 올바르게 실제 범주를 추정한 전체비율을 나타내는 것으로 오류율과는 상반되는 개념이다. 정확도는 다음과 같은 식에 의해 산출된다.

$$\text{정확도} = \frac{TP + TN}{TP + FP + FN + TN} = 1 - \text{오류율}$$

(3) 민감도(sensitivity)

민감도는 실제 참인 경우를 참으로 분류하여 판정하는 비율(특정 질병에 대해 실제 질병이 있는 경우를 양성으로 판정하는 비율)을 나타내는 것으로 식으로 표현하면 다음과 같다.

$$\text{민감도} = \frac{TP}{TP + FN}$$

(4) 특이도(Specificity)


특이도는 실제 거짓인 경우를 거짓으로 분류하여 판정하는 비율(특정 질병에 대해 실제 질병이 없는 경우를 음성으로 판정하는 비율)을 나타내는 것으로 식으로 표현하면 다음과 같다.

$$\text{특이도} = \frac{TN}{FP + TN}$$

3. ROC(Receiver Operating Characteristic) 곡선 검사

ROC 곡선은 분류모델의 판단결과의 성능을 보여주는 그래프로, 민감도와 특이도 간의 관계를 표현한 그래프이다. 일반적으로 민감도와 특이도는 반비례적인 관계(민감도가 올라가면 특이도는 내려가는 등)에 있으므로 이 둘을 동시에 높이는 것은 어려운 일이다. 따

라서 이 두 값을 어떠한 기준을 가지고 연속적으로 변경해가면서 측정한 후, 이들 간의 관계를 한눈에 볼 수 있게 한 것이 ROC 곡선으로, 민감도를 y축으로 (1-특이도)를 x축으로 하는 그래프이다.



[그림 3-2] ROC 곡선

[그림 3-2]에서 보는 바와 같이 ROC 곡선이 북서쪽 코너에 가까울수록 분류모델의 성능이 우수함을 의미하고, 45도 각도의 직선에 다가갈수록 분류 성능이 나쁘다고 말할 수 있다. 이와 같은 내용을 바탕으로 ROC 곡선을 통한 정량적인 성능분석 척도를 AUC(Area Under the Curve)라 한다. AUC는 ROC 곡선의 아래 면적을 계산한 값으로써 ROC 곡선이 북서쪽에 가까워질수록 AUC 값이 1에 가까워지며 AUC 값이 1에 가까워질수록 분류성능이 우수하다고 말할 수 있다. 반면 AUC 값이 0.5에 다가갈수록 분류성능이 나빠진다고 할 수 있다. 이를 통해 문제 상황별로 어떠한 지점을 기준으로 민감도와 특이도를 동시에 고려한 기준을 잡을지 합리적인 결정하는 데 도움을 줄 수 있다.

⑤ 군집 빅데이터 분석모델 성능평가를 위한 검사 방법

본 절에서는 군집 모델에 대한 성능평가 검사방법을 알아보도록 한다. 군집 모델에 대한 평가는 앞서 살펴보았던 분류 모델에 대한 분석과 다르게 객체들이 속한 군집에 대한 적절한 종속변수가 존재하지 않기 때문에 임의의 군집 해에 대한 성능을 평가하는 것이 쉽지 않다. 독립변수들이 2개 혹은 3개인 저차원의 데이터면 그래프를 통한 도식화로 성과악이 어느 정도 가능하지만 그 이상의 고차원 데이터에 대한 군집해의 평가는 도식화가 불가능하므로 수치상으로 표현한 정량화된 평가척도가 필요하게 된다. 이를 위해 일반적으로 군집이 얼마나 잘 되었나를 측정하는 방법으로 내부 평가와 외부 평가가 있다.

1. 내부 평가

내부 평가는 외부 정보에 대한 도움 없이 데이터 세트를 군집한 결과 그 자체로만 평가하는 척도이다. 내부 평가에서는 한 군집 내에서는 유사도가 높을수록, 군집 사이에는 유사도가 낮을수록 군집모델의 성능이 높은 것으로 간주한다. 데이터 세트의 군집해만 놓고 판단을 하는 내부 평가방식은 제안된 평가점수가 높다 할지라도 실제 참값에 가깝다는 것을 보장하지는 않는다.

(1) 던 지수(Dunn Index)

군집 간의 거리가 멀수록, 군집 내에 데이터 간의 거리가 가까울수록(즉, 군집 내 밀도가 높고 군집이 잘 나누어질수록) 큰 값을 가지는 던 지수는 다음과 같이 정의한다.

$$DI = \frac{\min_{1 \leq i < j \leq n} d(i, j)}{\max_{1 \leq k \leq n} \hat{d}(k)}$$

로 $d(i, j)$ 는 군집 i 와 j 간의 거리, $\hat{d}(k)$ 는 군집 k 내 데이터 간의 거(군집 k 내 데이터 간의 최대거리)를 의미한다.

(2) CH 지수(CH Index)

Calinski와 Harabasz(1974)는 CH 지수를 제안하였으며, 이 또한 던 지수와 마찬가지로 군집 내 밀도가 높고 잘 나뉜 군집 해를 좋은 군집해로 평가하는 방법이다. 예를 들어 평가하고자 하는 군집해가 K 개의 군집으로 구성되어 있다고 가정하자. 이때, n 을 데이터 세트의 개수, C_k 를 군집 k , n_k 를 군집 k 의 데이터 수, c_k 를 군집 k 의 중심좌표, c 를 전체 데이터들의 중심좌표, $d(x, y)$ 를 두 데이터 x 와 y 간의 거리라 하자. 이때 CH 지수는

$$CH = \frac{\frac{1}{K-1} \sum_{k=1}^K n_k d(c_k, c)}{\frac{1}{n-K} \sum_{k=1}^K \sum_{x \in C_k} d(x, c_k)}$$

와 같이 정의된다. 분모는 군집의 밀집도를, 분자는 군집 간의 분리성을 나타내어 던 지수와 같이 CH 지수 또한 값이 클수록 군집이 잘 이루어진 해로 간주한다.

2. 외부평가

외부평가는 군집화에 사용되지 않는 데이터를 가지고 군집 해를 평가하는 방법을 말한다. 즉, 군집 해를 전문가들이 구성한 군집해 또는 기존에 잘 알려진 군집해 결과물을 이용하여 군집모델을 통해 얻은 군집해와 기존에 알려진 해와의 유사성을 바탕으로 군집모델의 성능을 평가하게 된다.

(1) 랜드지수(Rand Index; RI)

랜드지수는 군집모델을 통해 얻은 군집해와 기존에 알려진 군집해 사이에서 일치되는

데이터 쌍의 비율로 나타낸다. 예를 들어 n 개의 데이터로 구성된 데이터 세트는 $\binom{n}{2}$ 개의 데이터 쌍이 존재한다. 여기서, 기존에 알려진 군집 해는 $C_1 = \{C_{11}, C_{12}, \dots, C_{1k}\}$ 과 같이 k 개의 군집으로 구성되어 있다고 하고, 반면 평가하고자 하는 군집모델로부터 얻어진 군집 해는 $C_2 = \{C_{21}, C_{22}, \dots, C_{2l}\}$ 와 같이 l 개의 군집으로 구성된 해라고 가정하자. 각 데이터 쌍에 대해서 다음과 같은 4가지 경우에 해당하는 데이터 쌍 개수를 구한다.

- $CN_{+1+2} = C_1$ 내 군집별 데이터 쌍에 대해 C_2 의 임의의 군집에 해당 데이터 쌍이 포함되는 데이터 쌍의 개수
 - $CN_{+1-2} = C_1$ 내 군집별 데이터 쌍에 대해 C_2 의 임의의 군집에 해당 데이터 쌍이 포함되지 않는 데이터 쌍의 개수
 - $CN_{-1+2} = C_2$ 내 군집별 데이터 쌍에 대해 C_1 의 임의의 군집에 해당 데이터 쌍이 포함되지 않는 데이터 쌍의 개수
 - $CN_{-1-2} = C_1$ 과 C_2 내 임의의 군집에도 동시에 포함되지 않는 데이터 쌍의 개수
- 이들의 값을 바탕으로 랜드지수를 구하면 다음과 같다:

$$RI = \frac{CN_{+1+2} + CN_{-1-2}}{CN_{+1+2} + CN_{+1-2} + CN_{-1+2} + CN_{-1-2}}$$

(2) 자카드 지수(Jaccard Index; JI)

자카드 지수는 $\frac{CN_{+1+2}}{CN_{+1+2} + CN_{+1-2} + CN_{-1+2}}$ 와 같이 정의되며 비교 대상 두 군집 해에 적어도 한쪽의 군집에 포함되는 데이터 쌍의 개수 대비 두 군집해 동시에 하나의 군집에 포함되는 데이터 쌍의 개수를 나타낸 지수이다.

수행 내용 / 빅데이터 분석모델 평가하기

재료 · 자료

- 분석 세부 계획 수립을 위한 조직 내/외부 정보
- 통계 및 연구방법론 관련 도서/논문

기기(장비 · 공구)

- 컴퓨터, 프린터
- R을 포함한 빅데이터 분석도구
- 인터넷

안전 · 유의 사항

- 해당 없음

수행 순서

① 예측모델의 경우 예측 오차, 교차 유효성 검사 등을 이용하여 모델 성능을 평가한다.

훈련 데이터 세트를 가지고 구축된 예측모델을 검증 데이터 세트를 이용하여 예측모델의 성능을 평가한다. 평가방법은 앞서 설명한 예측 오차, 교차 유효성 검사 등이 있다. 다음은 검증데이터 세트를 이용하여 예측 오차 및 교차 유효성 검사를 통한 예측모델 성능평가 방법 예시를 살펴보고자 한다.

1. 예측 오차를 통한 예측모델 성능 평가


본 예제에서는 임의의 시계열 데이터가 주어졌을 때 훈련 데이터 세트와 검증 데이터 세트로 구분하고, 훈련 데이터 세트를 활용하여 ARIMA 모델을 생성 한다. 이 후, 검증 데이터 세트를 이용하여 MAE, MSE, MAPE 등과 같은 예측오차를 통해 ARIMA 모델의 성능을 평가하고자 한다. 먼저 [그림 3-3]과 같은 시계열 데이터가 주어졌다고 가정하자.

	A	B
1	time	value
2	1	32.11
3	2	32.05
4	3	32.02
5	4	31.96
6	5	31.99
7	6	32.07
8	7	32.15
9	8	32.13
10	9	32.14
11	10	32.04
12	11	32.05
13	12	31.96
14	13	32.09
15	14	32.12
16	15	32.11
17	16	32.01
18	17	32.12
19	18	32.07
20	19	32.04
21	20	32.02

[그림 3-3] example.csv 파일 저장
내용 예시

먼저 [그림 3-3]에 해당하는 데이터 세트를 저장하고 있는 csv 파일을 불러온다.

```
> install.packages("forecast")
> library(forecast)
> ex_data = read.csv("example.csv", header=TRUE)
> plot(ex_data)
```




[그림 3-4] example.csv에 저장된 시계열 데이터 플롯

다음은 데이터를 훈련 데이터 세트가 검증 데이터 세트로 구분한다.

```
> training_data = ex_data[1:293, 2] # 총 318 데이터 중 처음 293개의 데이터를
훈련 데이터 세트로 설정
> testing_data = ex_data[294:318, 2] # 나머지 25개의 데이터를 검증 데이터
세트로 설정
```

다음은 각각의 데이터 세트를 시계열 형식으로 변환한다.

```
> training_timeseries = ts(training_data, frequency = 1)
> testing_timeseries = ts(testing_data, frequency = 1)
> plot.ts(training_timeseries)
```



[그림 3-5] 시계열 데이터로 변환된 훈련 데이터에 대한 plot.ts()의 수행결과 플롯

다음은 훈련 데이터 세트를 바탕으로 ARIMA 예측 모델을 생성하고 Akaike 정보척도 (Akaike Information Criterion; AIC)를 이용하여 최선의 ARIMA 모델을 선택한다.

```
> max_p = 5      # 최대 ARIMA p 값
> max_q = 5      # 최대 ARIMA q 값

> # 각 p, q 값별로 AIC 값을 계산
> AIC_set = matrix(0, nrow = (max_p+1), ncol = (max_q+1))
> for (p in 0:max_p)
+ {
+   for (q in 0:max_q)
+   {
+       model = arima(training_timeseries, order = c(p,1,q),
method = "ML")
```

```

+     AIC_set[(p+1), (q+1)] = model$aic
+   }
+ }
> # AIC 값을 최소화 하는 p와 q 값을 선택
> which(AIC_set == min(AIC_set), arr.ind = TRUE)
      row col
[1,]    4    4

```

p=4이고 q=4인 경우가 최적의 경우이므로 이를 바탕으로 훈련 데이터 세트를 이용하여 ARIMA 모델을 생성하고, 생성된 모델을 바탕으로 이후 25개 데이터에 대한 예측치 결과를 얻는다.

```

> model = arima(training_timeseries, order = c(4,1,4))
> forecasted = forecast.Arima(model, h=25) # 25개 데이터에 대한 예측

```

다음은 실제 데이터와 ARIMA 모델을 통해 예측된 예측치 간의 비교를 MAE, MSE, MAPE 기준으로 성능평가를 수행한다.

```

> MAE_result = mean(abs(testing_data - forecasted$mean)) #MAE
> MSE_result = mean((testing_data - forecasted$mean)^2) # MSE
> MAPE_result = mean(abs(testing_data - forecasted$mean) /
testing)*100 # MAPE
> MAE_result
[1] 0.05559373
> MSE_result
[1] 0.003787759
> MAPE_result
[1] 0.1740622

```

위 결과에서 보인바와 같이 ARIMA 모델이 예측한 25개 예측 치와 검증 데이터 세트 간의 예측 오차를 MAE, MSE, MAPE 기준으로 각각 0.056, 0.0038, 0.1740과 같음을 알 수 있다.

2. 교차 유효성 검사를 통한 예측모델 성능 평가

본 예제에서는 R에서 제공하는 iris 데이터를 사용하며, 데이터 내 다른 변수들을 이용하여 Sepal Length를 예측하는 랜덤 포레스트 모델을 생성한다. 이때 교차 유효성 검사방법을 통해 예측모델의 성능을 평가한다. 먼저 iris 데이터를 불러온다.

```

> library(plyr)
> library(randomForest)

```

```
> data <- iris
```

다음은 K=5인 교차 유효성 검사를 위해 1부터 5까지의 인덱스를 관측치 개수만큼 샘플링하여 K개의 데이터 세트를 훈련 데이터 세트와 검증 데이터 세트로 구분하여 번갈아가면서 테스트를 진행한다.

```
> k = 5
> data$id <- sample(1:k, nrow(data), replace = TRUE) # 1부터 5까지
의 인덱스를 관측치 개수만큼 샘플링
> list <- 1:k
> prediction <- data.frame()
> testing_data_copy <- data.frame()
> for (i in 1:k){
+   # id가 i인 데이터를 제외한 나머지 데이터들을 훈련 데이터 세트를 구성
+   # id가 i인 데이터를 검증 데이터 세트를 구성
+   training_data <- subset(data, id %in% list[-i])
+   testing_data <- subset(data, id %in% c(i))
+
+   # 랜덤 포레스트 모델을 수행
+   mymodel <- randomForest(training_data$Sepal.Length ~ ., data
= training_data, ntree = 100)
+
+   # 열 1에 해당하는 Sepal.Length를 제거
+   temp <- as.data.frame(predict(mymodel, testing_data[, -1]))
+   # 현 반복단계에서의 예측값을 prediction 값에 덧붙임
+   prediction <- rbind(prediction, temp)
+
+   # 현 반복단계에서의 검증 데이터 세트를 testsetCopy 값에 덧붙임
+   testing_data_copy <- rbind(testing_data_copy, as.data.frame
(testing_data[, 1]))
+ }
```

마지막으로 교차 유효성 검사를 통해 얻은 예측치를 검증 데이터 세트값과 비교를 통해 성능평가를 수행하기 위해 앞서 살펴본 예측오차 MAE, MSE, MAPE 등을 기준으로 예측 성능을 평가한다.

```
> colnames(prediction) = "p"
```

```

> colnames(testing_data_copy) = "t"
> MAE_result = mean(abs(prediction$p - testing_data_copy$t))
> MSE_result = mean((prediction$p - testing_data_copy$t)^2)
> MAPE_result = mean(abs(prediction$p - testing_data_copy$t) /
testing_data_copy$t)*100

```

② 분류모델의 경우 분류오류율, 혼동행렬, ROC 곡선 기법 등을 이용하여 모델 성능을 평가한다.

분류모델도 예측모델의 경우와 마찬가지로 검증 데이터 세트를 이용하여 분류모델의 성능을 평가한다. 분류모델의 성능평가 방법으로는 앞서 살펴본 바와 같이 분류오류율, 혼동행렬, ROC 곡선 기법 등이 있으며, 다음은 혼동행렬과 ROC 곡선 기법을 통해 모델 성능을 검증하는 방법에 대해 살펴보려고 한다.

1. 혼동행렬을 통한 분류모델 성능 평가

예를 들어, 주어진 분류모델을 가지고 검증 데이터 세트 내 10,000개의 데이터를 활용하여 다음과 같은 혼동 행렬을 구했다고 하자.

		예측		
		참	거짓	합
실제	참	9644	252	9896
	거짓	23	81	104
	합	9667	333	10,000

이때 오류율과 정확도는 다음과 같다.

- 오류율 = $(252 + 23)/10,000 = 0.028$
- 정확도 = $1 - 0.028 = 0.9725$

그리고 민감도와 특이도는 다음과 같이 계산된다.

- 민감도 = $9644 / (9644 + 252) = 0.9746$
- 특이도 = $81 / (23 + 81) = 0.7788$

2. ROC 곡선 기법을 통한 분류모델 성능 평가

R을 이용하여 ROC 곡선 기법 적용 예제를 살펴보도록 하자. ROC 곡선은 ROCR 라이브러리를 이용하여 확인해볼 수 있다. 간단하게 ROCR에서 제공하는 데이터 ROCR.simple 데이터 세트를 이용하여 ROC 곡선을, 그리고 AUC 값을 확인해보자. 참고로 ROCR.simple 데이터는 실제 분류 유형을 나타내는 \$labels 항목 (이진 값)과 이에 대한 예측값 혹은 확률을 나타내는 \$predictions 항목 (수치형)으로 구성되어 있다.

```


> install.packages("ROCR")
> library(ROCR)

```

```

> data(ROCR.simple)
> predict_simple <- prediction(ROCR.simple$predictions,
ROCR.simple$labels)
> perf_simple <- performance(predict_simple,"tpr","fpr")
> plot(perf_simple)
> abline(a=0, b=1) # 북동쪽 코너에서 남서쪽 코너를 잇는 직선을 표시

```



[그림 3-6] R의 ROCR 라이브러리를 활용한 ROC 곡선 예시

ROCR에서 제공되는 데이터를 이용하여 예측한 모델의 AUC 값은 y.values 항목을 통해 0.834로 확인 가능하다.

```

> performance(predict_simple,"auc")
An object of class "performance"
Slot "x.name":
[1] "None"

Slot "y.name":
[1] "Area under the ROC curve"

Slot "alpha.name":
[1] "none"

```

```
Slot "x.values":
list()

Slot "y.values":
[[1]]
[1] 0.8341875

Slot "alpha.values":
list()
```

- ③ 군집모델의 경우 내부평가(던 지수, CH 지수 등) 혹은 외부평가(랜드 지수, 자카드 지수 등) 등을 이용하여 모델 성능을 평가한다.

1. 내부 평가를 이용한 군집모델 성능 평가

(1) 데이터 준비 및 스케일링

R에서 기본적으로 제공하는 iris 데이터를 활용하여 군집모델 생성을 위해 군집에 적합한 데이터를 준비한다. caret 패키지의 createDataPartition 함수를 사용하여 훈련 데이터 세트와 검증 데이터 세트를 준비한다. 또 scale 함수를 사용하여 iris 데이터를 표준화한다.

```
> library(caret)
> set.seed(102)
> index4training <- createDataPartition(y=iris$Species, p=0.7,
list=FALSE)
> training_data <- iris[index4training,]
> testing_data <- iris[-index4training,]
> training.data <- scale(training_data[,-5])
> summary(training.data)
```

	Sepal.Length		Sepal.Width		Petal.Length		Petal.Width
Min.	:-1.73764	Min.	:-2.5534	Min.	:-1.5535	Min.	:-1.4420
1st Qu.	:-0.88220	1st Qu.	:-0.5928	1st Qu.	:-1.2706	1st Qu.	:-1.1819
Median	:-0.02677	Median	:-0.1027	Median	: 0.3702	Median	: 0.1189

Mean	: 0.00000	Mean	: 0.0000	Mean	: 0.0000	Mean	:
0.0000							
3rd Qu.:	0.70646	3rd Qu.:	0.6325	3rd Qu.:	0.7662	3rd Qu.:	
0.7693							
Max.	: 2.53953	Max.	: 3.3283	Max.	: 1.7847	Max.	:
1.6799							

(2) 군집모델 생성

단계 (1)에서 iris 데이터를 훈련 데이터 세트와 검증 데이터 세트로 나누었는데, 그 중 훈련 데이터 세트를 이용하여 3개의 군집으로 군집화하는 군집모델을 생성한다.

```
> kmeans_iris <- kmeans(training.data[, -5], centers=3,
iter.max=10000)
```

(3) 검증 데이터 세트를 통한 모델 정확성 확인

단계 (2)에서 생성한 군집모델을 검증 데이터 세트를 통해 모델의 정확성을 확인하고자 한다.

```
> library("rpart")
> fitted <- train(x=training.data[, -5],
y=training_data$cluster, method="rpart")
> testing.data <- as.data.frame(scale(testing_data[-5]))
> testClusters <- predict(fitted, testing.data)
```

(4) 내부평가 방법을 이용한 모델성능 평가하기

단계 (3)에서 생성된 검증 데이터 세트의 군집결과를 바탕으로 된 지수 값을 확인한다.

```
> library("clValid")
> dunn(testClusters, testing_data)
[1] 0.5987254
```

수행 tip

- 분석목적이 예측인지, 분류인지, 군집인지 등에 따라서 분석모델을 구축하고 각 분석목적에 따라서 다른 분석모델의 성능평가 방식이 존재함을 인지한다. 분석목적과 구축한 분석모델에 부합하는 적절한 성능평가 방법을 선택하고 이를 통해 구축한 분석모델의 성능을 확인한다.
- 분석목적 및 분석모델별로 성능평가 방법이 다양하며 상황에 따라서 단 하나의 성능평가 방법을 적용하는 것이 아닌 하나 이상의 성능평가 방법을 적용해보고 분석모델의 성능에 대해 적절한 평가를 하는 것이 중요하다.
- 군집모델의 경우 가능하다면 내부평가와 외부평가 방법 모두를 적용하여 모델성능을 평가하는 것이 중요하다.

교수 방법

- 분석모델 구축과 모델 평가의 객관성을 확보하기 위해 훈련, 평가, 검증 데이터 세트로 구분함을 이해할 수 있도록 지도한다.
- 과적합이 발생하는 이유를 설명하고 불가피성에 대해 이해할 수 있도록 지도한다.
- 통계 및 데이터 마이닝 기반 분석모델들에 대한 성능평가에 있어 분석모델의 목적이 예측인지, 분류인지, 군집인지에 따라 성능평가 지표들이 상이함을 이해할 수 있도록 지도한다.
- 예측 분석모델, 분류 분석모델, 군집 분석모델별로 각 성능평가 지표들의 개념과 계산방법들에 정확히 적용할 수 있도록 지도한다.

학습 방법

- 분석모델 구축과 모델 평가의 객관성을 확보하기 위해 훈련, 평가, 검증 데이터 세트로 구분됨을 숙지한다.
- 과적합이 발생하는 이유를 설명하고 불가피성에 대해 숙지한다.
- 통계 및 데이터 마이닝 기반 분석모델들에 대한 성능평가에 있어 분석모델의 목적이 예측인지, 분류인지, 군집인지에 따라 성능평가 지표들이 다름을 이해한다.
- 예측 분석모델, 분류 분석모델, 군집 분석모델별로 어떠한 성능지표들이 있는지 숙지하고, 각 성능평가 지표들의 개념과 계산방법들에 대해 정확히 이해하고 적용할 수 있도록 학습한다.

학습3 평 가

평가 준거

- 평가자는 학습자가 학습 목표를 성공적으로 달성하였는지를 평가해야 한다.
- 평가자는 다음 사항을 평가해야 한다.

학습 내용	평가 항목	성취수준		
		상	중	하
빅데이터 분석모델 평가	- 구현된 모델은 모델 운영의 안정성과 적합성을 평가할 수 있다.			
	- 설정되어 있는 모델의 평가 절차 및 기준에 따라 구현된 모델을 평가할 수 있다.			
	- 모델 평가를 위한 데이터 세트는 훈련 데이터 세트와 구분, 관리되어 평가의 객관성을 확보할 수 있다.			
	- 모델 평가의 전 과정을 절차에 따라 진행되었음을 증적으로 확보해야 하고 모델 평가결과를 리포팅할 수 있다.			

평가 방법

- 문제해결 시나리오

학습 내용	평가 항목	성취수준		
		상	중	하
빅데이터 분석모델 평가	- 하나의 예측 빅데이터 분석모델 결과를 예측오차 및 교차 유효성 검사를 통해 성능평가를 수행할 수 있도록 R 통계프로그램을 작성할 수 있는 능력			
	- 하나의 분류 빅데이터 분석모델 결과를 혼동행렬 및 ROC 곡선검사를 통해 성능평가를 수행할 수 있도록 R 통계프로그램을 작성할 수 있는 능력			
	- 하나의 군집 빅데이터 분석모델 결과에 대해 내부평가를 통해 성능평가를 수행할 수 있도록 R 통계프로그램을 작성할 수 있는 능력			

• 평가자 질문

학습 내용	평가 항목	성취수준		
		상	중	하
빅데이터 분석모델 평가	- 분석모델 구축 및 성능평가 시, 훈련, 평가, 검증 데이터 세트로의 구분이유에 대한 이해도			
	- 과적합이 발생하는 이유 및 불가피성에 대해 이해도			
	- 통계 및 데이터 마이닝 기반 분석모델들에 대한 성능평가에 있어 분석모델의 목적이 예측인지, 분류인지, 군집인지에 따라 성능평가 지표들의 상이함에 대한 이해도			
	- 예측 분석모델, 분류 분석모델, 군집 분석모델별 성능평가 지표들에 대한 이해도 및 각 성능평가 지표들의 개념과 계산방법들에 대한 이해도			

피드백

1. 문제해결 시나리오

- 평가 항목별로 통계 프로그램 수행을 통해 나온 성능 평가결과를 직접 수작업을 통해 동일한 계산을 수행하도록 유도하고 그 결과를 앞서 도출된 결과와 비교해볼 기회를 제공함으로써 성능 평가결과가 어떠한 논리적인 근거를 통해 도출된 것인지 실제 체험할 기회를 제공한다.

2. 평가자 질문

- 데이터 세트 구분을 통해 분석모델을 구축하고 각 데이터 세트들의 활용목적에 대해 명확히 이해하고 있는지 확인한다. 만일 이를 명확히 이해하지 못한 학생들에게는 실습과제를 통하여 이해도를 높일 수 있다.
- 과적합이 발생하는 이유와 왜 과적합이 불가피한지에 대해 명확히 이해하고 있는지 확인한다. 만일 이를 이해하지 못한 학생들에게는 관련 자료 수집 및 요약하는 과제를 요구하거나 혹은 추가 예시를 통해 이해도를 높일 수 있다.
- 분석목적에 따른 분석모델에 대한 성능평가 지표 간의 차이점을 명확히 이해하고 있는지 확인하고, 각 성능평가 지표들을 어떻게 계산하고 결과를 도출하는지에 대해 명확히 이해하고 있는지 확인한다. 만일 이를 명확히 이해하지 못하는 학생들에게는 실습과제를 통하여 이해도를 높일 수 있다.

학습 1	가설 설정하기(LM2001010506_15v1.1)
학습 2	빅데이터 모델 개발하기(LM2001010506_15v1.2)
학습 3	빅데이터 모델 평가 검증하기(LM2001010506_15v1.3)
학습 4	빅데이터 모델 운영방안 마련하기 (LM2001010506_15v1.4)

4-1. 빅데이터 모델 운영시스템 적용방안

학습 목표

- 절차에 따라 모델 평가가 완료되어 모델을 운영 시스템에 전개할 수 있다.
- 운영 시스템에 모델을 적용하기 위하여 필요시 운영시스템에 적용이 가능한 프로그램 언어로 설계할 수 있다.

필요 지식 /

① 빅데이터 모델 개발 및 운영 단계

본 절에서는 빅데이터 모델 개발부터 운영에 이르기까지의 과정에 대해 단계별로 간략히 살펴보고자 한다.

1. 분석 목적의 정의

분석을 위해서는 무엇보다도 문제가 무엇인지, 어떠한 방식으로 분석하고 문제를 해결하고자 하는지에 대한 목적을 명확히 해야 한다. 또 이 단계에서 문제 해결을 위한 분석 기법으로써 빅데이터 모델의 적용 가능성을 판단한다.

2. 가설 검토

분석의 목적을 명확히 한 이후, 빅데이터 모델 개발을 통해 문제 해결에 적합한 가설을 세우고 어떠한 통계적으로 유의미한 결론을 도출하며 그 결과를 어떻게 활용하여 문제를 해결할 것인지에 대한 구체적인 검토를 수행한다.

3. 데이터 준비 및 처리

이 단계에서는 빅데이터 모델 구축 및 이를 활용한 분석을 위한 데이터를 파악하고 이들을 수집, 저장하는 단계이다. 또 변수에 대한 정의, 단위 및 수집/측정 기간에 대한 일관성 점검, 그리고 데이터 정제, 결측치 처리 등의 데이터 전처리 과정을 수행한다. 더 나아가, 불필요한 변수는 제거하고 변수 변환 혹은 필요하다면 새로운 파생변수를 생성하는 등의 작업을 통해 변수별로 분석모델에 포함하는 것이 타당한지 확인해야 한다. 데이터 마이닝 기반 분석모델을 개발할 때는 훈련 데이터 세트, 평가 데이터 세트, 검증 데이터 세트로 수집된 데이터를 나누는 작업도 이 단계에서 수행한다.

4. 모델링 및 분석


앞선 1, 2단계에서 검토되었던 사안(분석목적, 가설검토 등)에 대해 구체적인 통계적 질문으로 변환하는 단계로, 분석목적에 부합하는 빅데이터 분석 유형 및 적합한 모델을 선택한다. 그리고 3단계에서 준비된 데이터(특히 훈련 데이터 세트를 이용)를 이용하여 분석모델을 도출한다.

5. 정확도 및 성능 평가

4단계에서 도출된 빅데이터 분석모델에 대하여 검증 데이터 세트를 이용하여 분석모델의 성능을 평가하는 단계이다.

6. 운영

마지막 단계에서는 분석모델을 운영시스템과 통합하여 분석목적에 맞게 도출된 빅데이터 분석모델을 활용하는 것이다.



[그림 4-1] 빅데이터 모델 개발 및 운영 프로세스

② 빅데이터 모델의 운영시스템 적용 방안

수집된 빅데이터를 기반으로 도출된 분석모델을 의사결정에 활용하기 위해서는 운영시스템과의 통합이 요구된다. 이는 분석모델을 도출하기 위해 어떠한 통계 툴(R, SAS 등) 혹은 개발언어(파이썬, 자바 등)가 사용되었는지에 따라서 이를 운영시스템과 통합하는 작업의 난이도가 상이하게 된다. 예를 들어 운영시스템의 개발언어와 분석모델을 도출하기 위해 사용된 언어가 같을 경우에는 분석모델의 운영시스템 내 통합과정이 상대적으로 용이하다고 할 수 있다. 반면, 대부분의 통계 패키지들을 통해 분석모델이 개발된 경우에는 운영시

시스템과 통계 패키지와 호환하기 위한 인터페이스 개발이 추가로 필요하게 된다. 운영시스템상에서 분석모델을 호출하여 예측결과 등의 의사결정을 위해 필요한 데이터를 전달받기 위해서는 앞서 언급한 인터페이스를 통해 통계 패키지 혹은 개발언어로 구현된 모듈을 구동하고 그 결과값을 인터페이스를 통해 직접 전달받거나 아니면 파일, DBMS를 통해 간접적으로 전달받아서 활용하는 방법도 가능하다.

수행 내용 / 빅데이터 모델의 운영시스템 적용하기

재료 · 자료

- 분석 세부 계획 수립을 위한 조직 내/외부 정보
- 통계 및 연구방법론 관련 도서/논문

기기(장비 · 공구)

- 컴퓨터, 프린터
- 문서 편집 도구
- 인터넷

안전 · 유의 사항

- 해당 없음

수행 순서

① 빅데이터 분석모델을 운영시스템에 적용할 때 먼저 운영시스템의 구성을 이해하고 어떠한 모듈에 도출된 분석모델을 적용할지를 판단한다.

통계기반 빅데이터 분석모델 개발은 분석목적에 부합되게 개발되어야 하며, 초기 단계부터 분석모델에 활용될 독립변수들에 해당하는 데이터를 어떻게 운영시스템으로 전달받고 분석모델 결과물을 전체 비즈니스 프로세스 및 운영 시스템상에 어떠한 방식으로 활용할 것인지에 대해 명확히 해야 한다.

- ② 분석모델 개발언어 혹은 패키지 등을 고려하여 운영시스템 내 모듈과 어떠한 방식으로 통합할지를 결정하고 구현한다.

분석모델이 개발되고 성능평가가 이루어진 이후에는 운영시스템과의 통합을 위하여 통합 방식을 결정한다. 그에 맞추어 분석모델에 해당하는 모듈과 운영시스템상의 모듈 간 인터페이스를 위한 추가적인 작업을 통해 분석모델과 운영시스템 간의 통합작업을 추진해야 한다.

수행 tip

- 분석모델을 운영시스템에 적용하는 데 있어 분석목적과 이를 통해 어떠한 문제를 해결하고자 하는지에 대해 명확히 하고 운영시스템에 어떻게 통합할지를 고민할 필요가 있다.

4-2. 빅데이터 모델 운영 및 개선 방안 수립

학습 목표

- 전개된 모델의 생명주기(life cycle)를 이해하고 모델의 운영 주기, 모델의 정밀도 등 설정된 평가 기준에 따라 모델 개선방안을 수립할 수 있다.
- 모델이 운영시스템에서 원활하게 운영될 수 있도록 운영방안을 수립할 수 있다.

필요 지식 /

① 빅데이터 모델 개선방안

빅데이터 분석모델이 운영시스템에 적용된 후 지속적인 분석모델에 대한 성능추적이 필요하다. 아무리 처음에는 성능이 좋은 분석모델이라 할지라도 시간이 지남에 따라서 제반 상황이 변하게 되고 그에 따른 성능저하가 발생할 수 있기 때문이다. 본 절에서는 예측 오차를 추적하기 위한 방안에 대해 살펴보기로 한다.

1. 예측모델에 대한 성능추적

예측모델에 대해서는 예측 오차를 지속해서 추적하여 예측 오차가 지속해서 증가하는지 혹은 감소하는지를 확인하게 된다. 이를 통해 예측모델의 타당성을 지속해서 확인한다. 일반적으로 예측 오차의 추적은 추적 신호(Tracking Signal; TS)값을 활용하여 지속해서 추적하게 되는데, 만약 예측 오차 $y_i - \hat{y}_i$ 을 e_i 로 정의한다면 추적 신호 TS는

$$TS = \frac{\sum_{t=1}^n e_t}{\frac{\sum_{t=1}^n |e_t|}{n}}$$

와 같이 정의된다. 즉, TS는 예측 오차들의 합을 평균 절대편차로 나눈 값이다. TS는 0 부근에 있는 것이 정상이며 일반적으로 -4와 4사이에 있다면 예측모델이 정상적으로 성능을 유지하고 있다고 할 수 있다.

2. 예측모델에 대한 개선방안

예측 오차의 지속적인 추적을 통해 예측모델의 점검이 필요하게 되면 일반적으로 (a) 같은 분석모델을 사용하되 새로운 데이터를 수집하여 재학습을 위해 해당 분석모델 적용을 통해 수정된 분석모델을 도출하거나, (b) 아예 다른 분석 기법을 적용하여 분석모델 자체를 변경하게 된다.

수행 내용 / 빅데이터 모델 운영 및 개선 방안 수립하기

재료 · 자료

- 통계 및 연구방법론 관련 도서/논문
- 통계 패키지 활용방법 등을 소개한 도서

기기(장비 · 공구)

- 컴퓨터, 프린터
- 엑셀, 통계 패키지 등
- 인터넷

안전 · 유의 사항

- 해당 없음

수행 순서


① 매번 예측모델 수행할 때 예측모델 적용 이후 예측 오차를 계산한다.

예측모델의 성능을 지속해서 추적하기 위해서 매회 예측모델 수행 시 그 결과값과 실제값과의 차이인 예측 오차를 계산하고 기록한다.

② 추적 신호를 계산하고 추적 신호의 상 · 하한 값을 고려하여 예측모델의 점검 여부를 결정한다.

새로 계산된 예측 오차를 가지고 추적 신호를 다시 계산하고, 아래와 같은 형식의 관리도를 활용하여 추적 신호를 추적한다.

[그림 4-1]에서 나타난 바와 같이 만약 추적 신호가 추적 신호 상한(보통은 4) 혹은 하한(일반적으로 -4)을 벗어나게 되면 예측모델의 성능이 저하되고 있음을 의미하고 이에 예측 모델 점검이 필요하게 된다.



[그림 4-2] 추적 신호에 대한 관리도 예시

③ 예측모델의 점검이 필요한 경우 예측모델 개선방향을 결정한다.

예측모델이 추적 신호 상한 혹은 하한을 벗어나서 개선이 필요할 경우 예측모델 개선 방안을 모색해야 한다. 가능한 개선방안 대안으로는 업데이트된 최근 데이터 세트를 활용하여 같은 예측모델 적용을 통해 업데이트된 예측모델을 구축하고 이를 다시 적용하거나 아니면 다른 예측모델을 구축하여 상호 비교평가를 통해 선정된 예측모델로 교체하는 방안 등이 있다.

수행 tip

- 예측값에 대응하는 실제 값이 주어지면 예측 오차 및 추적 신호를 계산하게 되고, 지속적인 예측 오차의 기록이 필요하다.
- 예측모델 개선이 필요한 경우, 운영시스템의 운영에 지장에 없도록 모델 개선이 이루어져야 한다.

교수 방법

- 빅데이터 분석모델 개발 및 운영 프로세스를 이해할 수 있도록 지도한다.
- 개발된 빅데이터 분석모델을 운영시스템에 적용할 수 있는 방안에 대한 소개를 통해 실제 상황에서 분석모델을 운영시스템에 통합할 수 있도록 실습을 지도한다.
- 운영시스템에 적용된 예측 분석모델을 추적 신호를 통해 성능을 추적하는 방법을 이해가 가능하도록 지도한다.
- 예측 분석모델 개선이 필요할 경우 다양한 모델개선 방안들에 대한 소개를 통해 이해가 가능하도록 지도한다.

학습 방법

- 빅데이터 분석모델 개발 및 운영 프로세스를 명확히 숙지한다.
- 개발된 빅데이터 분석모델을 운영시스템에 적용할 수 있는 방안에 대해 숙지하고, 실제 상황에서 분석모델을 운영시스템에 통합하는 방법에 대해 이해할 수 있도록 실습한다.
- 운영시스템에 적용된 예측 분석모델을 추적 신호를 통해 성능을 추적하는 방법을 숙지한다.
- 예측 분석모델 개선이 필요할 경우 다양한 모델개선 방안들에 대해 숙지하고 실제 처리가 가능할 수 있도록 실습한다.

학습4 평 가

평가 준거

- 평가자는 학습자가 학습 목표를 성공적으로 달성하였는지를 평가해야 한다.
- 평가자는 다음 사항을 평가해야 한다.

학습 내용	평가 항목	성취수준		
		상	중	하
빅데이터 모델 운영시스템 적용방안	- 절차에 따라 모델 평가가 완료되어 모델을 운영 시스템에 전개할 수 있다.			
	- 운영 시스템에 모델을 적용하기 위하여 필요시 운영 시스템에 적용이 가능한 프로그램 언어로 설계할 수 있다.			
빅데이터 모델 운영 및 개선 방안 수립	- 전개된 모델의 생명주기(life cycle)를 이해하고 모델의 운영 주기, 모델의 정밀도 등 설정된 평가 기준에 따라 모델 개선방안을 수립할 수 있다.			
	- 모델이 운영시스템에서 원활하게 운영될 수 있도록 운영방안을 수립할 수 있다.			

평가 방법

- 사례연구

학습 내용	평가 항목	성취수준		
		상	중	하
빅데이터 모델 운영시스템 적용방안	- 빅데이터 분석모델 개발, 성능 검증 후 운영시스템에 통합하기 위한 다양한 실제 사례를 조사 후 분석			
빅데이터 모델 운영 및 개선 방안 수립	- 예측 분석모델개선이 필요할 경우 다양한 모델개선 방안들에 대해 논문 혹은 실제 사례들을 조사 및 요약			

• 평가자 질문

학습 내용	평가 항목	성취수준		
		상	중	하
빅데이터 모델 운영시스템 적용방안	빅데이터 분석모델 개발 및 운영 프로세스 이해도			
	개발된 빅데이터 분석모델을 운영시스템에 적용할 수 있는 방안에 대한 이해도			
빅데이터 모델 운영 및 개선 방안 수립	운영시스템에 적용된 예측 분석모델을 추적 신호를 통해 성능을 추적하는 방법에 대한 이해도			

피드백

1. 사례연구

- 사례연구의 목적은 빅데이터 분석모델 개발부터 실제 운영시스템에 적용까지의 전체 생애 주기를 이해하고, 특히 실제 운영시스템에 어떠한 방식으로 적용될 수 있는지를 조사함으로써 시스템 관점에서 더욱 깊은 이해를 도모하기 위함을 주지시키고, 조사 내용을 타 학습자들과 공유할 기회를 제공한다.

2. 평가자 질문

- 도출된 빅데이터 분석모델을 운영시스템에 따라서 적용하는 방안이 다를 수 있으며 이에 대해 명확히 이해하고 있는지 확인한다. 더 명확한 이해를 도모하기 위해서 가능하다면 실제 회사적용 사례들을 소개함으로써 이해도를 높일 수 있다.
- 예측 분석모델 개선이 필요한 경우 어떠한 개선방안들이 있을지를 설명할 수 있는지에 대해 확인한다. 만일 이를 이해하지 못한 학생들에게는 관련 자료 수집 및 요약하는 과제를 요구하거나 혹은 추가 예시를 통해 이해도를 높일 수 있다.



- 김우철 (2001). 『현대통계학』. 영지문화사.
- 김형수, 박대윤, 연규필, 이재남 (2016). 『이정도면 충분한 SAS 마케팅 통계분석』. 자유아카데미.
- 서진수 (2016). 『R라뷰: R을 활용한 데이터 분석 입문편』. 더알음.
- 양현철 • 김진철 • 신신애 • 김배현 (2014). 『빅데이터 활용 단계별 업무절차 및 기술 활용 매뉴얼(Version 1.0)』. 미래창조과학부.
- 전치혁, 정민근, 이해선 (1998). 『공학응용통계』. Postech Press.
- 한국데이터베이스진흥원 편 (2014). 『데이터 분석 전문가 가이드』. 한국데이터베이스진흥원.
- Alfaro, E., Gamez, M., & Garcia, N. (2013). adabag: An R Package for Classification with Boosting and Bagging. *Journal of Statistical Software*, 52(2), 1-35.
- Calinski, T., & Harabasz, J. (1974). A Dendrite Method for Cluster Analysis. *Communications in Statistics - Theory and Methods*, 3(1), 1-27.
- Han, J., Kamber, M., & Pei, J. ([2012] 2015). 『데이터마이닝 : 개념과 기법 (Data mining : concepts and techniques)』. 정사범, 송용근 (역). 에이콘출판.
- <http://happycontrol.tistory.com/entry/%EC%9D%B8%EA%B3%B5%EC%8B%A0%EA%B2%BD%EB%A7%9D1>에서 2016. 11. 21. 검색
- http://myweb.uiowa.edu/cavaaugh/ms_lec_2_ho.pdf에서 2016. 10. 01. 검색
- <https://rocr.bioinf.mpi-sb.mpg.de/ROCR.pdf>에서 2016. 10. 01. 검색
- <https://shapeofdata.wordpress.com/2013/03/26/general-regression-and-over-fitting/>에서 2016. 10.02. 검색

NCS 학습모듈 개발진

(대표집필자)

전종훈(명지대학교)*

(집필진)

김승윤(KB국민카드)*

김시환(LG CNS)*

이경미((주)프람트테크놀로지)

이재원(한국정보화진흥원)

정진석((주)위켄비앤아이)

정태수(고려대학교)

최진영(아주대학교)

홍지후(KT)*

(검토진)

김한준(서울시립대학교)

나연목(단국대학교)

윤석용((주)베가스)*

이우기(인하대학교)

장재영(한성대학교)

(공동개발기관)

최홍순(명지대학교 산학협력단)

(연구기관)

옥준필(한국직업능력개발원)

박종성(한국직업능력개발원)

나현미(한국직업능력개발원)

최영인(한국직업능력개발원)

구윤재(한국직업능력개발원)

*표시는 해당 NCS 개발진임

※ 이 학습모듈은 자격기본법 시행령(제8조 국가직무능력표준의 활용)에 의거하여 개발하였으며,
NCS 국가직무능력표준 통합포털사이트(<http://www.ncs.go.kr>)에서 다운로드 할 수 있습니다.



www.ncs.go.kr